Application des probabilités en biologie

Les chaînes de Markov et leurs utilisations biologiques

Mémoire de Master en Science des Données
Sous la direction de Pr. Hu
Université Sorbonne Paris Nord
Année universitaire 2025–2026

Introduction

La biologie est un domaine dans lequel les probabilités et les statistiques sont très présentes.
Ce mémoire étudie l'utilisation des outils mathématiques des probabilités, en particulier les chaînes de Markov à temps discret, pour la modélisation en biologie.
Il s'agit d'une première approche qui a pour objectif de donner un aperçu et une intuition de l'application de ces outils mathématiques aux modèles du vivant.

Chaînes de Markov — Définition I

Soit $(X_n)_{n\geq 0}$ une suite de variables aléatoires définies sur un espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$ et à valeurs dans un ensemble fini ou dénombrable E appelé espace d'états.
On dit que $(X_n)_{n\geq 0}$ est une chaîne de Markov si et seulement si :

(1) Propriété de Markov :

Pour tout $n \geq 0$ et pour tous $x_0, x_1, \ldots, x_{n+1} \in E$, on a :

$$\mathbb{P}(X_{n+1} = x_{n+1} \mid X_n = x_n, X_{n-1} = x_{n-1}, \ldots, X_0 = x_0) = \mathbb{P}(X_{n+1} = x$$

Autrement dit, la loi conditionnelle de X_{n+1} ne dépend que de l'état actuel X_n et non du passé.

Chaînes de Markov — Définition II

(2) **Homogénéité dans le temps :**
Les probabilités de transition sont homogènes : pour tous $x, y \in E$ et pour tout $n \geq 0$,

$$P_{xy} = \mathbb{P}(X_{n+1} = y \mid X_n = x)$$

ne dépend pas de n.

Matrice de transition

La matrice

$$P = (P_{xy})_{x,y \in E}$$

est appelée **matrice de transition** de la chaîne de Markov.

Probabilité d'absorption I

Un état $a \in E$ est dit **absorbant** si :

$$P_{aa} = 1 \quad \text{et} \quad P_{ay} = 0 \text{ pour tout } y \neq a.$$

Si la chaîne contient au moins un état absorbant, on définit pour tout état initial x et tout état absorbant a la **probabilité d'absorption** :

$$u(x) = \mathbb{P}_x(T_a < \infty),$$

où

$$T_a = \inf\{n \geq 0 : X_n = a\}.$$

Cette probabilité satisfait souvent une équation de type :

$$u(x) = \sum_{y \in E} P_{xy} u(y), \quad \text{avec } u(a) = 1.$$

Applications biologiques

En biologie, les temps discrets correspondent souvent à des cycles biologiques (générations, divisions cellulaires, épidémies), tandis que les temps continus décrivent des réactions ou transitions spontanées. Ces modèles trouvent de nombreuses applications en biologie. Nous étudierons dans le cadre de ce mémoire :

- Modélisation de la croissance d'une population,
- Modélisation de propagation d'épidémies.

Marche aléatoire — Définition I

Une **marche aléatoire** est un type particulier de chaîne de Markov sur l'ensemble des entiers $\mathbb{Z}$.
Formellement, soit $(X_n)_{n\geq 0}$ une chaîne de Markov sur $\mathbb{Z}$ telle que :

$$X_{n+1} = X_n + \xi_{n+1},$$

où $(\xi_n)_{n\geq 1}$ sont des variables aléatoires indépendantes et identiquement distribuées prenant les valeurs $+1$ ou -1 avec probabilités respectives p et $q = 1 - p$.
Cette chaîne est appelée **marche aléatoire simple**.

Propriétés de la marche aléatoire

Espérance : $\mathbb{E}[X_n] = X_0 + n(p - q)$

Variance : $\mathrm{Var}[X_n] = 4npq$

La marche est dite :

symétrique si $p = q = \frac{1}{2}$,

asymétrique sinon.

Chaînes de Markov et marches aléatoires I

La marche aléatoire est un exemple simple mais fondamental de chaîne de Markov.

La probabilité de transition est :

$$P_{i,i+1} = p, \quad P_{i,i-1} = q.$$

La matrice de transition P est tridiagonale.

Les marches aléatoires servent de modèles de base pour :

- la diffusion d'atomes ou molécules,
- la modélisation de populations,
- les processus stochastiques financiers simples.

Temps d'extinction — Définition I

Soit une population dont la taille à l'instant n est X_n.
On définit le **temps d'extinction** comme :

$$T_0 = \inf\{n \geq 0 : X_n = 0\}.$$

T_0 est une variable aléatoire.

On s'intéresse à :

la probabilité que la population s'éteigne : $\mathbb{P}(T_0 < \infty)$,
l'espérance du temps d'extinction : $\mathbb{E}[T_0]$.

Calcul du temps d'extinction

Si X_n suit une chaîne de Markov avec états $0, 1, 2, \ldots, N$, où 0 est absorbant :

$$u(i) = \mathbb{P}_i(T_0 < \infty)$$

satisfait l'équation de récurrence :

$$u(i) = \sum_{j=0}^{N} P_{ij} u(j), \quad u(0) = 1.$$

De même, l'espérance du temps d'extinction $v(i) = \mathbb{E}_i[T_0]$ satisfait :

$$v(i) = 1 + \sum_{j=0}^{N} P_{ij} v(j), \quad v(0) = 0.$$

Exemples de modèles biologiques I

Modèle de naissance-mort simple :

$X_n \to X_n + 1$ avec probabilité p (naissance),
$X_n \to X_n - 1$ avec probabilité q (mort),
$X_n \to X_n$ avec probabilité $1 - p - q$ (aucun changement).

Modèle SIS pour épidémies :

Individus susceptibles (S) ou infectés (I),
Transitions probabilistes S$\to$I et I$\to$S,
Forme une chaîne de Markov à deux états par individu.

Particularités des modèles biologiques

États absorbants : extinction de la population ou disparition de l'épidémie.

Probabilités de transition souvent dépendantes de la taille de la population :

$$P_{i,i+1} = f(i), \quad P_{i,i-1} = g(i)$$

pour i individus.

Étude de la stabilité des états et des probabilités d'absorption.

Problème de la ruine du joueur I

On énonce ici un problème classique qui pourra être apparenté par la suite à un modèle d'évolution de population basique.
On considère une marche aléatoire sur $\mathbb{Z}$ représentant la fortune d'un joueur après chaque pari. On suppose que le joueur commence avec une fortune initiale $X_0 = k$, où $0 < k < N$, et que :

- l'état 0 représente la ruine du joueur,
- l'état N représente un gain d'arrêt (le joueur quitte le jeu s'il atteint la somme N),

tous deux étant des états absorbants.
L'espace d'états est donc $E = \{0, 1, 2, \ldots, N\}$, et la matrice de transition de la chaîne de Markov associée est donnée par :

$$P_{k,k+1} = p, \quad P_{k,k-1} = q, \quad \text{pour } 1 \leq k \leq N-1,$$

Problème de la ruine du joueur II

avec $P_{00} = P_{NN} = 1$ (états absorbants), les autres probabilités de transition étant nulles.

Probabilité de ruine I

On cherche à déterminer, pour une condition initiale $X_0 = k$, la **probabilité de ruine** :

$$a_k = \mathbb{P}_k(T_0 < T_N),$$

où $T_0 = \inf\{n \geq 0 : X_n = 0\}$ et $T_N = \inf\{n \geq 0 : X_n = N\}$ désignent les temps d'atteinte des états 0 et N.
Ces probabilités $(a_k)_{0 \leq k \leq N}$ satisfont un système de relations de récurrence. En effet, par la formule des probabilités totales conditionnellement au premier pas, partant de l'état k avec $1 \leq k \leq N-1$, on atteint l'état $k+1$ avec probabilité p ou l'état $k-1$ avec probabilité q. D'où :

$$\begin{cases} a_0 = 1 \quad \text{(l'état 0 est absorbant, ruine certaine)}, \\ a_N = 0 \quad \text{(l'état } N \text{ est absorbant, pas de ruine)}, \\ a_k = p\, a_{k+1} + q\, a_{k-1}, \quad \text{pour } 1 \leq k \leq N-1. \end{cases}$$

Résolution — cas $p = q = \frac{1}{2}$ I

La relation de récurrence devient :

$$a_k = \frac{1}{2}a_{k+1} + \frac{1}{2}a_{k-1},$$

soit

$$a_{k+1} - 2a_k + a_{k-1} = 0.$$

L'équation caractéristique associée est :

$$r^2 - 2r + 1 = 0,$$

qui admet une racine double $r = 1$. La solution générale est donc de la forme

$$a_k = C_1 k + C_2,$$

où C_1, C_2 sont des constantes réelles.

Résolution — cas $p = q = \frac{1}{2}$ (suite) I

En utilisant les conditions aux bords :

$$a_0 = C_2 = 1, \qquad a_N = C_1 N + C_2 = 0,$$

on obtient

$$C_1 = -\frac{1}{N}, \quad C_2 = 1.$$

Ainsi, pour tout $k \in \{0, \ldots, N\}$,

$$\boxed{a_k = 1 - \frac{k}{N}.}$$

Résolution — cas $p \neq q$ I

La relation de récurrence est :

$$a_k = p\, a_{k+1} + q\, a_{k-1},$$

soit

$$pa_{k+1} - a_k + qa_{k-1} = 0.$$

On cherche une solution de la forme $a_k = r^k$. L'équation caractéristique associée est :

$$pr^2 - r + q = 0.$$

Comme $p + q = 1$, les deux racines sont :

$$r_1 = 1, \qquad r_2 = \frac{q}{p}.$$

Résolution — cas $p \neq q$ (suite) I

La solution générale est donc de la forme :

$$a_k = C_1 + C_2 \left(\frac{q}{p}\right)^k,$$

où C_1, C_2 sont des constantes.
En utilisant les conditions aux bords :

$$\begin{cases} a_0 = C_1 + C_2 = 1, \\ a_N = C_1 + C_2 \left(\frac{q}{p}\right)^N = 0, \end{cases}$$

on résout le système et on obtient :

$$C_2 = \frac{1}{1 - \left(\frac{q}{p}\right)^N}, \qquad C_1 = -\frac{\left(\frac{q}{p}\right)^N}{1 - \left(\frac{q}{p}\right)^N}.$$

Résolution — cas $p \neq q$ (suite) II

On en déduit l'expression explicite :

$$\boxed{a_k = \frac{\left(\frac{q}{p}\right)^k - \left(\frac{q}{p}\right)^N}{1 - \left(\frac{q}{p}\right)^N}, \qquad 0 \leq k \leq N.}$$

Modèle sans limite de taille de population I

Si l'on considère que le joueur ne dispose pas de fortune maximale (pas de borne N), on obtient un modèle sur l'espace d'états semi-infini $E = \{0, 1, 2, \ldots\}$, qui représente mieux une population biologique sans limite fixée de taille.
On étudie alors le comportement asymptotique de a_k lorsque $N \to \infty$:
Pour le modèle sans limite de taille, on a :

$$a_k = \begin{cases} 1, & \text{si } p \leq q, \\ \left(\frac{q}{p}\right)^k, & \text{si } p > q. \end{cases}$$

Si $p > q$, la probabilité d'extinction est strictement inférieure à 1 : la population a une chance de survivre indéfiniment.

Espérance du temps d'extinction I

Une autre notion intéressante est l'espérance de la durée avant extinction (ou avant que le jeu s'arrête). Dans la suite, on note t_k l'espérance du temps avant extinction partant de l'état k.
En partant de l'état k, on effectue une transition, puis on se retrouve en $k+1$ avec probabilité p ou en $k-1$ avec probabilité q. D'où l'équation de récurrence :

$$t_k = 1 + p\, t_{k+1} + q\, t_{k-1}, \quad 1 \leq k \leq N-1,$$

avec les conditions aux bords $t_0 = t_N = 0$ (le jeu s'arrête).

Résolution dans le cas borné I

On peut résoudre cette équation de la même manière que pour les probabilités d'extinction. On obtient dans le cas borné le résultat suivant (pour $p \neq q$) :

$$t_k = \frac{1}{q-p}\left[k - N\left(\frac{1-\left(\frac{q}{p}\right)^k}{1-\left(\frac{q}{p}\right)^N}\right)\right].$$

Pour le cas $p = q = \frac{1}{2}$, on a :

$$t_k = k(N-k).$$

Passage au cas semi-infini I

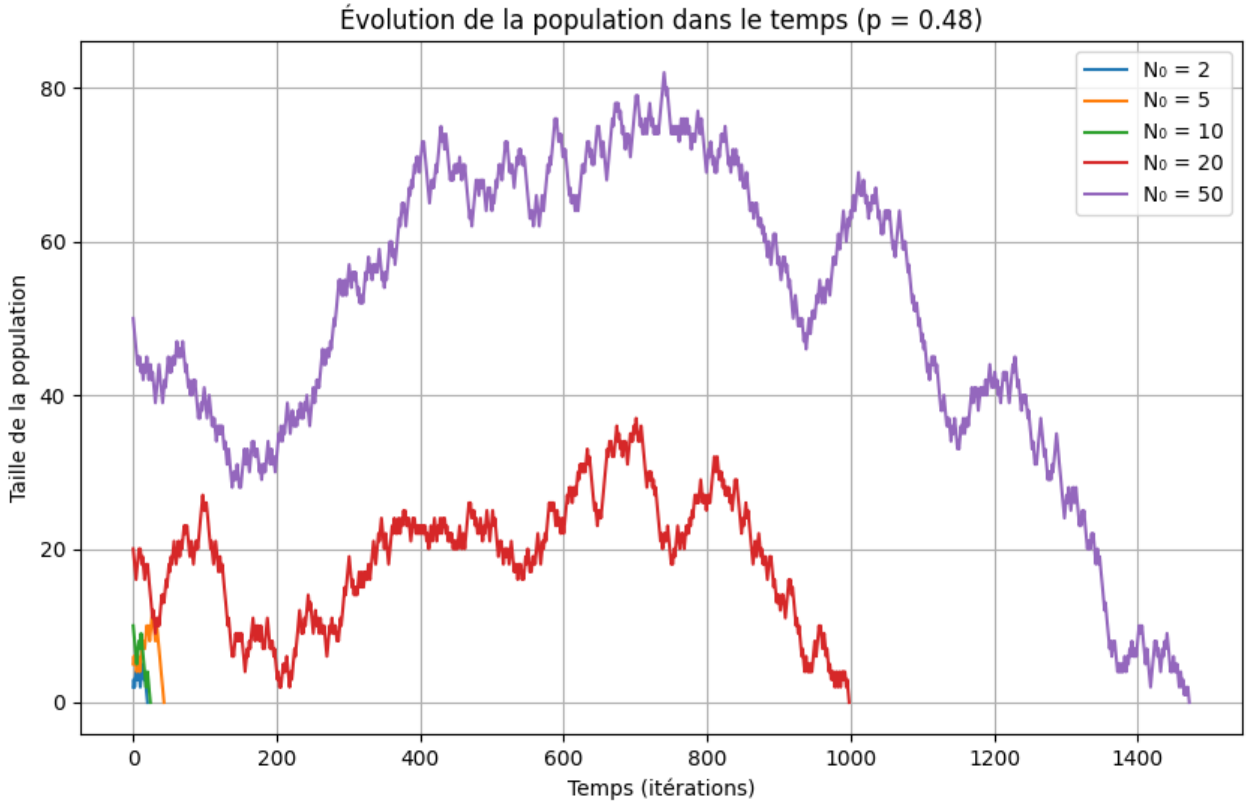
Dans le cas d'un domaine semi-infini ($N \to \infty$), on obtient :

$$t_k = \begin{cases} \dfrac{k}{q-p}, & \text{si } p < q, \\ +\infty, & \text{si } p \geq q. \end{cases}$$

Exemples de modélisations I

Un bon moyen de se rendre compte de ce que l'on manipule est d'observer et de comparer des graphes en modifiant les différents paramètres à notre disposition.
Les figures 2.1, 2.2 et 2.3 montrent toutes les trois des exemples d'évolutions de la population et du moment où elles s'éteignent en fonction de populations initiales différentes. Ce qui change entre ces trois figures, ce sont les probabilités de naissance et de mort d'un individu à chaque pas.

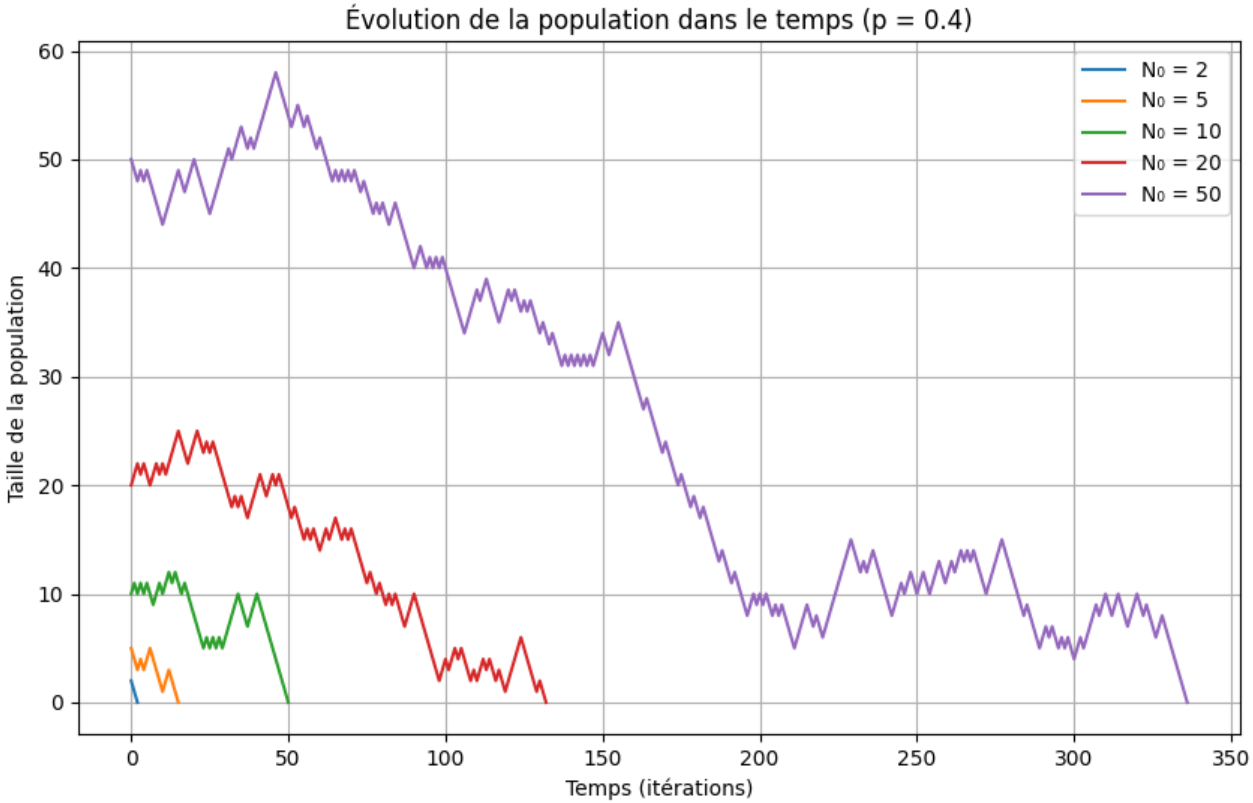
Évolution de la population pour $p = 0.4$



Commentaires I

Les figures 2.1 et 2.2 illustrent parfaitement le cas $p < q$: en fonction de la population de départ, cela met plus ou moins de temps à s'éteindre.

Évolution de la population pour $p = 0.45$



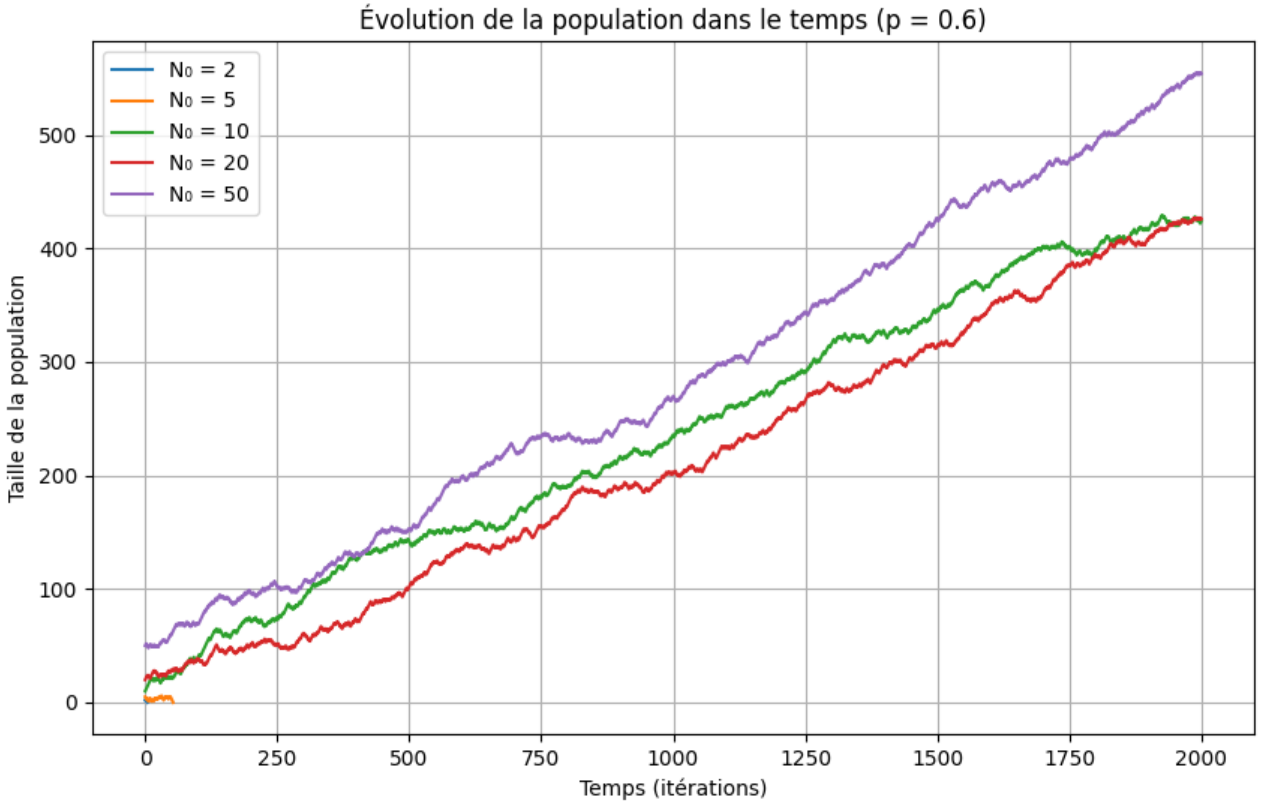
Commentaires I

La figure 2.3 n'a rien de surprenant pour une population assez importante : puisqu'il y a plus de chances d'avoir une naissance qu'une mort, on se retrouve rapidement vers une population qui croît indéfiniment. On observe tout de même pour les populations initiales 2 et 5 une extinction.
Théoriquement, avec ce que l'on a vu précédemment :

Pour la population initiale de 2 : probabilité d'extinction $a_2 = \left(\frac{0,4}{0,6}\right)^2 = \frac{4}{9} \approx 0,44.$

Pour la population initiale de 5 : probabilité d'extinction $a_5 = \left(\frac{0,4}{0,6}\right)^5 \approx 0,132.$

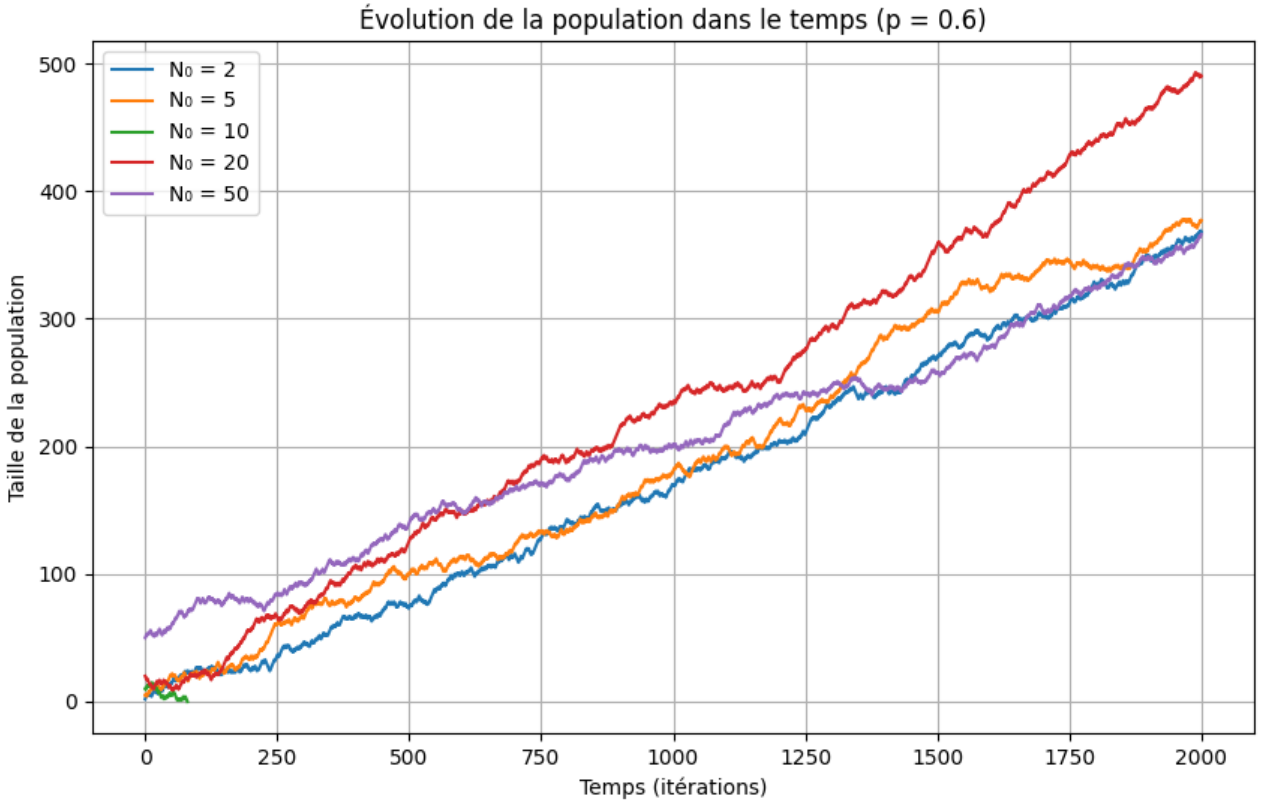
Évolution de la population pour $p = 0.6$



Extinction rare I

Ce résultat n'a pas été reproduit lors des simulations ultérieures. Cependant, une autre simulation a donné un résultat encore moins probable : une extinction pour une population initiale de 10, ce qui correspond à une probabilité théorique d'environ 0,017.

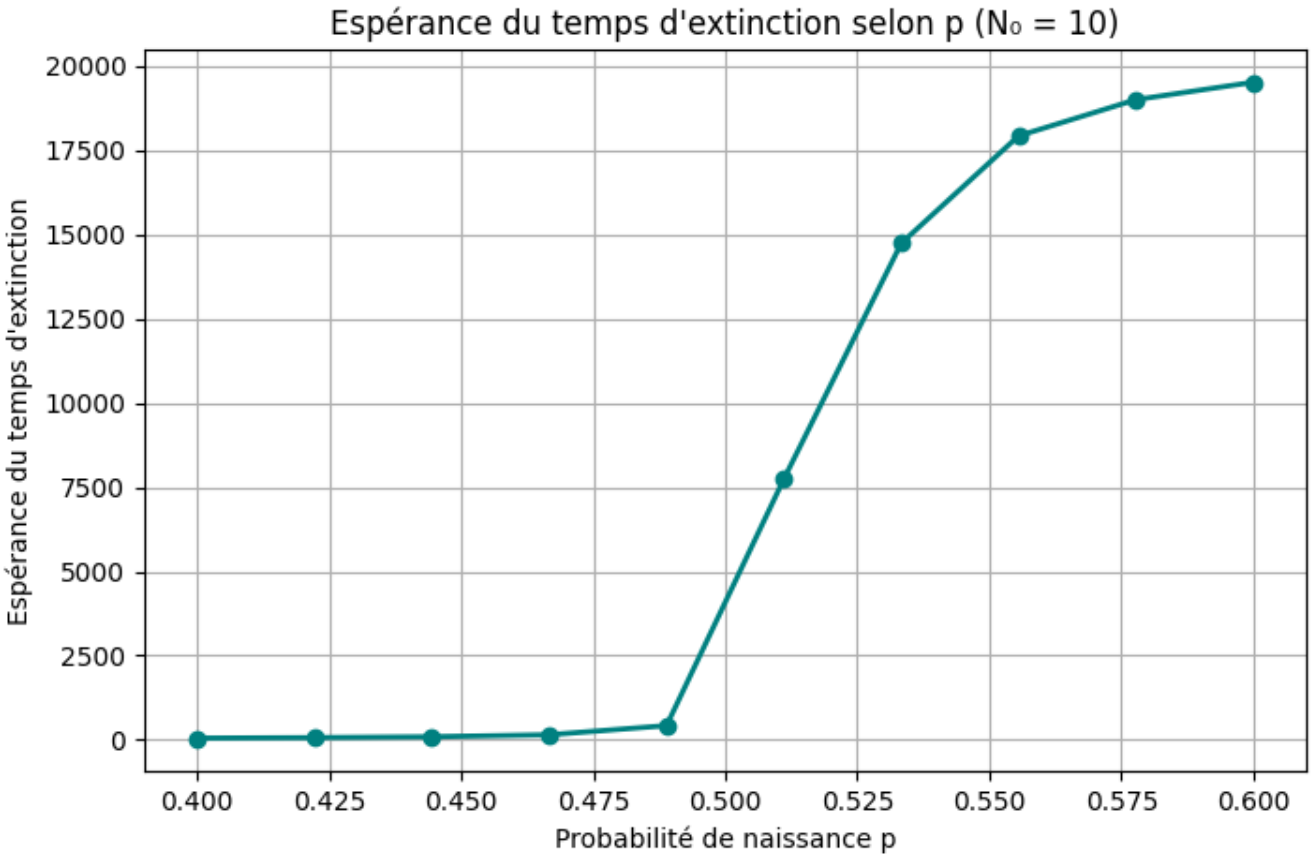
Extinction rare pour une population initiale de 10 avec $p = 0.6$



Espérance du temps d'extinction I

Une autre donnée importante à regarder est l'évolution de l'espérance du temps d'extinction : au bout de combien de temps on peut « espérer » qu'une population s'éteigne en fonction du paramètre p et d'une population initiale.
En faisant varier la population initiale (non illustré ici), on observe que plus la population de départ est importante, plus la variation de l'espérance du temps d'extinction est marquée lorsque p varie.

Espérance du temps d'extinction en fonction de p



Modèles dans le cadre général I

Le cadre précédent est intéressant pour se donner une idée de comment ce type de modélisation fonctionne. Cependant, pour obtenir une modélisation plus réaliste des phénomènes biologiques, il convient d'élargir le modèle et de considérer un cadre plus général.
Tout d'abord, il faut comprendre la différence de situation. Dans le chapitre précédent, nous étions dans le cadre où, à chaque étape, on obtenait soit une naissance avec une probabilité p, soit une mort avec une probabilité $q = 1 - p$, ces probabilités étant **constantes**.
Dans le cadre général, il faut considérer que la probabilité d'avoir une naissance (resp. une mort) évolue en fonction de la taille de la population. On aura donc des probabilités qui changent à chaque pas.

Probabilité d'absorption dans le cadre général I

Contrairement au modèle précédent où p et q étaient constants, on considère maintenant que les probabilités de naissance et de mort dépendent de la taille actuelle de la population. On note :

$$p_k = \mathbb{P}(\text{naissance} \mid X_n = k), \quad q_k = \mathbb{P}(\text{mort} \mid X_n = k),$$

avec $p_k + q_k = 1$ pour tout $k \geq 1$.
Avec ces nouvelles considérations sur les probabilités, on obtient la relation :

$$a_k = p_k a_{k+1} + q_k a_{k-1},$$

avec la condition aux bords :

$$a_0 = 1.$$

Formule générale I

La formule générale est :
En notant $\rho_0 = 1$ et $\rho_j = \prod_{i=1}^{j} \frac{q_i}{p_i}$ pour $j \geq 1$,

$$a_k = \frac{\sum_{j=k}^{\infty} \rho_{j-1}}{\sum_{j=0}^{\infty} \rho_j} = \frac{\sum_{j=k-1}^{\infty} \rho_j}{\sum_{j=0}^{\infty} \rho_j}, \quad \text{si } \sum_{j=0}^{\infty} \rho_j < +\infty.$$

Espérance associée I

Et son espérance :

En posant :

$$u_k^{(N)} = t_k^{(N)} - t_{k-1}^{(N)}, \qquad 1 \leq k \leq N.$$

$$\boxed{t_k^{(N)} = \sum_{i=1}^{k} \left[\left(\prod_{l=1}^{i-1} \frac{q_l}{p_l} \right) u_1^{(N)} - \sum_{j=1}^{i-1} \frac{1}{p_j} \prod_{l=j+1}^{i-1} \frac{q_l}{p_l} \right].}$$

Processus logistique stochastique I

Le processus logistique stochastique est une généralisation des modèles de naissance et mort qui prend en compte l'effet de densité dans la croissance d'une population.
Rappelons d'abord le **modèle déterministe de croissance logistique** :

$$\frac{\mathrm{d}y}{\mathrm{d}t} = ry\left(1 - \frac{y}{K}\right), \quad y(0) = y_0,$$

où $r > 0$ est le taux de croissance intrinsèque et $K > 0$ est la capacité de charge (taille maximale soutenable de la population).

Taux de transition I

Le processus stochastique considère des transitions à temps discret avec les taux suivants :

$$\lambda_k = r\,k\left(1-\frac{k}{K}\right), \quad \text{(taux de naissance)},$$
$$\mu_k = d\,k, \qquad\qquad\qquad \text{(taux de mortalité)},$$

pour $k \geq 1$, où $d > 0$ est le taux de mortalité par individu.

Remarque I

Dans un processus à temps discret, on peut interpréter λ_k et μ_k comme des probabilités de naissance et de mort (en posant par exemple $p_k = \lambda_k/(\lambda_k + \mu_k)$ et $q_k = \mu_k/(\lambda_k + \mu_k)$ après normalisation).

Quasi-stationnarité I

Les taux dépendant désormais de la taille de la population, on introduit la notion de **quasi-stationnarité** : la population peut rester longtemps autour d'un état d'équilibre avant une extinction éventuelle.

On peut l'interpréter comme suit :

Si la croissance est faible ($r \approx d$), l'espérance t_k reste finie et la population s'éteint rapidement.

Si la population est proche de la capacité K et que $r > d$, t_k peut devenir très grande : la population se maintient longtemps autour d'un certain équilibre.

Distributions quasi-stationnaires I

La distribution quasi-stationnaire (QSD) décrit la répartition des tailles de population avant extinction, souvent concentrée autour du quasi-équilibre déterministe.
Même si l'extinction est inévitable à long terme, la QSD permet d'étudier le comportement moyen des populations vivantes sur de longues durées. Ce concept est particulièrement utile pour des espèces où le temps d'absorption est très long par rapport aux échelles d'observation biologique.
Elle permet ainsi de décrire la population comme évoluant autour d'un équilibre probabiliste, tout en intégrant implicitement la possibilité d'extinction à long terme.

Dépendance aux taux I

Comme on l'a vu précédemment, dans le cas du processus logistique stochastique, les taux de transition dépendent de la taille de la population :

$$\lambda_k = r\,k\left(1-\frac{k}{K}\right), \qquad \mu_k = d\,k.$$

Contrairement au modèle déterministe, cette dépendance introduit des changements aléatoires qui peuvent conduire à l'extinction.

Temps d'extinction I

Lorsque le taux de croissance est proche du taux de mortalité ($r \approx d$), les probabilités de décès compensent rapidement les naissances et l'espérance du temps d'extinction t_k reste modérée.
En revanche, lorsque $r > d$ et que la population évolue à proximité de la capacité de charge K, les rapports μ_k/λ_k deviennent faibles sur une large plage de valeurs de k, ce qui augmente l'espérance du temps d'extinction.
Typiquement ici, la distribution quasi-stationnaire fournit une approximation pertinente : la population reste longtemps concentrée autour d'un équilibre stochastique conditionnel avant que l'aléatoire ne conduise à l'extinction.

Temps d'extinction — définition I

On note le temps d'extinction :

$$T_0 = \inf\{t \geq 0 : X_t = 0\}.$$

Même si $\mathbb{P}(T_0 < \infty) = 1$ pour tout état initial $X_0 = k \geq 1$, on peut étudier la distribution quasi-stationnaire.

Définition I

Definition (Distribution quasi-stationnaire)

Une probabilité ν sur $\{1, \ldots, K\}$ est dite quasi-stationnaire si, pour tout $t \geq 0$ et $i \geq 1$:

$$\mathbb{P}_\nu(X_t = i \mid T_0 > t) = \nu(i),$$

où $\mathbb{P}_\nu$ désigne la probabilité sous la loi initiale $X_0 \sim \nu$.

Modèle SIS I

Le modèle SIS (Susceptible–Infectious–Susceptible) est un modèle épidémiologique simple dans lequel les individus peuvent être infectés, puis guéris, et redevenir susceptibles.
Il est particulièrement adapté à la modélisation de maladies pour lesquelles l'immunité n'est pas permanente.
On note :

$S(t)$: nombre d'individus susceptibles à l'instant t,

$I(t)$: nombre d'individus infectés à l'instant t,

avec une population totale constante :

$$N = S(t) + I(t).$$

Modèle SIS déterministe I

Le modèle déterministe associé est donné par l'équation différentielle :

$$\frac{\mathrm{d}I}{\mathrm{d}t} = \beta\frac{(N-I)I}{N} - \gamma I,$$

où :

$\beta > 0$ est le taux de transmission,

$\gamma > 0$ est le taux de guérison.

Nombre de reproduction de base I

On définit le nombre de reproduction de base :

$$\boxed{\mathcal{R}_0 = \frac{\beta}{\gamma}.}$$

Ce paramètre permet de déterminer le comportement asymptotique de la maladie.

Résultats I

Si $\mathcal{R}_0 \leq 1$, alors $I(t) \to 0$: extinction de la maladie.

Si $\mathcal{R}_0 > 1$, alors il existe un équilibre endémique non nul.

Modèle SIS stochastique I

Dans le modèle stochastique, le nombre d'individus infectés est modélisé par une chaîne de Markov à temps discret sur l'ensemble $\{0, 1, \ldots, N\}$.
Les transitions sont données par :

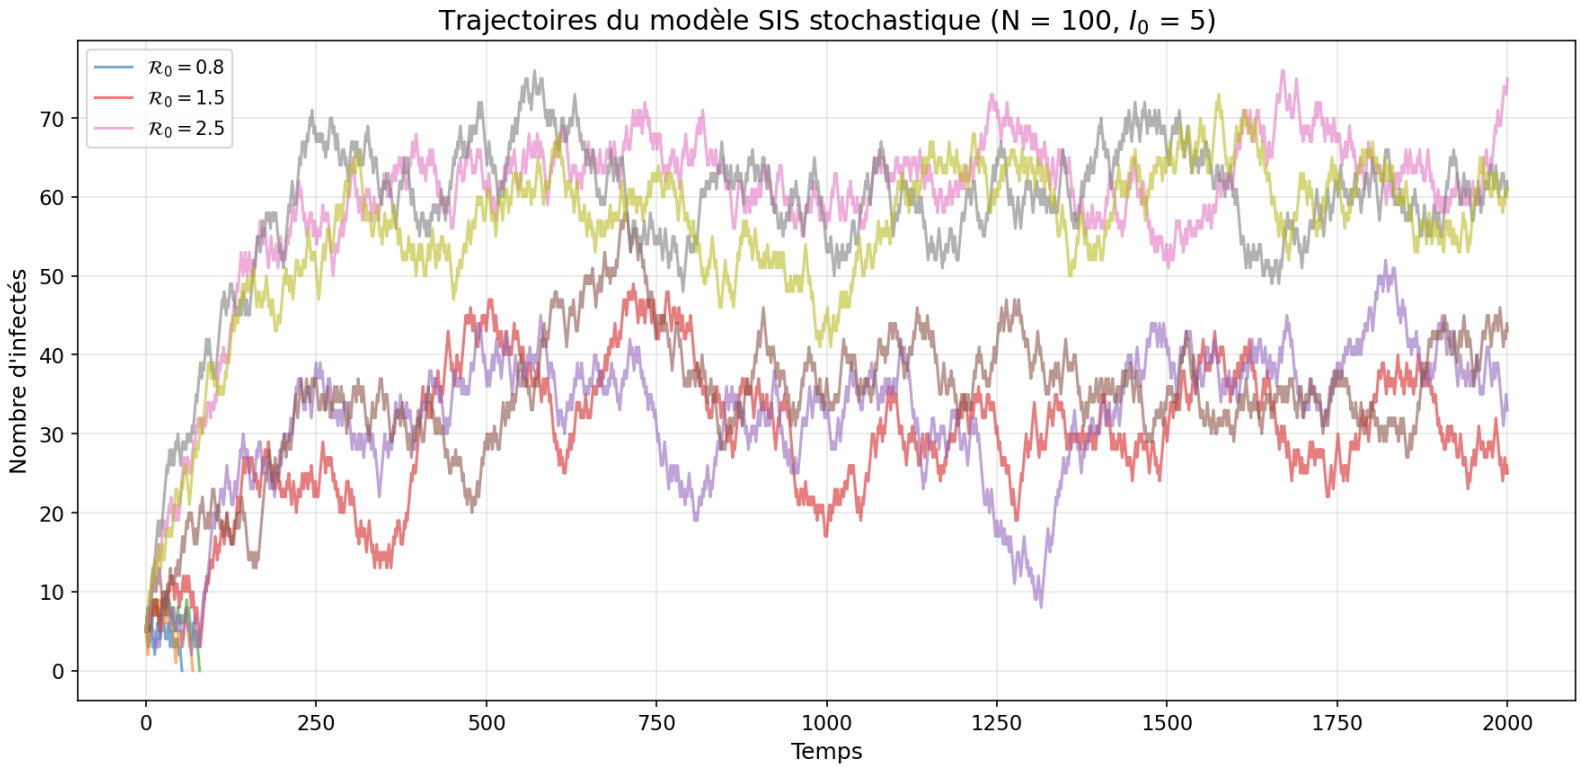
$$\mathbb{P}(I_{n+1} = i + 1 \mid I_n = i) = \beta \frac{i(N - i)}{N},$$
$$\mathbb{P}(I_{n+1} = i - 1 \mid I_n = i) = \gamma i.$$

L'état 0 est absorbant et correspond à l'extinction de la maladie.

Comparaison déterministe / stochastique I

Contrairement au modèle déterministe, le modèle stochastique prend en compte les fluctuations aléatoires dues à la taille finie de la population.
Ainsi, même lorsque $\mathcal{R}_0 > 1$, l'extinction reste possible avec une probabilité strictement positive.
Ce phénomène est analogue à celui observé dans les modèles de croissance de population étudiés précédemment.

Trajectoires du modèle SIS



Conclusion I

Dans ce mémoire, nous avons étudié l'utilisation des chaînes de Markov pour modéliser des phénomènes biologiques simples, en particulier la croissance de population et la propagation de maladies. À travers différents modèles, nous avons vu que l'aléatoire joue un rôle fondamental, notamment pour expliquer des phénomènes tels que l'extinction, même lorsque les modèles déterministes prédisent une survie ou un équilibre stable.
Ces modèles simples constituent une première étape vers des modèles plus complexes, intégrant davantage de paramètres biologiques, et ouvrent la voie à des applications dans des domaines variés tels que l'écologie, l'épidémiologie ou encore la dynamique des populations.

Merci pour votre attention