ACP

MAAT Joshua

USPN

Année universitaire 2025–2026

Plan

1. Introduction
2. Outils Mathématiques
3. Présentation du jeu de données
4. Matrice de corrélation
5. Choix du type d'ACP et lancement
6. Choix du nombre de composantes
7. Analyse des variables — cercles des corrélations
8. Analyse des individus — plan factoriel
9. Variables illustratives
10. Interprétation
11. Conclusion

Introduction

- L'ACP est une méthode descriptive de données.

Introduction

- L'ACP est une méthode descriptive de données.
- L'ACP cherche à représenter un nuage de n individus dans R^p en un nuage dans R^q, avec $q << p$, tout en conservant au mieux l'information.

Introduction

- L'ACP est une méthode descriptive de données.
- L'ACP cherche à représenter un nuage de n individus dans R^p en un nuage dans R^q, avec $q << p$, tout en conservant au mieux l'information.
- Fiabilité des informations représentées ?

Outils Mathématiques

- Mesurer la dispersion d'un nuage de points : Matrice de variance-covariance.

Outils Mathématiques

- Mesurer la dispersion d'un nuage de points : Matrice de variance-covariance.
- Réduction de la dimension : La projection orthogonale.

Outils Mathématiques

- Mesurer la dispersion d'un nuage de points : Matrice de variance-covariance.
- Réduction de la dimension : La projection orthogonale.
- Quelle est la meilleure représentation ? Résultat d'optimisation.

Theorem (Décomposition spectrale)

Toute matrice symétrique réelle $\mathrm{M} \in \mathbb{R}^{n \times n}$ *est diagonalisable dans une base orthonormée :*

$$\mathrm{M} = \mathrm{U}\mathrm{A}\mathrm{U}^{\top},$$

où $\mathrm{U} \in \mathbb{R}^{n \times n}$ *est une matrice orthogonale dont les colonnes* $(\boldsymbol{u}_1, \ldots, \boldsymbol{u}_n)$ *forment une base orthonormée de* $\mathbb{R}^n$*, ce sont les vecteurs propres de M.*
Aussi on a $\mathrm{A} = \mathrm{diag}(\lambda_1, \ldots, \lambda_n)$.
Avec les valeurs propres ordonnées : $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$.

Outils Mathématiques

- Décomposition spectrale -> Meilleur sous espace de projection des données.
  (théorème du quotient de Rayleigh)

Outils Mathématiques

- Décomposition spectrale -> Meilleur sous espace de projection des données.
  (théorème du quotient de Rayleigh)
- La SVD (Décomposition en valeurs singulières) nous donne le même résultat.

Outils Mathématiques

- Décomposition spectrale -> Meilleur sous espace de projection des données.
  (théorème du quotient de Rayleigh)
- La SVD (Décomposition en valeurs singulières) nous donne le même résultat.
- En pratique la SVD est plus stable numériquement.
  Les algorithmes pour la calculer sont complexes.

Présentation du jeu de données

Le dataset `decathlon` est disponible dans `FactoMineR`. Il regroupe les performances de 41 athlètes masculins lors de deux compétitions de décathlon : le *Decastar* (13 athlètes) et les *Jeux Olympiques d'Athènes 2004* (28 athlètes). Chaque athlète est décrit par 13 variables.

Présentation du jeu de données

Épreuve	SEBRLE	CLAY	KARPOV	BERNARD
100m	11.04	10.76	11.02	11.02
Long jump	7.58	7.40	7.30	7.23
Shot put	14.83	14.26	14.77	14.25
High jump	2.07	1.86	2.04	1.92
400m	49.81	49.37	48.37	48.93
110m hurdle	14.69	14.05	14.09	14.99
Discus	43.75	50.72	48.95	40.87
Pole vault	5.02	4.92	4.92	5.32
Javelin	63.19	60.15	50.31	62.77
1500m	291.70	301.50	300.20	280.10
Rank	1	2	3	4
Points	8217	8122	8099	8067
Competition	Decastar	Decastar	Decastar	Decastar

Présentation du jeu de données

On distingue trois types de variables :

- **Variables actives** (lignes 1 à 10) : les dix épreuves.

Présentation du jeu de données

On distingue trois types de variables :

- **Variables actives** (lignes 1 à 10) : les dix épreuves.
- **Variables illustratives quantitatives** (lignes 11 et 12) : `Rank` et `Points`.

Présentation du jeu de données

On distingue trois types de variables :

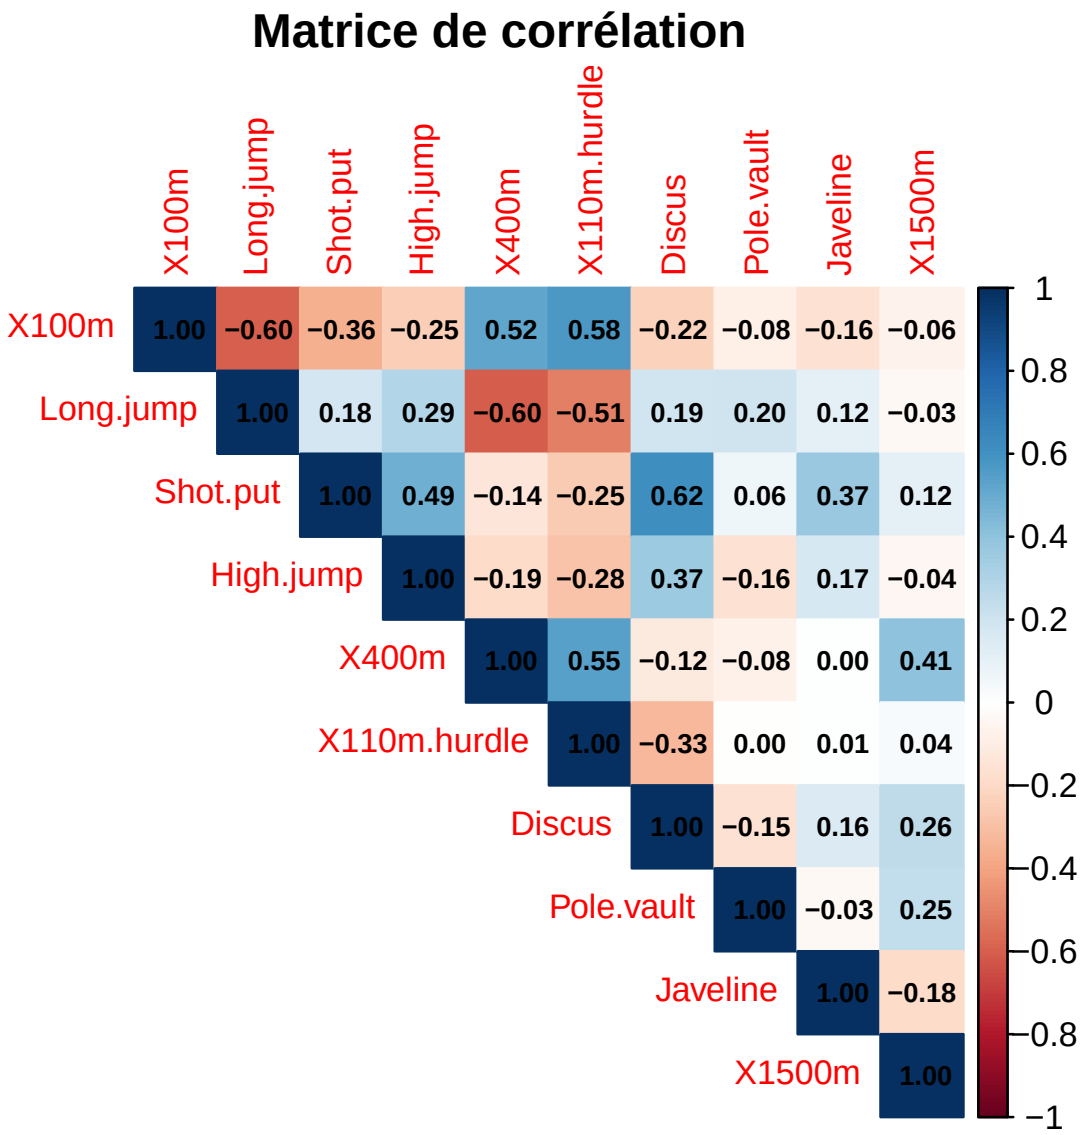
- **Variables actives** (lignes 1 à 10) : les dix épreuves.
- **Variables illustratives quantitatives** (lignes 11 et 12) : `Rank` et `Points`.
- **Variable illustrative qualitative** (ligne 13) : `Competition`.

Présentation du jeu de données

Table – Statistiques descriptives des dix variables actives.

Variable	Unité	Min.	Moyenne	Max.
100m	secondes	10,44	11,00	11,64
Long.jump	mètres	6,61	7,26	7,96
Shot.put	mètres	12,68	14,48	16,36
High.jump	mètres	1,85	1,98	2,15
400m	secondes	46,81	49,62	53,20
110m.hurdle	secondes	13,97	14,61	15,67
Discus	mètres	37,92	44,33	51,65
Pole.vault	mètres	4,20	4,76	5,40
Javeline	mètres	50,31	58,32	70,52
1500m	secondes	262,1	279,0	317,0

Matrice de corrélation



Matrice de corrélation

Trois groupes de corrélations se dégagent :

- **Bloc vitesse–explosivité** : `100m`, `400m`, `110m.hurdle` et `Long.jump`

Matrice de corrélation

Trois groupes de corrélations se dégagent :

- **Bloc vitesse–explosivité** : `100m`, `400m`, `110m.hurdle` et `Long.jump`
- **Bloc force–lancer** : `Shot.put` et `Discus` sont fortement corrélés ($r = 0{,}62$).

Matrice de corrélation

Trois groupes de corrélations se dégagent :

- **Bloc vitesse–explosivité** : `100m`, `400m`, `110m.hurdle` et `Long.jump`
- **Bloc force–lancer** : `Shot.put` et `Discus` sont fortement corrélés ($r = 0{,}62$).
- **Variables indépendantes** : `Pole.vault`, `Javeline` et `1500m`

Choix du nombre de composantes

Le nombre de composantes à retenir est une décision importante qui varie en fonction des situations.
Plusieurs critères existent ; nous en présentons trois.

Choix du nombre de composantes

1 – Règle de Kaiser–Guttman. En ACP normée, la moyenne des valeurs propres de R vaut

$$\bar{\lambda} = \frac{1}{p}\,\mathrm{tr}(\mathrm{R}) = \frac{p}{p} = 1.$$

Ici on a :

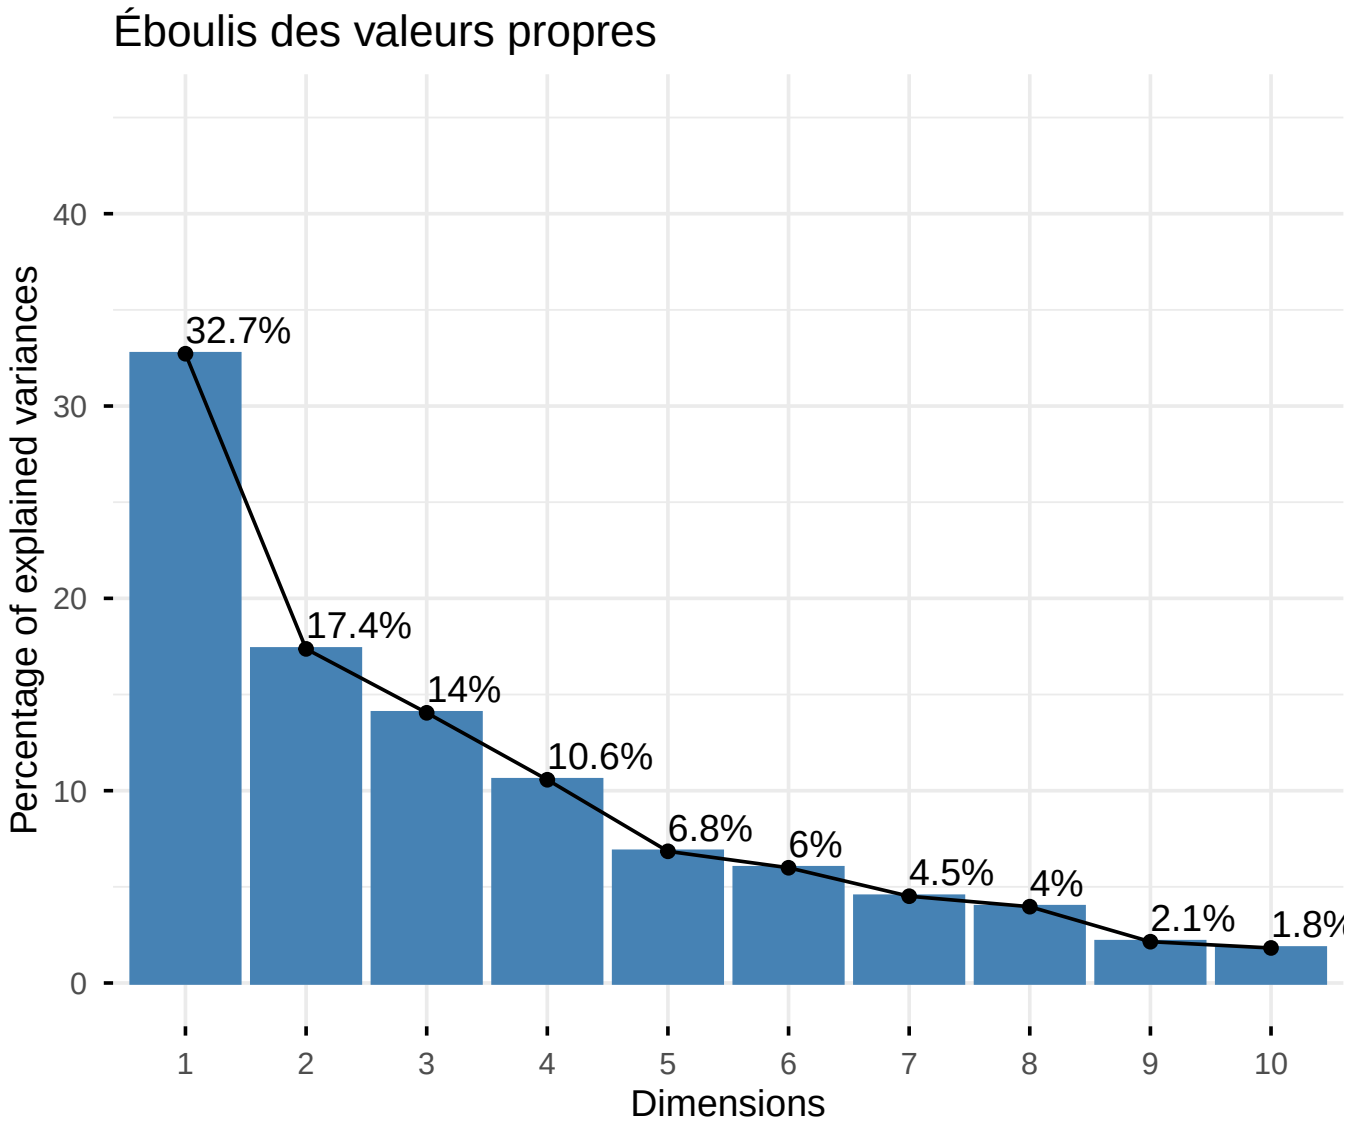
Composante	λ_k	$\lambda_k > 1$?	**Décision**
F_1	3,272	Oui	Retenir
F_2	1,737	Oui	Retenir
F_3	1,405	Oui	Retenir
F_4	1,057	Oui	Retenir
F_5	0,685	Non	Exclure

La règle de Kaiser recommande de retenir **4 composantes**. F_4 passe le seuil de justesse.

Choix du nombre de composantes

2 – Règle du coude (*éboulis des valeurs propres*). On représente les valeurs propres λ_k en fonction de leur rang k. On retient les composantes situées "avant" le coude, au-delà, les valeurs propres apportent moins. Ici (voir schéma juste après) l'éboulis montre une décroissance rapide entre F_1 et F_5, puis une stabilisation à partir de F_5. La rupture de pente est localisée entre F_4 et F_5 : après F_4. La règle du coude désigne donc plutôt **4 composantes**. Mais ça reste discutable au vu du graphique.

Choix du nombre de composantes



Choix du nombre de composantes

3 – Pourcentage d'inertie cumulée. On retient le plus petit q tel que les q premières composantes expliquent une part suffisante de l'inertie totale :

$$\tau_q = \frac{\sum_{k=1}^{q} \lambda_k}{\sum_{k=1}^{p} \lambda_k} \geq \text{seuil}.$$

Ici on retient **4 composantes principales** pour l'analyse principale. F_1, F_2, F_3 et F_4 expliquent à eux deux 74.708% de l'inertie totale comme le montre le tableau ci-après.

Choix du nombre de composantes

	Valeur propre	% de variance	% cumulé
Comp 1	3.272	32.719	32.719
Comp 2	1.737	17.371	50.090
Comp 3	1.405	14.049	64.140
Comp 4	1.057	10.569	74.708

Table – Valeurs propres et variance expliquée

Analyse des variables — cercles des corrélations

- Représentation de nos anciennes variables par rapport à ces nouveaux axes : les loadings.

Un loading mesure la corrélation entre une variable originelle x_j et une composante principale F_k.

Definition (Loading)

Le *loading* de la variable j sur la composante k est la corrélation de Pearson entre la variable centrée-réduite z_j et la composante F_k :

$$\ell_{jk} = r(z_j, F_k) = \sqrt{\lambda_k}\, a_{jk}.$$

Analyse des variables — cercles des corrélations

Definition (Corrélation de Pearson)

La corrélation de Pearson entre deux variables z_j et z_m est

$$r(z_j, z_m) = \frac{\mathrm{Cov}(z_j, z_m)}{\sqrt{\mathrm{Var}(z_j)\ \mathrm{Var}(z_m)}}.$$

C'est un scalaire dans $[-1, 1]$ qui mesure le degré de liaison linéaire entre les deux variables.

Analyse des variables — cercles des corrélations

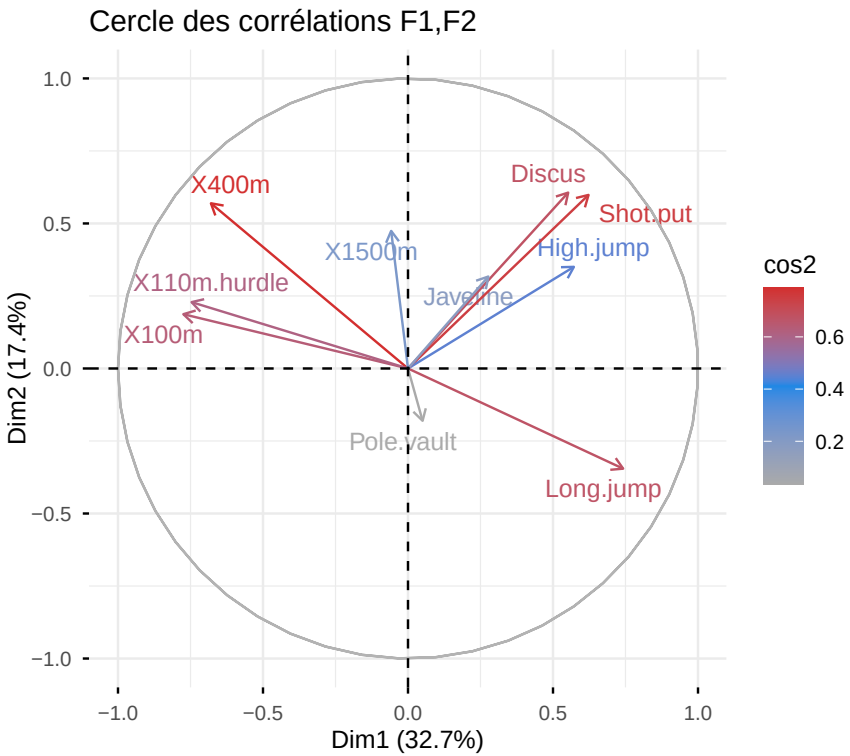
Definition (Cercle des corrélations)

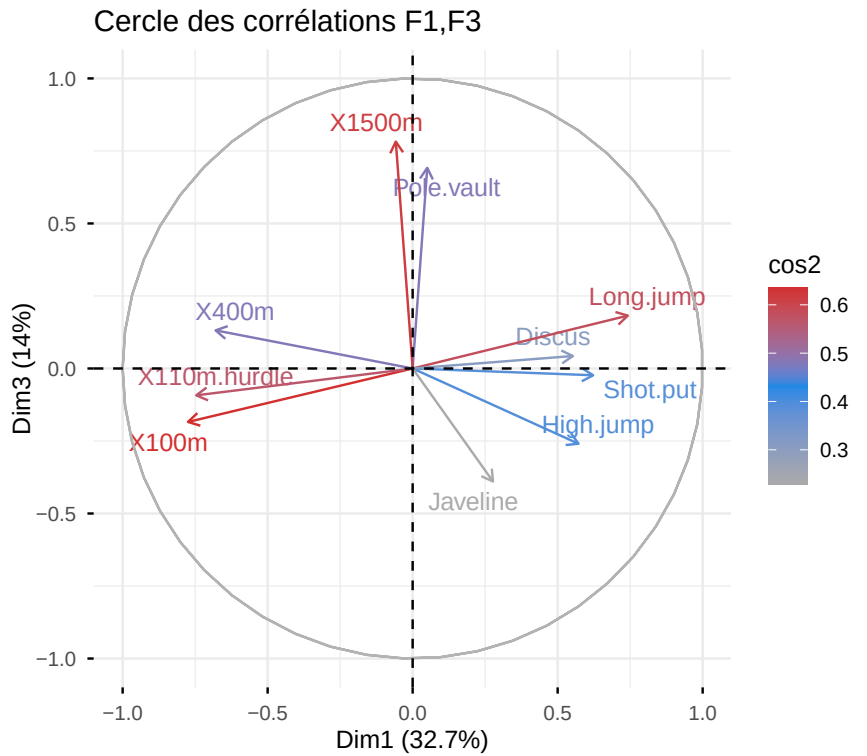
Le cercle des corrélations est la représentation graphique des variables dans le plan des deux premiers facteurs (F_1, F_2). Chaque variable j est représentée par le point de coordonnées

$$(\ell_{j1}, \ell_{j2})$$

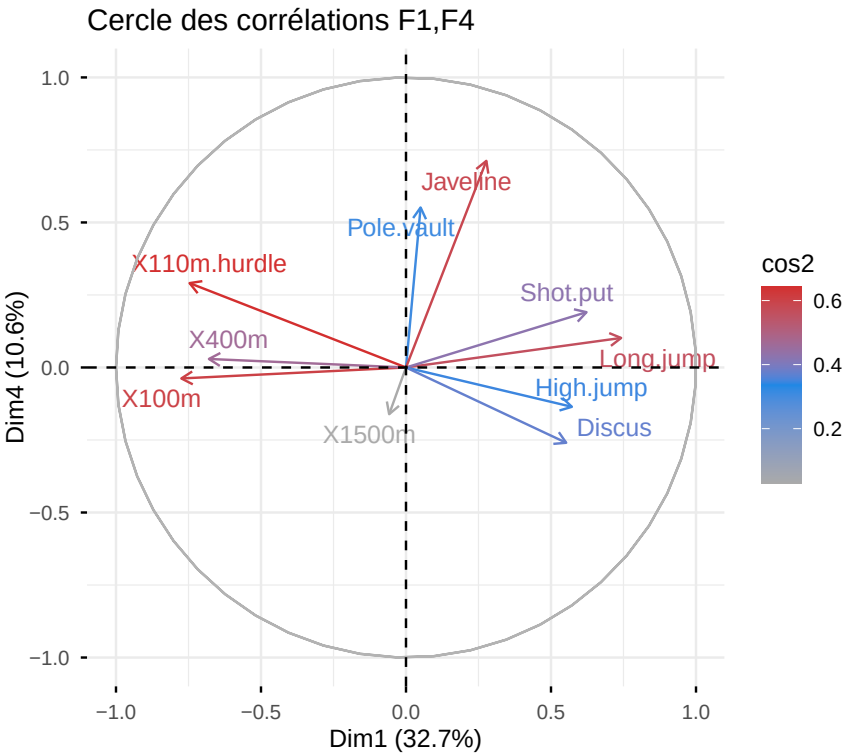
Tous ces points sont à l'intérieur ou sur le cercle unité (puisque $\ell_{j1}^2 + \ell_{j2}^2 \leq \sum_{k=1}^{p} \ell_{jk}^2 = 1$).

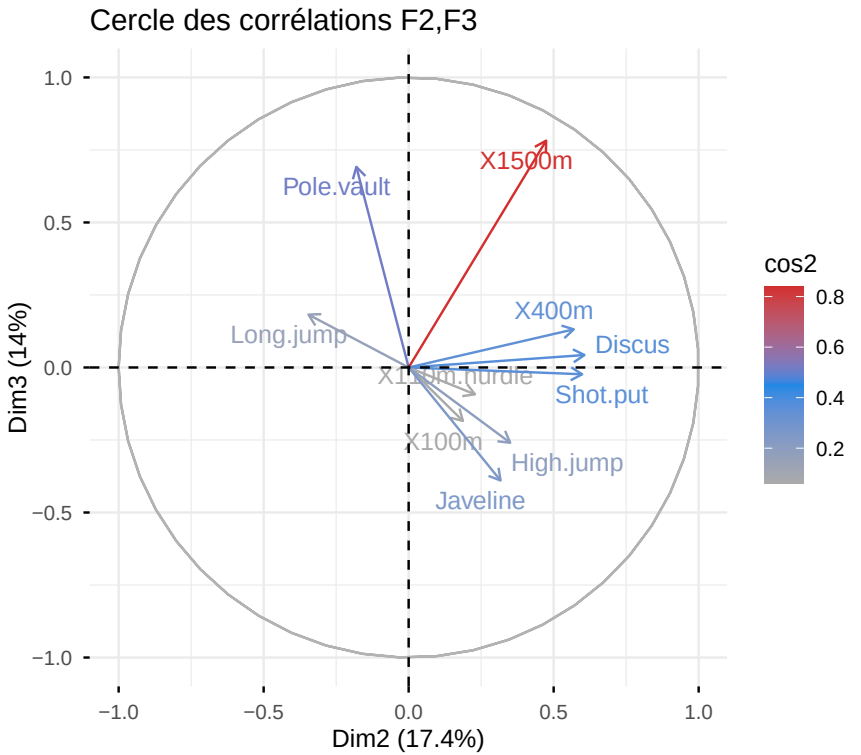
Analyse des variables — cercles des corrélations



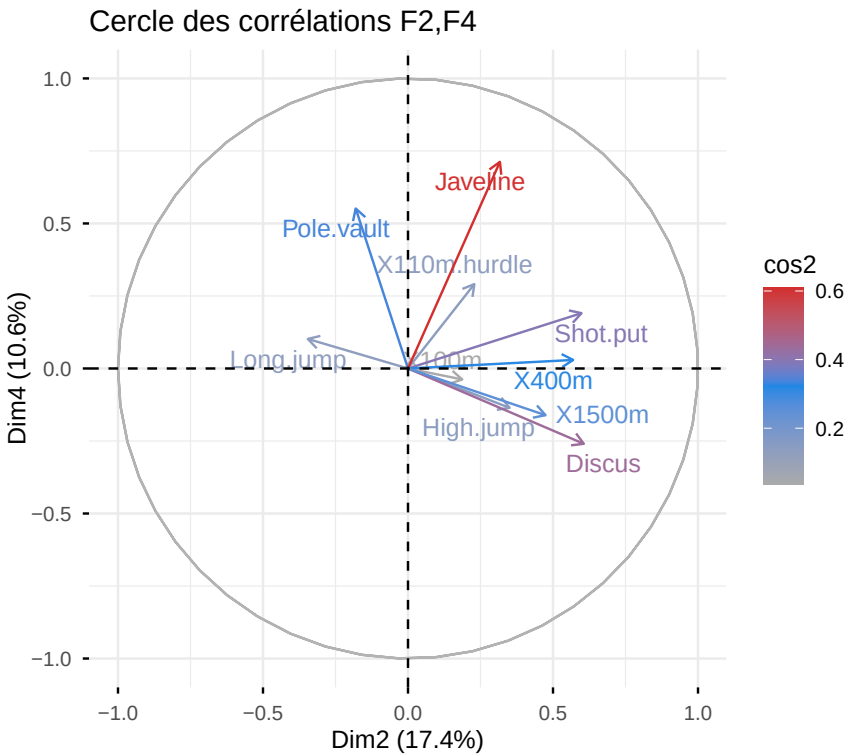


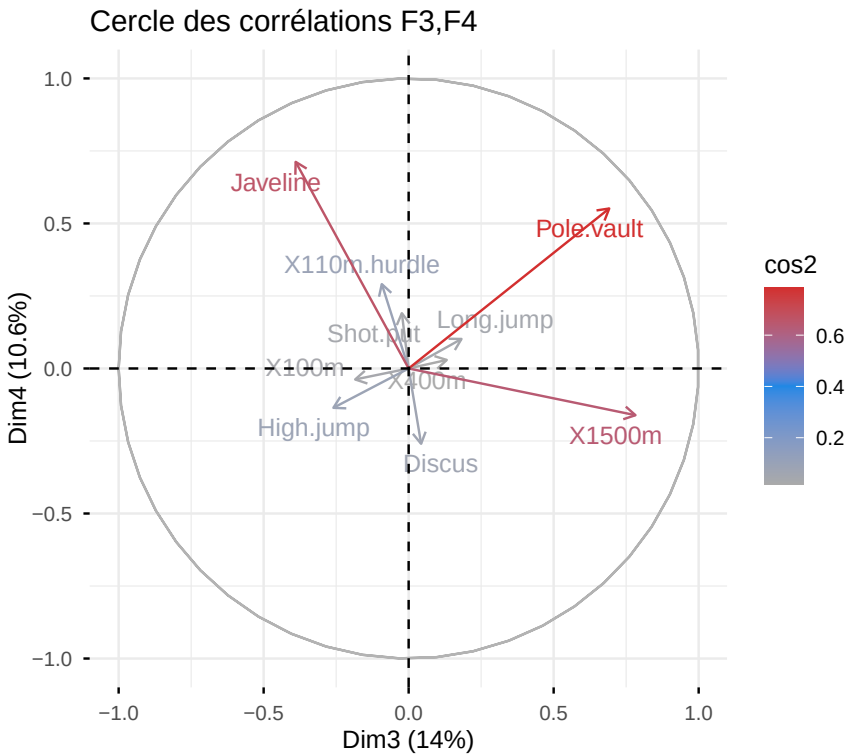
Analyse des variables — cercles des corrélations





Analyse des variables — cercles des corrélations





Analyse des variables — cercles des corrélations

- Variables sont bien représentées sur F1/F2.

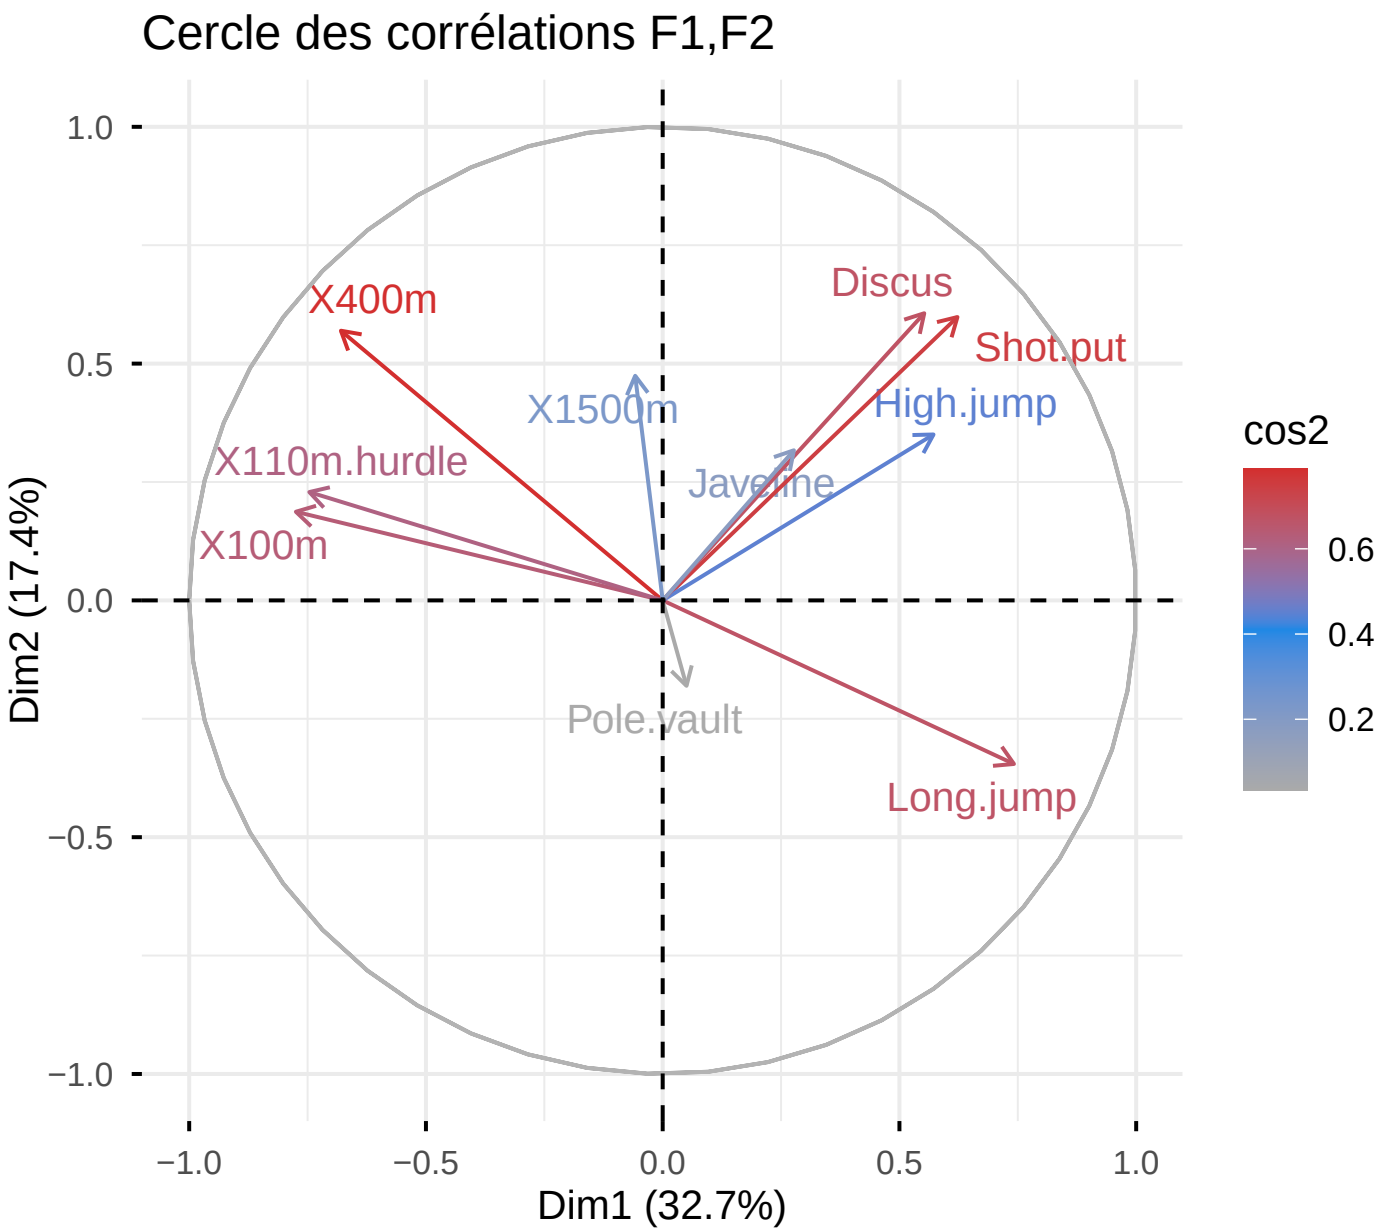
Analyse des variables — cercles des corrélations

- Variables sont bien représentées sur F1/F2.
- X1500m, Javeline moins fiables, mieux représentées sur F3/F4

Analyse des variables — cercles des corrélations

- Variables sont bien représentées sur F1/F2.
- X1500m, Javeline moins fiables, mieux représentées sur F3/F4
- High.jump moyennement représenté partout.

Analyse des variables — cercles des corrélations



Analyse des individus — plan factoriel

- Représentation de nos individus sur nos nouveaux axes. (= Projection)

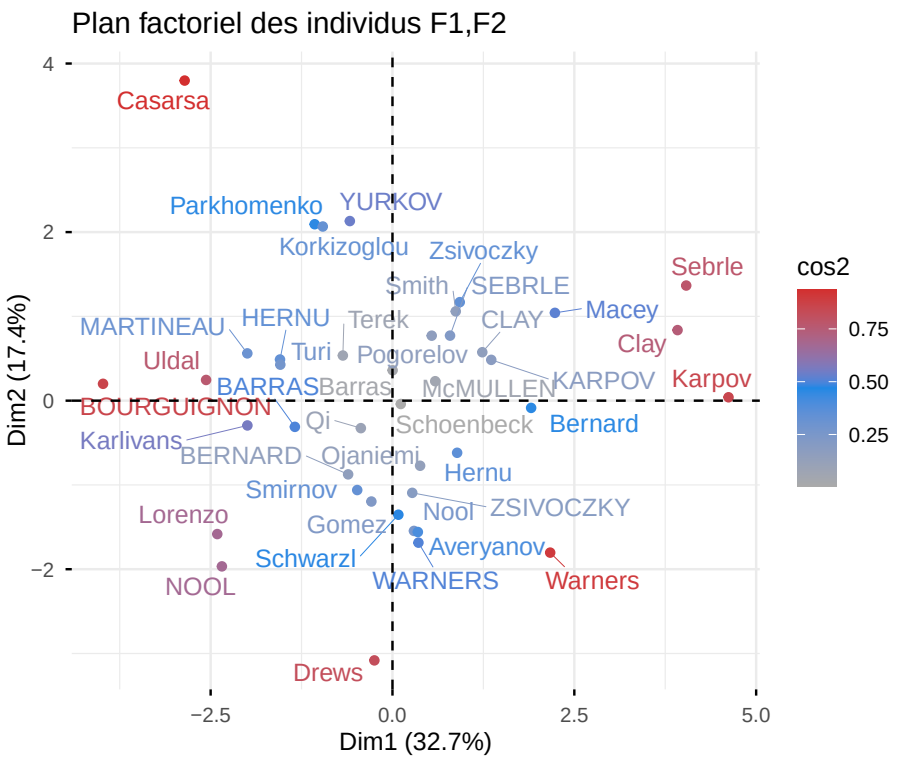
Analyse des individus — plan factoriel

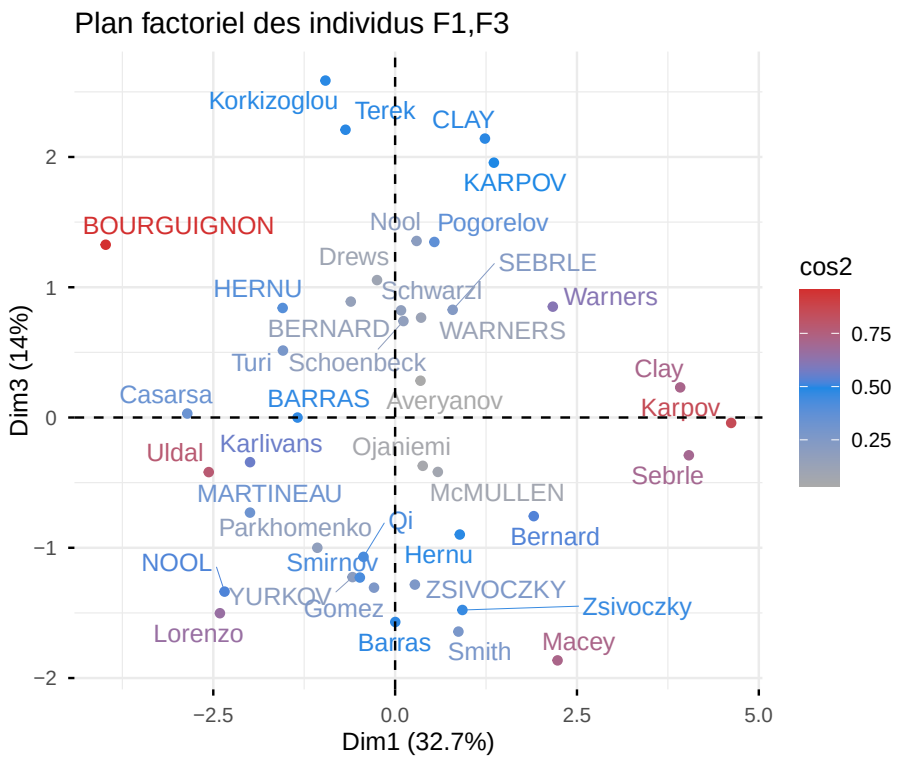
- Représentation de nos individus sur nos nouveaux axes. (= Projection)
- Sont ils bien représentés ? (cos^2)

Analyse des individus — plan factoriel

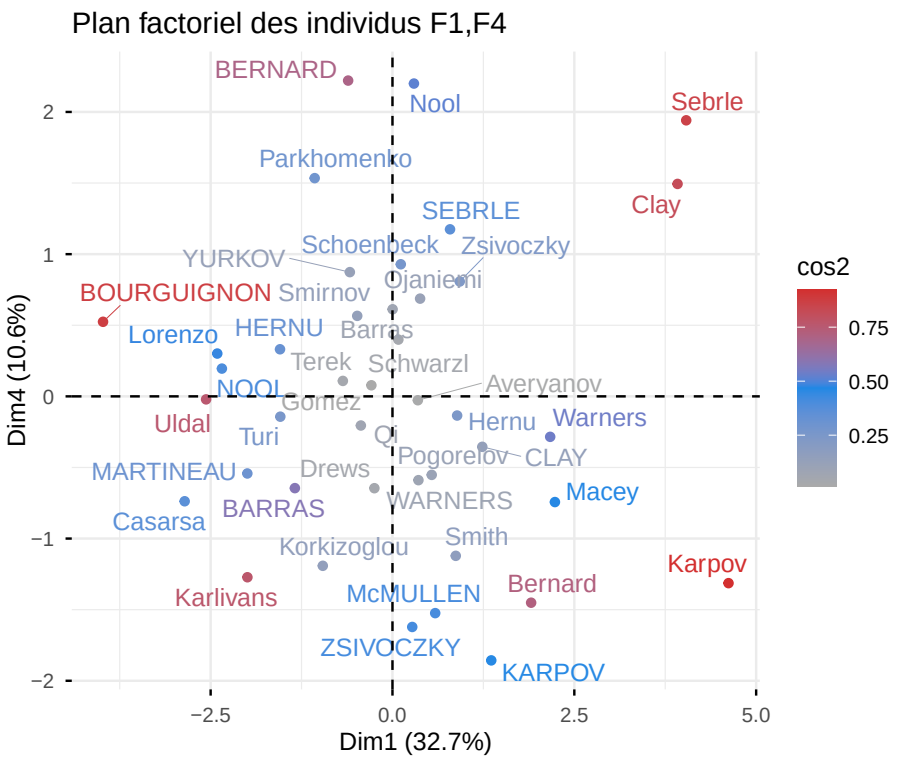
- Représentation de nos individus sur nos nouveaux axes. (= Projection)
- Sont ils bien représentés ? (cos^2)
- Contribution d'un individu à la construction d'un axe.

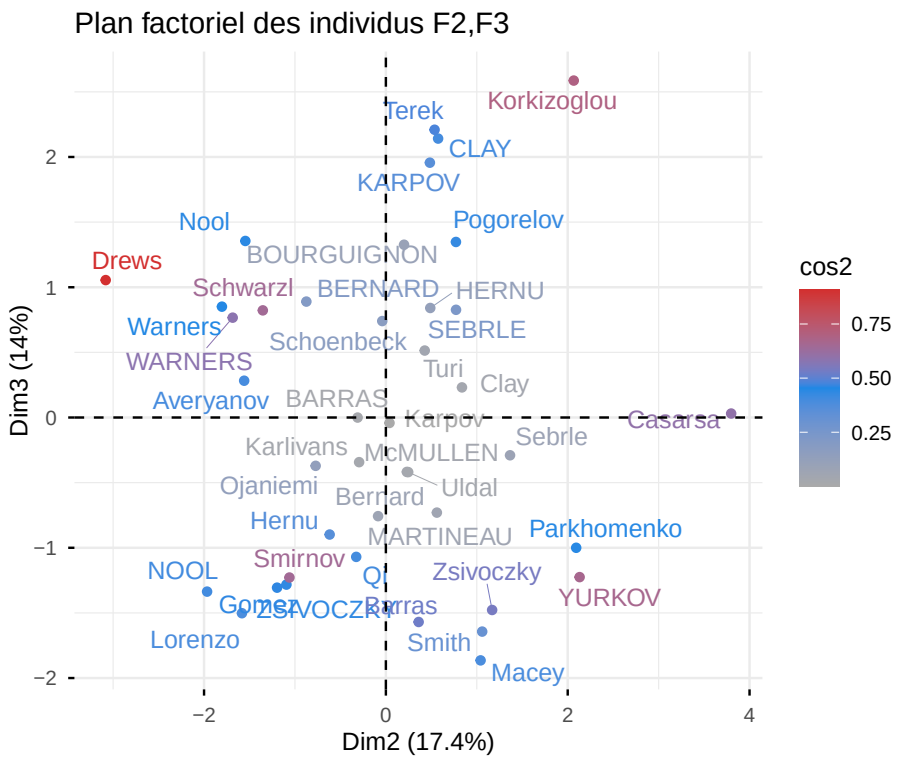
Analyse des individus — plan factoriel



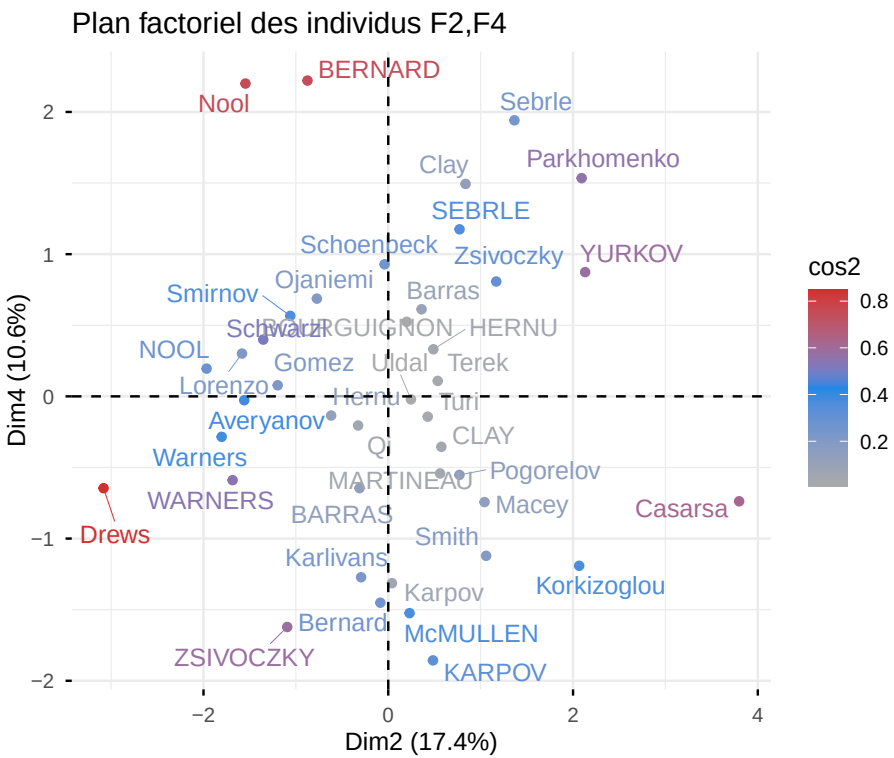


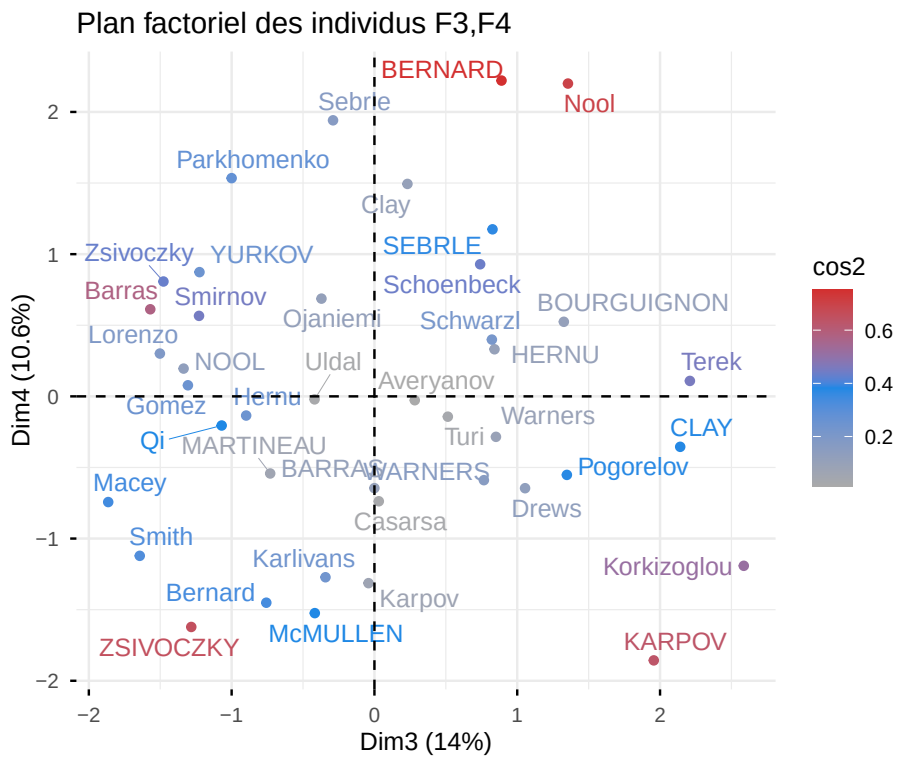
Analyse des individus — plan factoriel





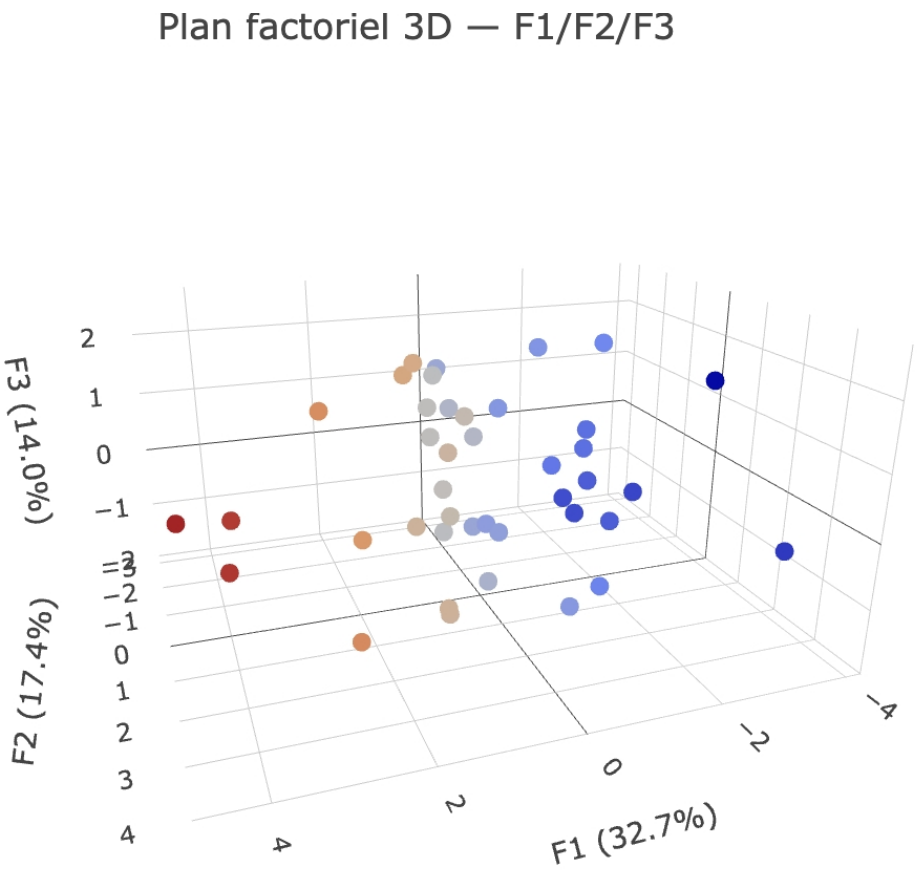
Analyse des individus — plan factoriel





Analyse des individus — plan factoriel

Cette figure est ici figée mais dans Rstudio on peut se déplacer dans l'espace 3D et avoir une bonne appréhension de la représentation de nos individus.



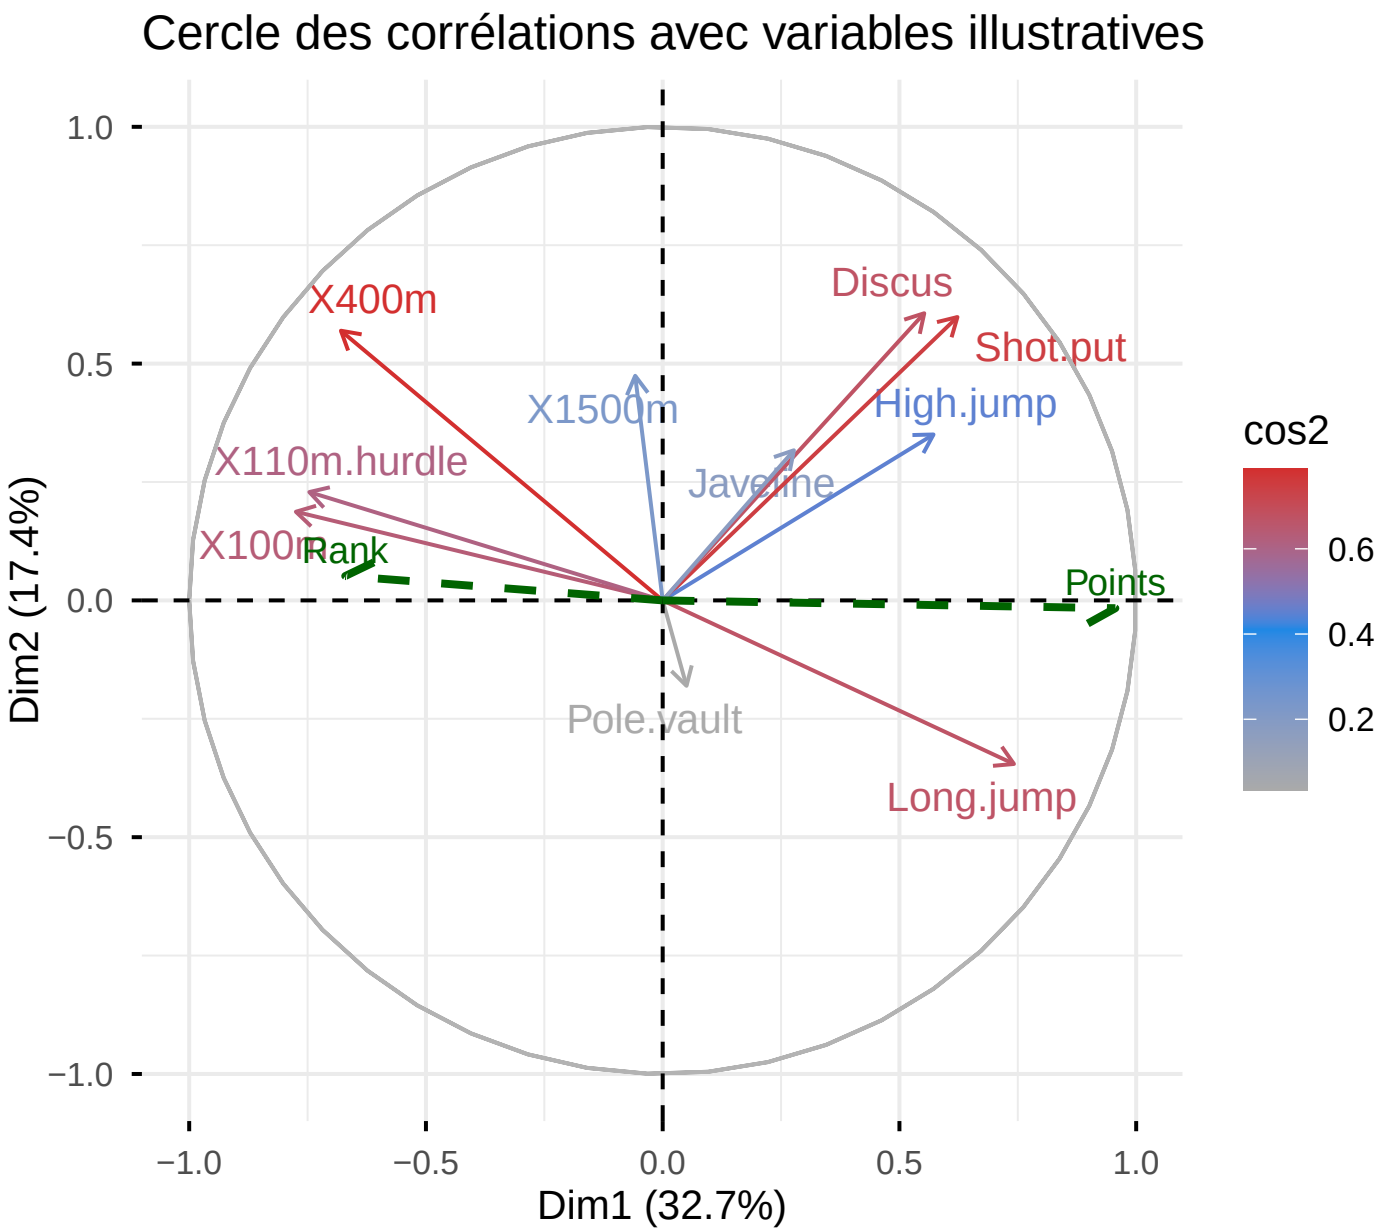
Analyse des individus — plan factoriel

	Dim.1	Dim.2	Dim.3	Dim.4
MARTINEAU	3.0	0.4	0.9	0.7
NOOL	4.1	5.4	3.1	0.1
BOURGUIGNON	11.8	0.1	3.1	0.6
Sebrle	12.2	2.6	0.1	8.7
Clay	11.5	1.0	0.1	5.2
Karpov	15.9	0.0	0.0	4.0
Macey	3.7	1.5	6.0	1.3
Warners	3.5	4.6	1.3	0.2
Bernard	2.7	0.0	1.0	4.9
Lorenzo	4.3	3.5	3.9	0.2
Karlivans	3.0	0.1	0.2	3.7
Uldal	4.9	0.1	0.3	0.0
Casarsa	6.1	20.3	0.0	1.3

Variables illustratives

Les variables illustratives `Rank`, `Points` (quantitatives) et `Competition` (qualitative) n'ont pas participé au calcul des axes. On les projette sur le plan (F_1, F_2) construit précédemment, on observe le lien qu'on peut avoir sans avoir influencé la formation des axes et choix précédents.

Variables illustratives



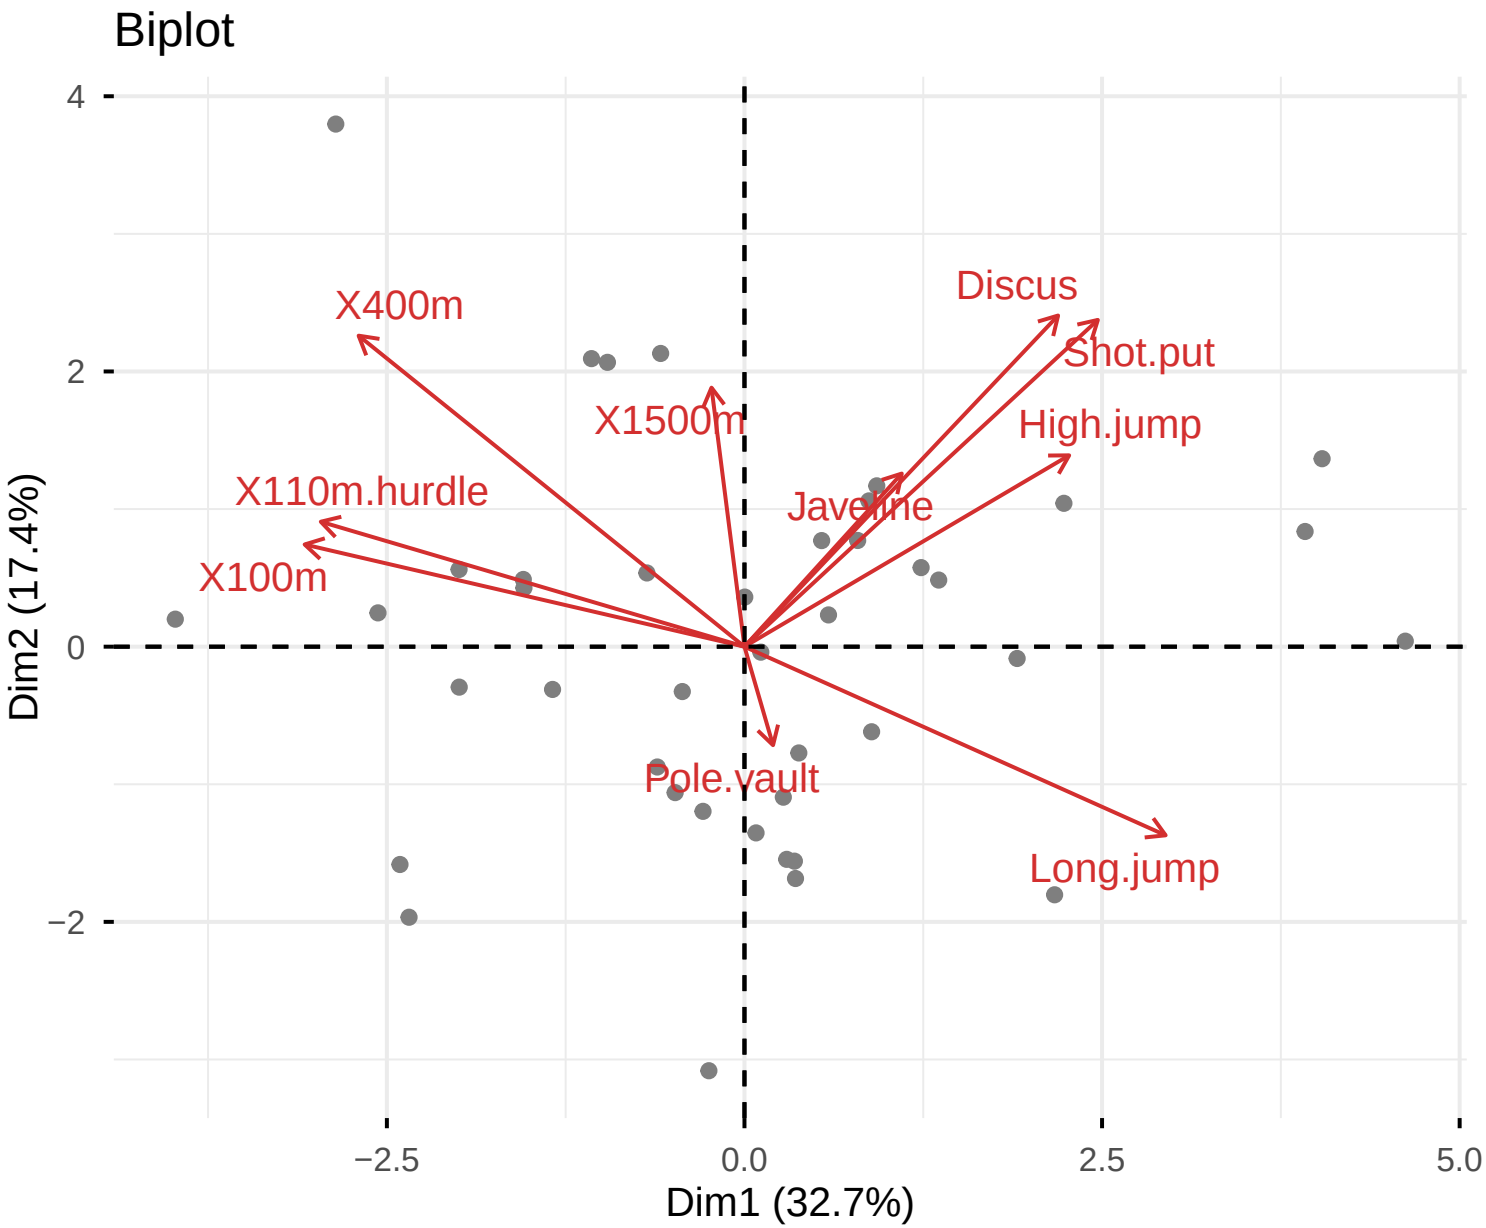
Interprétation

- Le biplot permet de superposer les variables et les positions des individus. C'est la représentation la plus synthétique de l'ACP.

Interprétation

- Le biplot permet de superposer les variables et les positions des individus. C'est la représentation la plus synthétique de l'ACP.
- Un individu placé dans l'axe d'une des variables initiales possède une valeur élevée dans cette discipline.

Interprétation



Conclusion

- Outils mathématiques : matrice de var-covar, la projection et la décomposition spectrale.
- Application conseillée : RStudio pour effectuer l'ACP.
- Distinguer les types de variables et adapter en fonction de nos données.
- Choix du nombre de composantes principales.
- Analyse et visualisation de la qualité de représentation de nos variables.
- Visualisation de nos individus dans un espace plus interprétable.
- Analyse de la qualité de représentation de nos individus.
- Analyse de l'influence des individus quant à la construction de notre espace projectif.
- Interprétation de variables illustratives.

Merci de votre attention

Questions & Discussions

Analyse en Composantes Principales

MAAT Joshua — Université Sorbonne Paris Nord
Sous la direction de Pr. Pham Ngoc