Analyse en Composantes Principales

(ACP)

Mémoire de Master en Science des Données

Sous la direction de Pr. Pham Ngoc

Université Sorbonne Paris Nord

Année universitaire 2025–2026

MAAT Joshua

Remerciements

Je tiens à remercier l'équipe pédagogique du Master de mathématiques en science des données de l'Institut Galilée pour son accompagnement durant cette formation. Je remercie également ma directrice de mémoire Pr. Pham Ngoc pour son accompagnement et son implication. Une mention particulière va à ma famille pour son soutien inconditionnel. Enfin, mes remerciements s'adressent à Ricco RAKOTOMALALA, C. Duby, S. Robin,Pierre-Louis Gonzalez et, Arnak DALALYAN dont les cours sur le sujet ont été les principales ressources pour ce mémoire.

Table des matières

Introduction **1**

1 Rappels de mathématiques **2**

1.1 Nuage de points : centre de gravité et inertie 3

1.2 Matrice de variance-covariance et de corrélation 4

1.3 Projection orthogonale 6

1.4 Décomposition spectrale 7

1.5 Décomposition en valeurs singulières (SVD) 8

1.6 SVD tronquée et théorème d'Eckart–Young 9

2 Analyse en Composantes Principales **10**

2.1 Formulation du problème 11

2.2 Définition des axes principaux 12

2.3 Caractérisation par les vecteurs propres 13

2.4 Choix du nombre de composantes 16

2.5 Formulation via la SVD 17

2.6 Équivalence des trois formulations 17

2.7 Composantes principales 19

2.8 Scores 20

2.9 Loadings (corrélations variables–facteurs) 21

2.10 Cosinus carré — qualité de représentation 23

2.11 Cercle des corrélations 25

3 Application à la main sur un petit exemple **26**

3.1 Présentation du jeu de données 27
3.2 Centrage et réduction 28
3.3 Calcul de la matrice de corrélation 29
3.4 Calcul des valeurs propres 31
3.5 Calcul des vecteurs propres (axes principaux) 32
3.6 Calcul des scores et des loadings 34
3.7 Cosinus carrés et contributions 36
3.8 Représentations graphiques 38

4 Application sur données réelles **40**

4.1 Présentation du jeu de données 41
4.2 Chargement et préparation des données 43
4.3 Exploration préliminaire et matrice de corrélation 45
4.4 Choix du type d'ACP et lancement 48
4.5 Choix du nombre de composantes 51
4.6 Analyse des variables — cercle des corrélations 54
4.7 Analyse des individus — plan factoriel 58
4.8 Variables illustratives 62
4.9 Interprétation 65

Conclusion **67**

Introduction

L'ACP est une méthode descriptive de données. Elle permet d'appréhender la compréhesion de larges jeux de données en graphiques visuels en essayant de conserver au maximum la fiabilité des informations représentées. L'enjeux principal est d'éviter les informations superflues à la compréhension des données qui peuvent être très corrélées. Un point essentiel de l'ACP est également de savoir et de maîtriser notre perte d'information au profit d'une visualisation simplifiée. Nous verrons dans un premier temps dans ce mémoire les outils mathématiques sur lesquels se base l'ACP. Dans un deuxième temps nous verrons en détail la méthode elle même, les informations qu'elle nous fournit et leurs interprétations. Ensuite nous verrons une application pratique sur un petit exemple qui illustrera les mathématiques à la base de l'ACP. Et enfin nous verrons un cas plus général d'utilisation de l'ACP avec sa mise en oeuvre avec les outils informatiques.

Chapitre 1

Rappels de mathématiques

Dans ce chapitre, nous rappelons les notions mathématiques nécessaires à la compréhension de l'ACP. Nous décrivons d'abord comment représenter et mesurer la dispersion des données, puis nous introduisons les outils permettant de réduire leur dimension.

1.1 Nuage de points : centre de gravité et inertie

L'ACP opère sur un ensemble de n individus décrits chacun par p variables. Nous commençons par formaliser ce nuage de points et définir l'inertie, quantité que l'ACP cherchera à préserver au maximum lors de la réduction de dimension.

Soit un tableau de données $\mathbf{X} \in \mathbb{R}^{n \times p}$ (n individus, p variables). On note x_{ij} la valeur de la variable j pour l'individu i.

Le centre de gravité représente le point moyen du nuage.

Définition 1.1.1 (Centre de gravité)**.** *Le centre de gravité $\boldsymbol{g} \in \mathbb{R}^p$ du nuage est le vecteur :*

$$g_j = \bar{x}_j = \frac{1}{n} \sum_{i=1}^{n} x_{ij}, \qquad j = 1, \ldots, p.$$

Définition 1.1.2 (Inertie totale du nuage)**.** *L'inertie I du nuage par rapport à son centre de gravité est*

$$I = \frac{1}{n} \sum_{i=1}^{n} d^2(i, G) = \frac{1}{n} \sum_{i=1}^{n} \|\boldsymbol{x}_i - \boldsymbol{g}\|^2$$

($p_i = 1/n$ avec p_i le poids des vecteurs)

Remarque 1.1.1. *L'inertie mesure la dispersion totale du nuage autour de son centre de gravité. Une bonne représentation en dimension réduite est celle qui en perd le moins.*

Propriété 1.1.1. *L'inertie totale est égale à la somme des variances empiriques des variables :*

$$I = \sum_{j=1}^{p} s_j^2, \qquad s_j^2 = \frac{1}{n} \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2.$$

Pour travailler sur cette dispersion, on étudie la matrice de variance-covariance.

1.2 Matrice de variance-covariance et de corrélation

La dispersion du nuage est entièrement représentée par la matrice de variance-covariance, qui encode la variance de chaque variable et les relations entre elles.

Définition 1.2.1 (Matrice de variance-covariance)**.** *La matrice de variance-covariance empirique de* $\mathbf{X}$ *est*

$$\mathbf{S} = \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{x}_i - \bar{\boldsymbol{x}})(\boldsymbol{x}_i - \bar{\boldsymbol{x}})^\top \in \mathbb{R}^{p\times p}.$$

Dans le cadre de l'ACP, on centre les données, cela simplifie tous les calculs de dispersion. On pose $\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{1}_n\bar{\boldsymbol{x}}^\top$. Alors la matrice de variance-covariance s'écrit simplement :

$$\mathbf{S} = \frac{1}{n}\tilde{\mathbf{X}}^\top\tilde{\mathbf{X}}.$$

Propriété 1.2.1.

(1) $\mathbf{S}$ *est symétrique positive.*

(2) *Sa trace vaut* $\mathrm{tr}(\mathbf{S}) = \sum_{j=1}^{p} s_j^2 = I$ *(inertie totale).*

Lorsque les variables sont de natures ou d'échelles différentes, les variances ne sont pas comparables et une variable peut dominer les autres. On réduit et on travaille sur des données centrées et réduites.

Définition 1.2.2 (Corrélation de Pearson)**.** *La corrélation de Pearson entre deux variables* z_j *et* z_m *est*

$$r(z_j, z_m) = \frac{\mathrm{Cov}(z_j, z_m)}{\sqrt{\mathrm{Var}(z_j)\ \mathrm{Var}(z_m)}}.$$

C'est un scalaire dans $[-1, 1]$ *qui mesure le degré de liaison linéaire entre les deux variables.*

Définition 1.2.3 (Matrice de corrélation de Pearson)**.** *La matrice de corrélation* $\mathbf{R} \in \mathbb{R}^{p\times p}$ *est la matrice dont le terme* (j, m) *est la corrélation de Pearson entre les variables* z_j *et* z_m *:*

$$R_{jm} = r(z_j, z_m) = \frac{\mathrm{Cov}(z_j, z_m)}{\sqrt{\mathrm{Var}(z_j)\ \mathrm{Var}(z_m)}}.$$

En particulier, $R_{jj} = 1$ *pour tout* j*, et* $\mathbf{R}$ *est la matrice de variance-covariance des données centrées-réduites.*

Propriété 1.2.2. $\mathbf{R}$ *est symétrique positive. Sa trace vaut* $\mathrm{tr}(\mathbf{R}) = p$*, ce qui en fait l'inertie totale de l'ACP normée.*

Le choix entre $\mathbf{S}$ et $\mathbf{R}$ dépend des données : si toutes les variables sont dans la même unité et que leurs variances sont comparables, on travaille sur $\mathbf{S}$; sinon on préfère $\mathbf{R}$.

On a maintenant un outil pour mesurer la dispersion du nuage. L'objectif de l'ACP est de réduire la dimension des données tout en conservant cette dispersion au maximum. On introduit alors la projection orthogonale pour réduire la dimension.

1.3 Projection orthogonale

La projection orthogonale consiste à représenter chaque individu par un nombre réduit de coordonnées sur de nouvelles directions. Le choix de ces directions se posera plus tard.

Définition 1.3.1 (Produit scalaire)**.** *Dans $\mathbb{R}^n$, le produit scalaire canonique est défini par*

$$\langle \boldsymbol{u}, \boldsymbol{v} \rangle = \boldsymbol{u}^\top \boldsymbol{v} = \sum_{i=1}^{n} u_i v_i, \qquad \boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n.$$

La norme euclidienne associée est $\|\boldsymbol{u}\| = \sqrt{\langle \boldsymbol{u}, \boldsymbol{u} \rangle}$.

Définition 1.3.2 (Orthogonalité)**.** *Deux vecteurs $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n$ sont dits* orthogonaux*, noté $\boldsymbol{u} \perp \boldsymbol{v}$, si $\langle \boldsymbol{u}, \boldsymbol{v} \rangle = 0$.*

Définition 1.3.3 (Projection orthogonale sur un vecteur)**.** *La projection orthogonale de $\boldsymbol{x} \in \mathbb{R}^p$ sur la direction $\boldsymbol{a} \in \mathbb{R}^p \setminus \{\mathbf{0}\}$ est le vecteur*

$$\hat{\boldsymbol{x}} = \frac{\langle \boldsymbol{x}, \boldsymbol{a} \rangle}{\|\boldsymbol{a}\|^2} \boldsymbol{a}.$$

Si $\|\boldsymbol{a}\| = 1$, on a $\hat{\boldsymbol{x}} = \langle \boldsymbol{x}, \boldsymbol{a} \rangle \, \boldsymbol{a}$, et $\hat{x} = \langle \boldsymbol{x}, \boldsymbol{a} \rangle$ est la coordonnée scalaire (qu'on nommera "score") de $\boldsymbol{x}$ sur $\boldsymbol{a}$.

Version matricielle

En pratique, l'ACP ne projette pas sur une seule direction mais sur un sous-espace de dimension q, engendré par q axes orthogonaux ; la formulation matricielle suivante décrit ce cadre.

Soit $V \subset \mathbb{R}^p$ un sous-espace vectoriel de dimension q, et $\mathbf{Q} \in \mathbb{R}^{p \times q}$ une matrice dont les colonnes forment une base orthonormée de V.

Théorème 1.3.1 (Projecteur orthogonal)**.** *La matrice de projection orthogonale sur V est*

$$\mathbf{P}_V = \mathbf{Q}\mathbf{Q}^\top.$$

la question qui se pose maintenant : sur quelles directions projeter ?

1.4 Décomposition spectrale

Choisir la meilleure direction de projection revient à un problème d'optimisation sur $\mathbf{S}$ (ou $\mathbf{R}$). $\mathbf{S}$ et $\mathbf{R}$ sont symétriques positives, ce qui garantit que leurs valeurs propres sont réelles et positives. La décomposition spectrale exploite ça pour donner la solution.

Définition 1.4.1 (Valeurs propres et vecteurs propres)**.** *Soit* $\mathbf{M} \in \mathbb{R}^{p\times p}$*. Un scalaire* $\lambda \in \mathbb{R}$ *est une* valeur propre *de* $\mathbf{M}$ *s'il existe un vecteur non nul* $\boldsymbol{v} \in \mathbb{R}^n$ *tel que*

$$\mathbf{M}\boldsymbol{v} = \lambda\boldsymbol{v}.$$

$\boldsymbol{v}$ *est appelé* vecteur propre *associé à* λ*.*

Théorème 1.4.1 (Décomposition spectrale)**.** *Toute matrice symétrique réelle* $\mathbf{M} \in \mathbb{R}^{n\times n}$ *est diagonalisable dans une base orthonormée :*

$$\mathbf{M} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top,$$

où $\mathbf{U} \in \mathbb{R}^{n\times n}$ *est une matrice orthogonale dont les colonnes* $(\boldsymbol{u}_1, \ldots, \boldsymbol{u}_n)$ *forment une base orthonormée de* $\mathbb{R}^n$*, et* $\mathbf{\Lambda} = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$*.*

Et avec les valeurs propres ordonnées : $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$*.*

Remarque 1.4.1. *Pour conserver un maximum de dispersion lors de la réduction de dimension, on cherchera à privilégier les directions associées aux plus grandes valeurs propres, qui correspondent aux directions d'étirement maximal de* $\mathbf{M}$*.*

La décomposition spectrale s'applique aux matrices carrées symétriques, et est suffisante pour faire de l'ACP. En pratique, pour les raisons vues ci-après, c'est la SVD qui est utilisée.

1.5 Décomposition en valeurs singulières (SVD)

La décomposition spectrale permet en théorie de résoudre le problème de l'ACP en diagonalisant $\mathbf{Z}^\top \mathbf{Z}$, proportionnelle à la matrice de variance-covariance. Cependant, travailler directement sur la matrice de données $\mathbf{Z} \in \mathbb{R}^{n \times p}$, qui est rectangulaire dès que $n \neq p$, est numériquement préférable. La SVD généralise cette décomposition aux matrices rectangulaires et sera l'outil privilégié pour calculer les axes de l'ACP.

Théorème 1.5.1 (SVD)**.** *Toute matrice $\mathbf{Z} \in \mathbb{R}^{n \times p}$ $(n \geq p)$ admet la décomposition*

$$\mathbf{Z} = \mathbf{U} \boldsymbol{\Delta} \mathbf{V}^\top,$$

où

- $\mathbf{U} \in \mathbb{R}^{n \times n}$ *est orthogonale* $(\mathbf{U}^\top \mathbf{U} = \mathbf{I}_n)$,
- $\mathbf{V} \in \mathbb{R}^{p \times p}$ *est orthogonale* $(\mathbf{V}^\top \mathbf{V} = \mathbf{I}_p)$,
- $\boldsymbol{\Delta} \in \mathbb{R}^{n \times p}$ *est pseudo-diagonale :* $\Delta_{kk} = \delta_k \geq 0$ *avec* $\delta_1 \geq \cdots \geq \delta_p \geq 0$, *et* $\Delta_{ij} = 0$ *pour* $i \neq j$.

Les δ_k sont les valeurs singulières *de* $\mathbf{A}$.

Remarque 1.5.1. *Les matrices $\mathbf{U}$ et $\mathbf{V}$ ne sont pas arbitraires : leurs colonnes sont les vecteurs propres orthonormés de $\mathbf{Z}\mathbf{Z}^\top$ et $\mathbf{Z}^\top \mathbf{Z}$ respectivement.*

Remarque 1.5.2. *On pourrait se demander s'il suffit de travailler avec $\mathbf{Z}^\top \mathbf{Z}$, proportionnelle à la matrice de variance-covariance, qui est carrée, symétrique et donc diagonalisable par le théorème 1.4.1. Les axes obtenus seraient effectivement les mêmes. Cependant, la SVD est préférée en pratique : les algorithmes modernes travaillent directement sur $\mathbf{Z}$ sans jamais former $\mathbf{Z}^\top \mathbf{Z}$ explicitement, ce qui évite des erreurs d'arrondi et rend le calcul plus rapide.*

La SVD décompose $\mathbf{Z}$ sans perte d'information. On va chercher alors une approximation de rang réduit $q \ll p$ qui conserve l'essentiel des données.

1.6 SVD tronquée et théorème d'Eckart–Young

Le théorème d'Eckart-Young garantit que conserver les q premières valeurs singulières est optimal : parmi toutes les matrices de rang q possibles, c'est cette approximation qui est la plus proche de $\mathbf{Z}$, au sens de la norme de Frobenius $\|\mathbf{Z}\|_F = \sqrt{\sum_{i,j} z_{ij}^2}$, qui généralise la norme euclidienne aux matrices. Le choix de q reste une décision de l'analyste, abordée au chapitre suivant.

Définition 1.6.1 (SVD tronquée)**.** *Pour $q \leq \operatorname{rang}(\mathbf{Z})$, l'approximation de rang q de $\mathbf{Z}$ est*

$$\mathbf{Z}_q = \mathbf{U}_q \boldsymbol{\Delta}_q \mathbf{V}_q^\top = \sum_{k=1}^{q} \delta_k \, \boldsymbol{u}_k \boldsymbol{v}_k^\top,$$

où $\mathbf{U}_q$ et $\mathbf{V}_q$ contiennent les q premières colonnes de $\mathbf{U}$ et $\mathbf{V}$ respectivement, et $\boldsymbol{\Delta}_q = \operatorname{diag}(\delta_1, \ldots, \delta_q)$.

Théorème 1.6.1 (Eckart–Young, 1936)**.** *Parmi toutes les matrices de rang au plus q, $\mathbf{Z}_q$ minimise la distance de Frobenius :*

$$\|\mathbf{Z} - \mathbf{Z}_q\|_F = \min_{\operatorname{rang}(\mathbf{B}) \leq q} \|\mathbf{Z} - \mathbf{B}\|_F = \sqrt{\sum_{k=q+1}^{p} \delta_k^2},$$

où $\|\mathbf{Z}\|_F = \sqrt{\operatorname{tr}(\mathbf{Z}^\top \mathbf{Z})}$ désigne la norme de Frobenius.

Nous disposons désormais de tous les outils nécessaires. Une mesure de la dispersion des données ($\mathbf{S}$ ou $\mathbf{R}$). Un outil pour projeter les individus sur de nouvelles directions, et un résultat d'optimalité pour que la troncature SVD soit bien la meilleure approximation possible. Le chapitre suivant utilise ces éléments pour construire formellement l'ACP.

Chapitre 2

Analyse en Composantes Principales

Les outils introduits au chapitre précédent : mesure de la dispersion, projection orthogonale, décomposition spectrale et SVD, sont maintenant réunis pour construire formellement l'ACP. Ce chapitre en présente la formulation mathématique, la caractérisation des axes principaux et leur calcul, ainsi que les critères permettant de choisir le nombre de composantes à retenir.

2.1 Formulation du problème

L'ACP cherche à représenter un nuage de n individus dans $\mathbb{R}^p$ en un nuage dans $\mathbb{R}^q$, avec $q \ll p$, tout en conservant au mieux la dispersion des données. On fixe $q \in \{1, \dots, p-1\}$ et on note $\mathbf{Z} \in \mathbb{R}^{n \times p}$ la matrice des données centrées (et réduites si l'on travaille sur $\mathbf{R}$) ; $\mathbf{S}$ (resp. $\mathbf{R}$) désigne la matrice de variance-covariance (resp. de corrélation) introduite au chapitre 1.

La question « quelle est la *meilleure* représentation en dimension q ? » admet trois formulations équivalentes, chacune éclairant un aspect différent du problème.

(F1) Maximisation séquentielle de la variance. Trouver q directions orthonormées $\boldsymbol{a}_1, \dots, \boldsymbol{a}_q \in \mathbb{R}^p$: chaque $\boldsymbol{a}_k$ maximise la variance des scores de projection $\boldsymbol{a}^\top \mathbf{S}\, \boldsymbol{a}$ sous la contrainte d'être unitaire et orthogonal aux $k-1$ directions déjà choisies.

(F2) Minimisation globale des résidus. Trouver le sous-espace $V \subset \mathbb{R}^p$ de dimension q qui minimise la somme des carrés des distances entre les individus et leurs projections orthogonales sur V :

$$\min_{\substack{V \subset \mathbb{R}^p \\ \dim V = q}} \frac{1}{n} \sum_{i=1}^{n} \left\| \boldsymbol{z}_i - \mathbf{P}_V \boldsymbol{z}_i \right\|^2 .$$

(F3) Meilleure approximation de rang q (Eckart–Young). Trouver la matrice $\mathbf{B} \in \mathbb{R}^{n \times p}$ de rang au plus q minimisant la distance de Frobenius :

$$\min_{\operatorname{rang}(\mathbf{B}) \le q} \|\mathbf{Z} - \mathbf{B}\|_F .$$

La solution optimale est la SVD tronquée à q termes (théorème 1.6.1).

Dans la suite de ce chapitre, nous développons la formulation **(F1)**, qui conduit à un problème d'optimisation sous contrainte sur $\mathbf{S}$ et se résout par sa diagonalisation.

2.2 Définition des axes principaux

On développe ici la formulation **(F1)** introduite à la section précédente. On travaille sur la matrice $\mathbf{Z} \in \mathbb{R}^{n \times p}$ des données centrées (et réduites en ACP normée), et sur la matrice de variance-covariance $\mathbf{S}$ (resp. de corrélation $\mathbf{R}$) associée. On note $\mathbf{M}$ cette matrice, avec $\mathbf{M} = \mathbf{S}$ ou $\mathbf{M} = \mathbf{R}$ selon le contexte.

Motivation

Projeter les individus sur une direction unitaire $\boldsymbol{a} \in \mathbb{R}^p$ produit des scores $\boldsymbol{a}^\top \boldsymbol{z}_i \in \mathbb{R}$. Si ces scores ont une grande variance, alors les individus sont bien *séparés* sur cet axe, on conserve de l'information. Une variance faible signifie que la projection écrase les différences entre individus, on perd de l'information. L'ACP cherche donc les directions qui maximisent cette variance.

Définition 2.2.1 (Premier axe principal)**.** *Le* premier axe principal *est la solution du problème*

$$\boldsymbol{a}_1 = \underset{\boldsymbol{a} \in \mathbb{S}^{p-1}}{\arg\max}\, \boldsymbol{a}^\top \mathbf{M}\, \boldsymbol{a}, \qquad \mathbb{S}^{p-1} = \{\boldsymbol{a} \in \mathbb{R}^p \mid \|\boldsymbol{a}\| = 1\}.$$

Définition 2.2.2 (k-ième axe principal)**.** *Pour $k \geq 2$, le* k-ième axe principal *est défini par récurrence comme la solution de*

$$\boldsymbol{a}_k = \underset{\boldsymbol{a} \in \mathbb{S}^{p-1},\, \boldsymbol{a} \perp \boldsymbol{a}_\ell,\, \ell=1,\ldots,k-1}{\arg\max}\, \boldsymbol{a}^\top \mathbf{M}\, \boldsymbol{a}.$$

La contrainte $\boldsymbol{a} \perp \boldsymbol{a}_\ell$ assure que chaque axe apporte une part de variance non capturée par les axes précédents.

2.3 Caractérisation par les vecteurs propres

Nous montrons ici que les axes principaux sont les vecteurs propres de $\mathbf{M}$, et les valeurs propres associées mesurent la variance conservée par chaque axe.

Théorème 2.3.1 (Axes principaux et valeurs propres)**.** *Soient $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$ les valeurs propres de $\mathbf{M}$, et $\boldsymbol{u}_1, \ldots, \boldsymbol{u}_p$ les vecteurs propres orthonormés associés (Existence par le théorème 1.4.1). Alors :*

(i) *Le k-ième axe principal est $\boldsymbol{a}_k = \boldsymbol{u}_k$.*

(ii) *La variance maximale atteinte sur le k-ième axe vaut $\boldsymbol{a}_k^\top \mathbf{M}\, \boldsymbol{a}_k = \lambda_k$.*

(iii) *L'inertie expliquée par les q premiers axes est $I_q = \sum_{k=1}^{q} \lambda_k$, et le taux d'inertie expliquée est*

$$\tau_q = \frac{\sum_{k=1}^{q} \lambda_k}{\sum_{k=1}^{p} \lambda_k} = \frac{\sum_{k=1}^{q} \lambda_k}{\operatorname{tr}(\mathbf{M})}.$$

Démonstration. Nous établissons le résultat pour le premier axe ; le cas général se déduit par récurrence à l'aide du théorème spectral 1.4.1.

Étape 1 — Lagrangien. On cherche à maximiser $f(\boldsymbol{a}) = \boldsymbol{a}^\top \mathbf{M} \boldsymbol{a}$ sous la contrainte $\|\boldsymbol{a}\|^2 = 1$. Le Lagrangien associé est

$$\mathcal{L}(\boldsymbol{a}, \lambda) = \boldsymbol{a}^\top \mathbf{M} \boldsymbol{a} - \lambda\big(\|\boldsymbol{a}\|^2 - 1\big).$$

Étape 2 — Condition du premier ordre. En différenciant par rapport à $\boldsymbol{a}$ et en égalisant à zéro :

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{a}} = 2\mathbf{M}\boldsymbol{a} - 2\lambda \boldsymbol{a} = \mathbf{0} \implies \mathbf{M}\boldsymbol{a} = \lambda \boldsymbol{a}.$$

Étape 3 — Interprétation du multiplicateur. Si $\mathbf{M}\boldsymbol{a} = \lambda \boldsymbol{a}$ et $\|\boldsymbol{a}\| = 1$, alors

$$f(\boldsymbol{a}) = \boldsymbol{a}^\top \mathbf{M} \boldsymbol{a} = \boldsymbol{a}^\top (\lambda \boldsymbol{a}) = \lambda \|\boldsymbol{a}\|^2 = \lambda.$$

Maximiser f revient donc à choisir la plus grande valeur propre.

Étape 4 — Choix de la valeur propre. Parmi $\lambda_1 \geq \cdots \geq \lambda_p \geq 0$, la variance est maximisée par λ_1. Le premier axe principal est $\boldsymbol{a}_1 = \boldsymbol{u}_1$, et la variance maximale vaut λ_1.

Étape 5 — Axes suivants. Pour le k-ième axe, on introduit $k-1$ multiplicateurs supplémentaires $\mu_1, \ldots, \mu_{k-1}$ associés aux contraintes $\boldsymbol{a}^\top \boldsymbol{u}_\ell = 0$, $\ell = 1, \ldots, k-1$. Le

Lagrangien devient

$$\mathcal{L}(\boldsymbol{a}, \lambda, \mu_1, \ldots, \mu_{k-1}) = \boldsymbol{a}^\top \mathbf{M} \boldsymbol{a} - \lambda\big(\|\boldsymbol{a}\|^2 - 1\big) - \sum_{\ell=1}^{k-1} \mu_\ell \, \boldsymbol{a}^\top \boldsymbol{u}_\ell.$$

La condition du premier ordre donne

$$2\mathbf{M}\boldsymbol{a} - 2\lambda \boldsymbol{a} - \sum_{\ell=1}^{k-1} \mu_\ell \, \boldsymbol{u}_\ell = \mathbf{0}.$$

On multiplie à gauche par $\boldsymbol{u}_\ell^\top$ et on exploite $\mathbf{M}\boldsymbol{u}_\ell = \lambda_\ell \boldsymbol{u}_\ell$ et la contrainte $\boldsymbol{u}_\ell^\top \boldsymbol{a} = 0$:

$$2 \underbrace{\boldsymbol{u}_\ell^\top \mathbf{M} \boldsymbol{a}}_{= \lambda_\ell \underbrace{\boldsymbol{u}_\ell^\top \boldsymbol{a}}_{=0} = 0} - 2\lambda \underbrace{\boldsymbol{u}_\ell^\top \boldsymbol{a}}_{=0} - \mu_\ell \underbrace{\boldsymbol{u}_\ell^\top \boldsymbol{u}_\ell}_{=1} = 0 \implies \mu_\ell = 0.$$

La condition se réduit donc à $\mathbf{M}\boldsymbol{a}_k = \lambda_k \boldsymbol{a}_k$, soit $\boldsymbol{a}_k = \boldsymbol{u}_k$. L'orthogonalité $\boldsymbol{u}_k \perp \boldsymbol{u}_\ell$ pour $k \neq \ell$ est garantie par le théorème spectral 1.4.1, puisque $\mathbf{M}$ est symétrique.

Étape 6 — Inertie expliquée (point (iii)). Par le théorème de König–Huygens, l'inertie totale se décompose en inertie projetée et inertie résiduelle.

Propriété 2.3.1 (Décomposition orthogonale de l'inertie)**.** *Pour tout individu $\boldsymbol{z}_i$ et tout sous-espace V, la projection orthogonale vérifie*

$$\|\boldsymbol{z}_i\|^2 = \|\mathbf{P}_V \boldsymbol{z}_i\|^2 + \|\boldsymbol{z}_i - \mathbf{P}_V \boldsymbol{z}_i\|^2,$$

les deux termes étant orthogonaux. En sommant sur les n individus, l'inertie totale se décompose en inertie projetée et inertie résiduelle :

$$I = I_{projetée} + I_{résiduelle}.$$

Chaque axe $\boldsymbol{u}_k$ capte une variance λ_k, et les axes étant orthogonaux, les contributions s'additionnent :

$$I_q = \sum_{k=1}^{q} \lambda_k.$$

L'inertie totale vaut $I = \operatorname{tr}(\mathbf{M}) = \sum_{k=1}^{p} \lambda_k$. Le taux d'inertie expliquée par les q premiers axes est donc

$$\tau_q = \frac{I_q}{I} = \frac{\sum_{k=1}^{q} \lambda_k}{\sum_{k=1}^{p} \lambda_k}.$$

□

Puisque I est fixe, maximiser I_q (formulation **(F1)**) est équivalent à minimiser $I_{\text{résiduelle}} =$

$\frac{1}{n}\sum_{i=1}^{n}\|\boldsymbol{z}_i - \mathbf{P}_V \boldsymbol{z}_i\|^2$, ce qui établit l'équivalence avec la formulation **(F2)**.

Remarque 2.3.1. *En ACP non normée (*$\mathbf{M} = \mathbf{S}$*), l'inertie totale est* $\mathrm{tr}(\mathbf{S}) = \sum_{j=1}^{p} s_j^2$. *En ACP normée (*$\mathbf{M} = \mathbf{R}$*), l'inertie totale est* $\mathrm{tr}(\mathbf{R}) = p$, *et le taux d'inertie expliquée par la k-ième composante se lit directement comme* λ_k/p.

2.4 Choix du nombre de composantes

Le nombre q de composantes à retenir est une décision importante qui varie en fonction des situations. Plusieurs critères existent ; nous en présentons ici trois.

(1) Règle de Kaiser–Guttman. En ACP normée, la moyenne des valeurs propres de $\mathbf{R}$ vaut

$$\bar{\lambda} = \frac{1}{p}\,\mathrm{tr}(\mathbf{R}) = \frac{p}{p} = 1.$$

Une composante qui capte moins de variance que la moyenne des variables originelles n'apporte pas d'information utile. La règle de Kaiser–Guttman recommande donc de retenir les composantes dont la valeur propre dépasse cette moyenne :

$$\lambda_k > 1.$$

Limite : Tend à retenir trop de composantes lorsque p est grand.

(2) Règle du coude (*éboulis des valeurs propres*). On représente les valeurs propres λ_k en fonction de leur rang k. La courbe décroît rapidement puis se stabilise ; on retient les composantes situées "avant" le coude, au-delà duquel les valeurs propres n'apportent plus grand chose.

Limite : la localisation du coude est subjective et ambiguë si la décroissance est régulière et pas de rupture nette.

(3) Pourcentage d'inertie cumulée. On retient le plus petit q tel que les q premières composantes expliquent une part suffisante de l'inertie totale :

$$\tau_q = \frac{\sum_{k=1}^{q} \lambda_k}{\sum_{k=1}^{p} \lambda_k} \geq \text{seuil}.$$

Le seuil retenu dépend du domaine applicatif : on vise typiquement 80 % en sciences humaines et sociales, et 90 % ou davantage en sciences exactes.

Limite : le seuil est conventionnel et dépend du domaine.

Remarque 2.4.1. *Ces trois critères peuvent conduire à des valeurs de q différentes.*

2.5 Formulation via la SVD

Le théorème 2.3.1 a caractérisé les axes principaux comme les vecteurs propres de $\mathbf{M}$, obtenus par la méthode des multiplicateurs de Lagrange. On montre qu'on peut obtenir ces mêmes axes à partir de la SVD de $\mathbf{Z}$, sans construire ni diagonaliser $\mathbf{M}$.

On considère la SVD de $\mathbf{Z}$:

$$\mathbf{Z} = \mathbf{U}\mathbf{\Delta}\mathbf{V}^\top,$$

où $\mathbf{U} \in \mathbb{R}^{n\times n}$ est orthogonale, $\mathbf{V} \in \mathbb{R}^{p\times p}$ est orthogonale, et $\mathbf{\Delta} \in \mathbb{R}^{n\times p}$ est pseudo-diagonale avec $\delta_1 \geq \cdots \geq \delta_p \geq 0$ sur la diagonale.

Proposition 2.5.1 (ACP via SVD)**.**

(1) *Les axes principaux de l'ACP sont les colonnes de* $\mathbf{V}$ *:*

$$\boldsymbol{a}_k = \boldsymbol{v}_k, \qquad k = 1, \ldots, p.$$

(2) *Les valeurs propres de* $\mathbf{M}$ *s'expriment en fonction des valeurs singulières de* $\mathbf{Z}$ *:*

$$\lambda_k = \frac{\delta_k^2}{n}.$$

Démonstration. On remplace Z par sa SVD dans $\mathbf{M} = \frac{1}{n}\mathbf{Z}^\top\mathbf{Z}$:

$$\mathbf{M} = \frac{1}{n}\mathbf{V}\mathbf{\Delta}^\top \underbrace{\mathbf{U}^\top\mathbf{U}}_{=\mathbf{I}_n}\mathbf{\Delta}\mathbf{V}^\top = \mathbf{V}\ \mathrm{diag}\Big(\tfrac{\delta_1^2}{n}, \ldots, \tfrac{\delta_p^2}{n}\Big)\mathbf{V}^\top.$$

Il s'agit de la décomposition spectrale de $\mathbf{M}$ (théorème 1.4.1) : on identifie $\lambda_k = \delta_k^2/n$, et les vecteurs propres orthonormés de $\mathbf{M}$ sont les colonnes $\boldsymbol{v}_k$ de $\mathbf{V}$, qui sont donc bien les axes principaux $\boldsymbol{a}_k$ (théorème 2.3.1).

Les algorithmes SVD actuels travaillent directement sur $\mathbf{Z}$ sans former $\mathbf{Z}^\top\mathbf{Z}$, ce qui évite les erreurs d'arrondi informatiques. □

2.6 Équivalence des trois formulations

La section précédente a montré comment calculer les axes de (F1) via la SVD. On montre maintenant que les trois formulations de la section 2.1 admettent toutes la même solution.

(F1) $\Leftrightarrow$ (F2). L'inertie totale $I = \mathrm{tr}(\mathbf{M})$ est fixe et se décompose (étape 6 du théorème 2.3.1) en $I = I_q + I_{\text{résiduelle}}$. Maximiser l'inertie projetée I_q est donc exactement équivalent à minimiser l'inertie résiduelle, qui est précisément l'objectif de (F2).

(F1) $\Leftrightarrow$ (F3). La distance de Frobenius entre $\mathbf{Z}$ et son approximation de rang q s'interprète directement comme l'inertie résiduelle :

$$\frac{1}{n}\|\mathbf{Z} - \mathbf{Z}_q\|_F^2 = \frac{1}{n}\sum_{i=1}^{n} \|\boldsymbol{z}_i - \mathbf{P}_V \boldsymbol{z}_i\|^2 = I_{\text{résiduelle}}.$$

On obtient alors la chaîne :

$$\min_{\operatorname{rang}(\mathbf{B}) \le q} \|\mathbf{Z} - \mathbf{B}\|_F^2 \iff \min\ I_{\text{résiduelle}} \iff \max\ I_q.$$

Par le théorème d'Eckart–Young (1.6.1), la solution est la SVD tronquée à q termes :

$$\mathbf{Z}_q = \mathbf{U}_q \boldsymbol{\Delta}_q \mathbf{V}_q^\top = \sum_{k=1}^{q} \delta_k\, \boldsymbol{u}_k \boldsymbol{v}_k^\top,$$

dont les axes $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_q$ sont les q premiers axes principaux de (F1).

Les trois formulations sont donc équivalentes et partagent la même solution : calculés en pratique via la SVD de $\mathbf{Z}$.

2.7 Composantes principales

Les axes principaux $\boldsymbol{a}_1, \ldots, \boldsymbol{a}_p$ sont les vecteurs propres de $\mathbf{M}$. Ces axes vivent dans $\mathbb{R}^p$: ce sont des directions. Il reste à définir les nouvelles variables obtenues en projetant les individus sur ces directions. Ce sont les composantes principales.

Définition 2.7.1 (Composante principale)**.** *La k-ième composante principale est la variable $\boldsymbol{F}_k \in \mathbb{R}^n$ définie par*

$$\boldsymbol{F}_k = \mathbf{Z}\,\boldsymbol{a}_k, \qquad k = 1, \ldots, p.$$

En notation matricielle, l'ensemble des p composantes principales se regroupe dans la matrice :

$$\mathbf{F} = \mathbf{Z}\mathbf{A} \in \mathbb{R}^{n\times p}, \qquad \mathbf{A} = [\boldsymbol{a}_1 \mid \cdots \mid \boldsymbol{a}_p] \in \mathbb{R}^{p\times p}.$$

Propriété 2.7.1 (Expression via la SVD)**.** *Soit $\mathbf{Z} = \mathbf{U}\boldsymbol{\Delta}\mathbf{V}^\top$ la SVD de $\mathbf{Z}$. Puisque $\mathbf{A} = \mathbf{V}$ (Proposition 2.5.1), la matrice s'écrit :*

$$\mathbf{F} = \mathbf{Z}\mathbf{V} = \mathbf{U}\boldsymbol{\Delta}\underbrace{\mathbf{V}^\top\mathbf{V}}_{=\mathbf{I}_p} = \mathbf{U}\boldsymbol{\Delta}.$$

Donc la SVD de $\mathbf{Z}$ donne les axes principaux (colonnes de $\mathbf{V}$), les valeurs propres et les composantes principales (colonnes de $\mathbf{U}\boldsymbol{\Delta}$).

2.8 Scores

Chaque élément F_{ik} de la matrice $\mathbf{F} = \mathbf{U}\boldsymbol{\Delta}$ est appelé *score* de l'individu i sur la k-ième composante :

$$F_{ik} = \boldsymbol{a}_k^\top \boldsymbol{z}_i = \sum_{j=1}^{p} a_{jk}\, z_{ij}.$$

Propriété 2.8.1 (Propriétés des scores)**.** *Pour tout $k = 1, \ldots, p$:*

(1) *Moyenne nulle :* $\dfrac{1}{n}\sum_{i=1}^{n} F_{ik} = 0.$

(2) *Variance égale à la valeur propre :* $\dfrac{1}{n}\sum_{i=1}^{n} F_{ik}^2 = \lambda_k.$

(3) *Non-corrélation : pour $k \neq k'$,* $\dfrac{1}{n}\sum_{i=1}^{n} F_{ik}\, F_{ik'} = 0.$

Démonstration.

(1) Les données étant centrées, $\mathbf{Z}$ a des colonnes de moyenne nulle,
donc $\frac{1}{n}\mathbf{1}_n^\top \mathbf{Z}\boldsymbol{a}_k = \bar{\boldsymbol{z}}^\top \boldsymbol{a}_k = \mathbf{0}^\top \boldsymbol{a}_k = 0.$

(2) $\frac{1}{n}\|\boldsymbol{F}_k\|^2 = \frac{1}{n}\boldsymbol{a}_k^\top \mathbf{Z}^\top \mathbf{Z}\, \boldsymbol{a}_k = \boldsymbol{a}_k^\top \mathbf{M}\, \boldsymbol{a}_k = \boldsymbol{a}_k^\top (\lambda_k \boldsymbol{a}_k) = \lambda_k.$

(3) De même, $\frac{1}{n}\boldsymbol{F}_k^\top \boldsymbol{F}_{k'} = \boldsymbol{a}_k^\top \mathbf{M}\, \boldsymbol{a}_{k'} = \lambda_{k'}\, \boldsymbol{a}_k^\top \boldsymbol{a}_{k'} = 0$, car $\boldsymbol{a}_k \perp \boldsymbol{a}_{k'}$. □

La propriété (3) est importante, elle dit : les composantes principales sont non corrélées donc elles apportent chacune une information distincte.

2.9 Loadings (corrélations variables–facteurs)

Un loading mesure la corrélation entre une variable originelle x_j et une composante principale F_k. Plus cette corrélation est forte en valeur absolue, plus la variable x_j contribue à définir l'axe k et est bien représentée par lui. On se place dans le cadre de l'ACP normée ($\mathbf{M} = \mathbf{R}$), où les données sont centrées-réduites ($\mathrm{Var}(z_j) = 1$).

Définition 2.9.1 (Loading)**.** *Le* loading *de la variable j sur la composante k est la corrélation de Pearson entre la variable centrée-réduite z_j et la composante F_k :*

$$\ell_{jk} = r(z_j, F_k) = \sqrt{\lambda_k}\, a_{jk}.$$

Démonstration. On calcule la covariance entre z_j et $F_k = \mathbf{Z}\boldsymbol{a}_k$:

$$\mathrm{Cov}(z_j, F_k) = \frac{1}{n}\boldsymbol{z}_j^\top \mathbf{Z}\boldsymbol{a}_k = \left(\frac{1}{n}\mathbf{Z}^\top\mathbf{Z}\,\boldsymbol{a}_k\right)_j = (\mathbf{R}\boldsymbol{a}_k)_j = \lambda_k\, a_{jk},$$

où l'on a utilisé $\mathbf{R}\boldsymbol{a}_k = \lambda_k \boldsymbol{a}_k$. Comme $\mathrm{Var}(z_j) = 1$ et $\mathrm{Var}(F_k) = \lambda_k$ (propriété (2) des scores), on obtient :

$$r(z_j, F_k) = \frac{\mathrm{Cov}(z_j, F_k)}{\sqrt{\mathrm{Var}(z_j)\ \mathrm{Var}(F_k)}} = \frac{\lambda_k\, a_{jk}}{\sqrt{\lambda_k}} = \sqrt{\lambda_k}\, a_{jk}.$$

□

Les loadings vérifient deux propriétés importantes :

Propriété 2.9.1.

(1) *La somme des carrés des loadings d'une variable sur tous les facteurs vaut 1 :*

$$\sum_{k=1}^{p} \ell_{jk}^2 = 1.$$

(2) *La somme des carrés des loadings d'un facteur sur toutes les variables vaut λ_k :*

$$\sum_{j=1}^{p} \ell_{jk}^2 = \lambda_k.$$

Démonstration.

(1) On substitue $\ell_{jk} = \sqrt{\lambda_k}\, a_{jk}$:

$$\sum_{k=1}^{p} \ell_{jk}^2 = \sum_{k=1}^{p} \lambda_k\, a_{jk}^2 = \left(\mathbf{A}\boldsymbol{\Lambda}\mathbf{A}^\top\right)_{jj} = \mathbf{R}_{jj} = 1,$$

où l'on a utilisé la décomposition spectrale $\mathbf{R} = \mathbf{A}\boldsymbol{\Lambda}\mathbf{A}^\top$ et le fait que les termes diagonaux de $\mathbf{R}$ valent 1.

(2) De même :

$$\sum_{j=1}^{p} \ell_{jk}^2 = \lambda_k \sum_{j=1}^{p} a_{jk}^2 = \lambda_k \left\|\boldsymbol{a}_k\right\|^2 = \lambda_k,$$

puisque $\boldsymbol{a}_k$ est un vecteur propre normé ($\|\boldsymbol{a}_k\| = 1$). □

La propriété **(1)** signifie que la variance totale de chaque variable originelle (égale à 1 en ACP normée) est entièrement répartie entre les p composantes.
La propriété **(2)** relie directement les loadings à la valeur propre λ_k : une composante qui a beaucoup de variance (λ_k grand) possède une somme de carrés de loadings élevée donc au moins une variable y est fortement liée.

2.10 Cosinus carré — qualité de représentation

Les loadings mesurent le lien entre variables et axes, les scores positionnent les individus dans le nouvel espace. Il reste une question : est-ce qu'un individu ou une variable est bien représenté sur les axes qu'on a retenus ? C'est ce que mesure le cosinus carré.

Pour les variables

En ACP normée, la variance totale de chaque variable z_j vaut 1 et se décompose entre les p composantes via les loadings (propriété **(1)** de la section 2.9) :

$$\sum_{k=1}^{p} \ell_{jk}^2 = 1.$$

Chaque terme ℓ_{jk}^2 représente donc la fraction de variance de z_j expliquée par F_k.

Définition 2.10.1 (Cosinus carré d'une variable)**.** *Le cosinus carré de la variable j sur l'axe k est*

$$\cos_{jk}^2 = \ell_{jk}^2 = \lambda_k \, a_{jk}^2.$$

Sa valeur cumulée sur les q premiers axes,

$$\cos_{j,q}^2 = \sum_{k=1}^{q} \cos_{jk}^2,$$

indique la qualité de représentation de la variable dans le sous-espace de dimension q.

Une variable avec $\cos_{j,q}^2$ proche de 1 est bien représentée dans le sous espace choisi. À l'inverse, $\cos_{j,q}^2$ proche de 0 signale que la variable est mal représentée et que son information est portée par d'autres axes.

Pour les individus

Pour un individu i, la qualité de représentation sur un axe se mesure différemment : on compare la distance de sa projection à l'origine à sa distance réelle à l'origine dans l'espace des données centrées.

Définition 2.10.2 (Cosinus carré d'un individu)**.** *Le cosinus carré de l'individu i sur l'axe k est*

$$\cos_{ik}^2 = \frac{F_{ik}^2}{d_i^2}, \qquad d_i^2 = \|\boldsymbol{z}_i\|^2 = \sum_{j=1}^{p} z_{ij}^2.$$

Sa valeur cumulée sur les q premiers axes,

$$\cos^2_{i,q} = \sum_{k=1}^{q} \cos^2_{ik} = \sum_{k=1}^{q} \frac{F_{ik}^2}{d_i^2},$$

indique la qualité globale de représentation de l'individu i dans le sous-espace de dimension q retenu. On a $\cos^2_{i,q} \in [0,1]$*, avec* $\cos^2_{i,p} = 1$*.*

Propriété 2.10.1. *Pour tout individu i, la somme des cosinus carrés sur tous les axes vaut 1, c'est un cas particulier pour q=p :*

$$\sum_{k=1}^{p} \cos^2_{ik} = 1.$$

Démonstration. On somme sur les p axes :

$$\sum_{k=1}^{p} \cos^2_{ik} = \frac{1}{d_i^2} \sum_{k=1}^{p} F_{ik}^2 = \frac{\|\boldsymbol{F}_i\|^2}{d_i^2},$$

où $\boldsymbol{F}_i \in \mathbb{R}^p$ est le vecteur des scores de l'individu i. Puisque $\boldsymbol{F}_i = \mathbf{A}^\top \boldsymbol{z}_i$ et que $\mathbf{A}$ est orthogonale ($\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p$), la transformation préserve les normes :

$$\|\boldsymbol{F}_i\|^2 = \|\mathbf{A}^\top \boldsymbol{z}_i\|^2 = \boldsymbol{z}_i^\top \mathbf{A}\mathbf{A}^\top \boldsymbol{z}_i = \boldsymbol{z}_i^\top \boldsymbol{z}_i = \|\boldsymbol{z}_i\|^2 = d_i^2.$$

On conclut $\sum_{k=1}^{p} \cos^2_{ik} = d_i^2/d_i^2 = 1$. □

Un individu avec un $\cos^2_{ik}$ élevé sur l'axe k est bien représenté sur cet axe. Un cosinus carré faible indique que l'individu est "écrasé" par la projection et que sa position dans le sous espace est à interpréter avec précaution, il est mal représenté.

Contributions

Le cosinus carré mesure la qualité de représentation d'un individu sur un axe. La contribution mesure l'influence d'un individu sur la construction de cet axe.

Définition 2.10.3 (Contribution d'un individu à un axe)**.** *La contribution de l'individu i à l'axe k est*

$$\mathrm{CTR}_{ik} = \frac{F_{ik}^2}{n\,\lambda_k}.$$

Un individu avec une contribution élevée est dit influent pour cet axe. On fera attention aux individus avec une contribution qui dépasse le seuil uniforme $1/n$, ils influencent l'axe plus que les autres.

2.11 Cercle des corrélations

Définition 2.11.1 (Cercle des corrélations)**.** *Le cercle des corrélations est la représentation graphique des variables dans le plan des deux premiers facteurs* (F_1, F_2)*. Chaque variable* j *est représentée par le point de coordonnées*

$$(\ell_{j1},\, \ell_{j2}) = (r(x_j, F_1),\, r(x_j, F_2)).$$

Tous ces points sont à l'intérieur ou sur le cercle unité (puisque $\ell_{j1}^2 + \ell_{j2}^2 \leq \sum_{k=1}^{p} \ell_{jk}^2 = 1$*).*

Règles d'interprétation.

- Un point proche du bord du cercle indique que la variable est bien représentée sur le plan (F_1, F_2).
- Deux variables proches l'une de l'autre sont fortement et positivement corrélées ; à l'opposé, elles sont fortement négativement corrélées.
- Une variable proche du centre est mal représentée sur ce plan (son information est portée par d'autres axes).
- L'angle θ_{jm} entre les vecteurs de deux variables approche leur corrélation : $r(x_j, x_m) \approx \cos\theta_{jm}$.

Chapitre 3

Application à la main sur un petit exemple

On s'intéresse ici à une application sur un petit exemple. L'idée est de bien comprendre ce qu'on fait. En travaillant sur un petit exemple, on suit le calcul de la matrice de corrélation, des valeurs propres et des vecteurs propres jusqu'aux représentations graphiques. On est en petite dimension les résultats sont donc assez peu parlant mais ils permettent de suivre l'application mathématique que l'on fait derrière.

3.1 Présentation du jeu de données

Description. Le jeu de données est constitué de six véhicules, de V_1 à V_6, avec chacuns trois variables quantitatives :

— X_1 : **Puissance moteur** (en chevaux) ;
— X_2 : **Poids** (en kilogrammes) ;
— X_3 : **Consommation mixte** (en litres aux cent kilomètres).

Ces trois variables ont intuitivvement des corrélations positives.

Tableau des données brutes. Les observations sont rassemblées dans la matrice des données $\mathbf{X} \in \mathcal{M}_{6,3}(\mathbb{R})$ suivante :

TABLE 3.1 – Données brutes du jeu de données voitures ($n = 6$, $p = 3$).

Individu	X_1 (ch)	X_2 (kg)	X_3 (L/100 km)
V_1	90	1 180	6,2
V_2	115	1 350	7,1
V_3	130	1 420	7,8
V_4	105	1 290	6,8
V_5	75	1 090	5,9
V_6	140	1 510	8,3

Notations. On note x_{ij} la valeur de la variable j pour l'individu i. Chaque individu a un poids $p_i = 1/n = 1/6$. On pose :

$$\bar{x}_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}, \qquad s_j^2 = \frac{1}{n}\sum_{i=1}^{n}(x_{ij} - \bar{x}_j)^2,$$

respectivement la moyenne la variance de la variable j. Les valeurs numériques sont récapitulées ci-dessous.

TABLE 3.2 – Statistiques descriptives univariées.

	X_1 (ch)	X_2 (kg)	X_3 (L/100 km)
Moyenne $\bar{x}_j$	109,17	1 306,67	7,02
Variance s_j^2	495,14	19 888,89	0,70

Remarque 3.1.1. *Les unités sont très hétérogènes, on verra qu'il est essentiel de considérer l'ACP normée réduite.*

3.2 Centrage et réduction

Pourquoi centrer et réduire ? Les trois variables X_1, X_2, X_3 sont exprimées dans des unités différentes et présentent des variances d'ordres de grandeur très différentes : $s_2^2 \approx 19\,889$ contre $s_3^2 \approx 0{,}70$ (voir tableau 3.2). Sans ça, l'ACP serait dominée par la variable la plus dispersée, en l'occurrence le poids X_2. on considère donc la matrice des données centrées-réduites $\mathbf{Z} \in \mathcal{M}_{6,3}(\mathbb{R})$, définie par :

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \qquad i = 1, \ldots, 6, \quad j = 1, 2, 3,$$

Calcul des données centrées-réduites.

$$z_{11} = \frac{90 - 109{,}17}{22{,}25} \approx -0{,}861, \qquad z_{12} = \frac{1\,180 - 1\,306{,}67}{141{,}03} \approx -0{,}898, \qquad z_{13} = \frac{6{,}2 - 7{,}02}{0{,}837} \approx -0{,}980.$$

En procédant de même pour les autres véhicules, on obtient la matrice $\mathbf{Z}$:

TABLE 3.3 – Données centrées-réduites $\mathbf{Z}$ (arrondi à 10^{-3}).

Individu	z_{i1}	z_{i2}	z_{i3}
V_1	$-0{,}861$	$-0{,}898$	$-0{,}980$
V_2	$0{,}262$	$0{,}307$	$0{,}096$
V_3	$0{,}936$	$0{,}804$	$0{,}932$
V_4	$-0{,}187$	$-0{,}118$	$-0{,}263$
V_5	$-1{,}536$	$-1{,}536$	$-1{,}339$
V_6	$1{,}386$	$1{,}441$	$1{,}530$
Somme	≈ 0	≈ 0	≈ 0

3.3 Calcul de la matrice de corrélation

Rappel : Dans le cadre d'une ACP normée, on peut analyser la matrice :

$$\mathbf{R} = \frac{1}{n}\,\mathbf{Z}^\top \mathbf{Z}.$$

Le terme générique de $\mathbf{R}$ est le coefficient de corrélation linéaire empirique entre les variables j et k :

$$r_{jk} = \frac{1}{n}\sum_{i=1}^{n} z_{ij}\, z_{ik} = \frac{1}{n}\sum_{i=1}^{n} \frac{(x_{ij}-\bar{x}_j)(x_{ik}-\bar{x}_k)}{s_j s_k}.$$

Calcul explicite des coefficients hors diagonale : On dispose des données centrées-réduites du tableau 3.3. Il y a trois coefficients distincts à calculer : r_{12}, r_{13} et r_{23}.

Coefficient r_{12} (Puissance / Poids).

$$\begin{aligned} r_{12} &= \frac{1}{6}\big[(-0{,}861)(-0{,}898) + (0{,}262)(0{,}307) + (0{,}936)(0{,}804) \\ &\qquad + (-0{,}187)(-0{,}118) + (-1{,}536)(-1{,}536) + (1{,}386)(1{,}441)\big] \\ &= \frac{1}{6}\big[0{,}773 + 0{,}080 + 0{,}753 + 0{,}022 + 2{,}359 + 1{,}997\big] = \frac{5{,}984}{6} \approx \mathbf{0{,}997}. \end{aligned}$$

Coefficient r_{13} (Puissance / Consommation).

$$\begin{aligned} r_{13} &= \frac{1}{6}\big[(-0{,}861)(-0{,}980) + (0{,}262)(0{,}096) + (0{,}936)(0{,}932) \\ &\qquad + (-0{,}187)(-0{,}263) + (-1{,}536)(-1{,}339) + (1{,}386)(1{,}530)\big] \\ &= \frac{1}{6}\big[0{,}844 + 0{,}025 + 0{,}872 + 0{,}049 + 2{,}057 + 2{,}121\big] = \frac{5{,}968}{6} \approx \mathbf{0{,}995}. \end{aligned}$$

Coefficient r_{23} (Poids / Consommation).

$$\begin{aligned} r_{23} &= \frac{1}{6}\big[(-0{,}898)(-0{,}980) + (0{,}307)(0{,}096) + (0{,}804)(0{,}932) \\ &\qquad + (-0{,}118)(-0{,}263) + (-1{,}536)(-1{,}339) + (1{,}441)(1{,}530)\big] \\ &= \frac{1}{6}\big[0{,}880 + 0{,}029 + 0{,}749 + 0{,}031 + 2{,}057 + 2{,}205\big] = \frac{5{,}951}{6} \approx \mathbf{0{,}992}. \end{aligned}$$

Matrice de corrélation : On obtient finalement :

$$\mathbf{R} = \begin{pmatrix} 1{,}000 & 0{,}997 & 0{,}995 \\ 0{,}997 & 1{,}000 & 0{,}992 \\ 0{,}995 & 0{,}992 & 1{,}000 \end{pmatrix}.$$

Remarque 3.3.1. *Pour cet exemple on voit bien qu'on a des corrélations extrèmement forte et qu'apriori un seul axe serait suffisant pour capturer l'essentiel des informations. On le mesure et vérifie dans la section suivante.*

3.4 Calcul des valeurs propres

Équation caractéristique : Les valeurs propres de $\mathbf{R}$ sont les racines du polynôme caractéristique de degré $p = 3$:

$$P(\lambda) = \det\big(\mathbf{R} - \lambda \mathbf{I}_3\big) = 0.$$

En développant :

$$P(\lambda) = (1-\lambda)\big[(1-\lambda)^2 - r_{23}^2\big] - r_{12}\big[r_{12}(1-\lambda) - r_{23}\, r_{13}\big] + r_{13}\big[r_{12}\, r_{23} - r_{13}(1-\lambda)\big]$$

Le polynôme caractéristique s'écrit donc :

$$\boxed{P(\lambda) = -\lambda^3 + 3\lambda^2 - 0{,}0319\,\lambda + 5{,}9 \times 10^{-5} = 0.}$$

Résolution numérique. Numériquement : $\lambda_1 \approx 2{,}989$, $\lambda_2 \approx 0{,}009$, $\lambda_3 \approx 0{,}002$.

TABLE 3.4 – Valeurs propres de $\mathbf{R}$ et parts d'inertie expliquées.

Composante	Valeur propre λ_k	Part λ_k/p (%)	Part cumulée (%)
CP_1	2,989	99,6	99,6
CP_2	0,009	0,3	99,9
CP_3	0,002	0,1	100,0
Total	3,000	100,0	

Remarque 3.4.1. *La méthode du déterminant fonctionne ici mais dans les faits la stratégie standard est de travailler directement sur la décomposition en valeurs singulières (SVD) de* $\mathbf{Z}$ *:*

$$\mathbf{Z} = \mathbf{U}\,\mathbf{\Sigma}\,\mathbf{V}^\top,$$

les valeurs propres de $\mathbf{R} = \frac{1}{n}\mathbf{Z}^\top\mathbf{Z}$ *s'obtenant alors comme* $\lambda_k = \sigma_k^2/n$*, sans jamais former* $\mathbf{R}$*.*

Remarque 3.4.2 (Concentration de l'inertie)**.** *Le premier axe principal capte à lui seul* 99,6 % *de l'inertie totale. Ce résultat, extrême mais cohérent avec les corrélations quasi-parfaites observées en section 3.3.*

3.5 Calcul des vecteurs propres (axes principaux)

Pour chaque λ_k, l'axe principal $\boldsymbol{a}_k$ est solution unitaire de :

$$(\mathbf{R} - \lambda_k \, \mathbf{I}_3)\, \boldsymbol{a}_k = \mathbf{0}, \qquad \|\boldsymbol{a}_k\| = 1.$$

Calcul de $\boldsymbol{a}_1$ pour $\lambda_1 = 2{,}989$. Le système $(\mathbf{R} - 2{,}989\,\mathbf{I}_3)\,\boldsymbol{a} = \mathbf{0}$ s'écrit :

$$\begin{aligned}
(L_1) \quad & -1{,}989\, a_1 + 0{,}997\, a_2 + 0{,}995\, a_3 = 0, \\
(L_2) \quad & 0{,}997\, a_1 - 1{,}989\, a_2 + 0{,}992\, a_3 = 0, \\
(L_3) \quad & 0{,}995\, a_1 + 0{,}992\, a_2 - 1{,}989\, a_3 = 0.
\end{aligned}$$

On fait $L_2' = 1{,}989\, L_2 + 0{,}997\, L_1$ pour éliminer a_1 :

$$-2{,}962\, a_2 + 2{,}965\, a_3 = 0 \quad \Longrightarrow \quad a_2 \approx 1{,}001\, a_3.$$

On pose $a_3 = 1$, d'où $a_2 \approx 1{,}001$, puis par (L_1) :

$$a_1 = \frac{0{,}997 \times 1{,}001 + 0{,}995}{1{,}989} = \frac{1{,}993}{1{,}989} \approx 1{,}002.$$

Normalisation : $\|\boldsymbol{v}_1\| = \sqrt{1{,}002^2 + 1{,}001^2 + 1^2} \approx 1{,}734$, d'où

$$\boxed{\boldsymbol{a}_1 \approx \begin{pmatrix} 0{,}578 \\ 0{,}577 \\ 0{,}577 \end{pmatrix}.}$$

Vecteurs $\boldsymbol{a}_2$ et $\boldsymbol{a}_3$. On applique la même procédure aux valeurs propres $\lambda_2 = 0{,}009$ et $\lambda_3 = 0{,}002$, sous la contrainte d'orthogonalité au théorème spectral. On obtient :

$$\boldsymbol{a}_2 \approx \begin{pmatrix} 0{,}198 \\ 0{,}587 \\ -0{,}785 \end{pmatrix}, \qquad \boldsymbol{a}_3 \approx \begin{pmatrix} -0{,}792 \\ 0{,}568 \\ 0{,}225 \end{pmatrix}.$$

Matrice des axes principaux.

$$\mathbf{A} \approx \begin{pmatrix} 0{,}578 & 0{,}198 & -0{,}792 \\ 0{,}577 & 0{,}587 & 0{,}568 \\ 0{,}577 & -0{,}785 & 0{,}225 \end{pmatrix}.$$

On vérifie l'orthogonalité :

$$\boldsymbol{a}_1^\top \boldsymbol{a}_2 = 0{,}114 + 0{,}339 - 0{,}453 = 0{,}000, \quad \boldsymbol{a}_1^\top \boldsymbol{a}_3 = -0{,}458 + 0{,}328 + 0{,}130 = 0{,}000.$$

3.6 Calcul des scores et des loadings

Scores. Les scores sont les coordonnées des individus sur les axes principaux. La matrice des scores est $\mathbf{F} = \mathbf{ZA}$, avec $F_{ik} = \boldsymbol{a}_k^\top \boldsymbol{z}_i$.

Calcul pour V_1 sur F_1.

En utilisant la première ligne de $\mathbf{Z}$ et $\boldsymbol{a}_1$:

$$\begin{aligned} F_{11} &= 0{,}578 \times (-0{,}861) + 0{,}577 \times (-0{,}898) + 0{,}577 \times (-0{,}980) \\ &= -0{,}498 - 0{,}518 - 0{,}566 = -1{,}581. \end{aligned}$$

En procédant de même pour tous les individus et les deux premiers axes, on obtient le tableau suivant (F_3 est pas calculé proche de 0 $\lambda_3 \approx 0$) :

TABLE 3.5 – Scores des individus sur les deux premiers axes principaux.

Individu	F_{i1}	F_{i2}
V_1	$-1{,}581$	$0{,}072$
V_2	$0{,}384$	$0{,}157$
V_3	$1{,}543$	$-0{,}074$
V_4	$-0{,}328$	$0{,}100$
V_5	$-2{,}547$	$-0{,}155$
V_6	$2{,}515$	$-0{,}081$
Somme	≈ 0	≈ 0

On vérifie que la variance des scores sur F_1 vaut bien λ_1 :

$$\frac{1}{6}\sum_{i=1}^{6} F_{i1}^2 = \frac{(-1{,}581)^2 + \cdots + (2{,}515)^2}{6} = \frac{17{,}95}{6} \approx 2{,}991 \approx \lambda_1.$$

Loadings. Le loading de la variable j sur l'axe k est :

$$\ell_{jk} = \sqrt{\lambda_k}\, a_{jk}.$$

On mesure la corrélation entre la variable de base z_j et le score F_k.

Calcul pour F_1. Avec $\sqrt{\lambda_1} = \sqrt{2{,}989} \approx 1{,}729$:

$$\ell_{11} = 1{,}729 \times 0{,}578 \approx 1{,}000, \quad \ell_{21} = 1{,}729 \times 0{,}577 \approx 0{,}998, \quad \ell_{31} = 1{,}729 \times 0{,}577 \approx 0{,}998.$$

En procédant de même pour F_2 ($\sqrt{\lambda_2} \approx 0{,}095$) et F_3 ($\sqrt{\lambda_3} \approx 0{,}045$), on obtient la matrice des loadings $\mathbf{L} = (\ell_{jk})$:

TABLE 3.6 – Matrice des loadings $\ell_{jk} = \sqrt{\lambda_k}\, a_{jk}$.

	F_1	F_2	F_3
X_1 (Puissance)	1,000	0,019	−0,036
X_2 (Poids)	0,998	0,056	0,026
X_3 (Conso.)	0,998	−0,075	0,010

On vérifie la propriété $\sum_{k=1}^{3} \ell_{jk}^2 = 1$ pour X_1 :

$$1{,}000^2 + 0{,}019^2 + 0{,}036^2 = 1{,}000 + 0{,}000 + 0{,}001 \approx 1{,}000.$$

Remarque 3.6.1. *Les loadings sur F_1 sont tous proches de 1 : les trois variables sont presque parfaitement corrélées au premier axe. F_2 et F_3 n'ont presque rien.*

3.7 Cosinus carrés et contributions

Cosinus carrés des variables. En ACP normée, le cosinus carré de la variable j sur l'axe k est directement le carré du loading :

$$\cos^2_{jk} = \ell^2_{jk}.$$

D'après le tableau 3.6, les loadings sur F_1 sont proches de 1, donc $\cos^2_{j,1} \approx 1$ pour $j = 1, 2, 3$: les trois variables sont quasiment représentées complètemennt sur le premier axe.

Cosinus carrés des individus. Le cosinus carré de l'individu i sur l'axe k est :

$$\cos^2_{ik} = \frac{F^2_{ik}}{d^2_i}, \qquad d^2_i = \|\boldsymbol{z}_i\|^2 = \sum_{j=1}^{3} z^2_{ij}.$$

Exemple pour V_2.

$$d^2_2 = 0{,}262^2 + 0{,}307^2 + 0{,}096^2 = 0{,}069 + 0{,}094 + 0{,}009 = 0{,}172,$$

$$\cos^2_{2,1} = \frac{F^2_{21}}{d^2_2} = \frac{0{,}384^2}{0{,}172} = \frac{0{,}147}{0{,}172} \approx 0{,}857.$$

V_2 est moins bien représenté sur F_1 que les autres véhicules : son score est plus proche de 0 donc il est proche du centre du nuage. En procédant de même pour tous les individus on a :

TABLE 3.7 – Distances au centre, cosinus carrés et qualité de représentation.

Individu	d^2_i	$\cos^2_{i,1}$	$\cos^2_{i,2}$	$\cos^2_{i,1+2}$
V_1	2,508	0,997	0,002	0,999
V_2	0,172	0,857	0,143	1,000
V_3	2,391	0,995	0,002	0,997
V_4	0,118	0,911	0,085	0,996
V_5	6,512	0,996	0,004	1,000
V_6	6,338	0,999	0,001	1,000

V_2 et V_4, plus proches du centre (car d^2_i petits), ils ont un $\cos^2_{i,1}$ légèrement inférieur : une partie de leur information est portée par F_2. Pour les autres, $\cos^2_{i,1} > 0{,}99$: ils sont très bien représentés sur le premier axe. Le plan (F_1, F_2) représente quasiment parfaitement l'ensemble des individus avec $\cos^2_{i,1+2} \geq 0{,}996$.

Contributions des individus. La contribution de l'individu i à la construction de l'axe k est :

$$\mathrm{CTR}_{ik} = \frac{F_{ik}^2}{n\,\lambda_k}.$$

Exemple pour V_5 sur F_1.

$$\mathrm{CTR}_{5,1} = \frac{(-2{,}547)^2}{6 \times 2{,}989} = \frac{6{,}487}{17{,}934} \approx 0{,}362 = 36{,}2\,\%.$$

TABLE 3.8 – Contributions des individus à F_1 (seuil uniforme $1/n \approx 16{,}7\,\%$).

Individu	F_{i1}^2	$\mathrm{CTR}_{i,1}$ (%)
V_1	2,499	13,9
V_2	0,147	0,8
V_3	2,381	13,3
V_4	0,108	0,6
V_5	6,487	36,2
V_6	6,325	35,3
Total	17,947	100,0

V_5 et V_6 contribuent à eux seuls à 71,5 % de la construction de F_1. V_2 et V_4 ont peu d'influence.

3.8 Représentations graphiques

Trois figures synthétisent les résultats des sections précédentes :

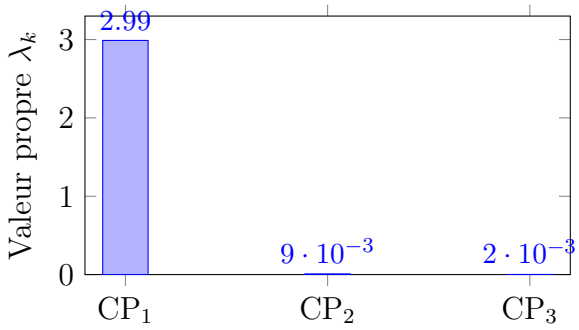


FIGURE 3.1 – Éboulis des valeurs propres de **R**.

Éboulis des valeurs propres. La chute est immédiate après CP_1 : la règle du coude et la règle de Kaiser–Guttman ($\lambda_k > 1$) désignent toutes deux une seule composante à retenir.

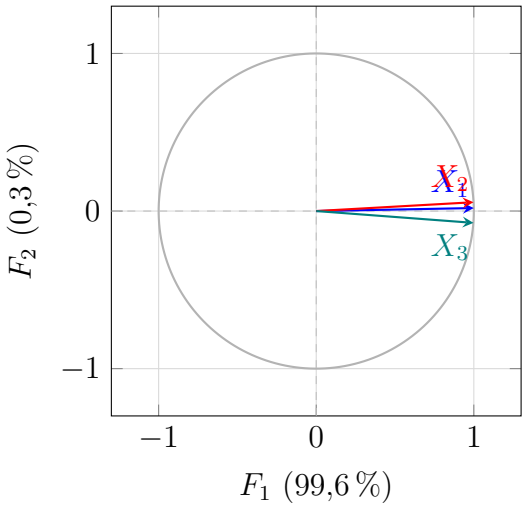


FIGURE 3.2 – Cercle des corrélations (plan F_1–F_2).

Cercle des corrélations. Les trois variables sont superposées près du bord : toutes ont un loading proche de 1 sur F_1 et négligeable sur F_2. Les flèches pointant dans la même direction qui se superposent indiquent que X_1, X_2 et X_3 sont corrélées entre elles (fortement).

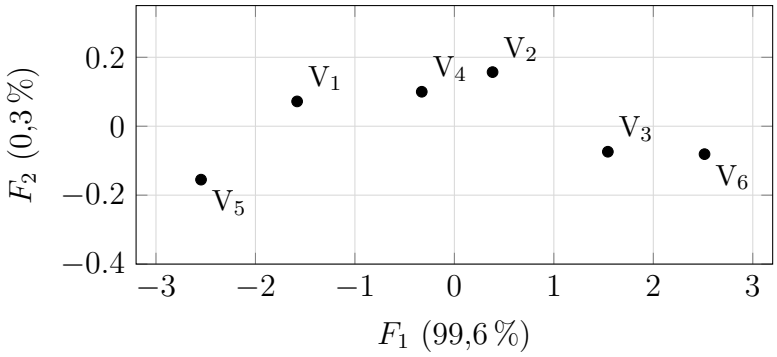


FIGURE 3.3 – Plan factoriel des individus (plan F_1–F_2).

Plan factoriel des individus. Les individus sont bien répartis sur F_1. Et le second axe ne montre que peu de variations.

Bilan. Les trois représentations convergent vers la même conclusion : la quasi-totalité de l'information contenue dans les trois variables est résumée par un unique axe. On passe ainsi d'un espace à 3 dimensions à 1 seule composante sans perte significative (99,6 % de l'inertie restituée), ce qui constitue l'objectif central de l'ACP. On a affiné en utilisant aussi F2 ici mais ce n'était probablement pas nécessaire. Cet exemple extrême (corrélations > 0.99) correspond à un cas dégénéré de l'ACP. On va alors s'intéresser à un cas plus réaliste et plus intéressant d'un nuage de points à plusieurs dimensions significatives.

Chapitre 4

Application sur données réelles

4.1 Présentation du jeu de données

Contexte : Le jeu de données utilisé dans ce chapitre est le dataset `decathlon`, disponible dans `FactoMineR`. Il regroupe les performances de 41 athlètes masculins lors de deux compétitions de décathlon : le *Decastar* (13 athlètes) et les *Jeux Olympiques d'Athènes 2004* (28 athlètes). Chaque athlète est décrit par 13 variables.

Variables : On distingue trois types de variables :

— **Variables actives** (colonnes 1 à 10) : les dix épreuves. Ce sont elles qui entrent dans le calcul des axes.

— **Variables illustratives** (colonnes 11 et 12) : `Rank` et `Points`. Elles ne participent pas au calcul mais seront projetées sur les axes pour aider à l'interprétation.

— **Variable illustrative qualitative** (colonne 13) : `Competition`. Elle permettra de visualiser si les athlètes des deux compétitions se distinguent sur le plan factoriel.

TABLE 4.1 – Description des dix variables actives.

Variable	Épreuve	Unité
`100m`	Sprint 100 m	secondes
`Long.jump`	Saut en longueur	mètres
`Shot.put`	Lancer du poids	mètres
`High.jump`	Saut en hauteur	mètres
`400m`	Course 400 m	secondes
`110m.hurdle`	110 m haies	secondes
`Discus`	Lancer du disque	mètres
`Pole.vault`	Saut à la perche	mètres
`Javeline`	Lancer du javelot	mètres
`1500m`	Course 1500 m	secondes

TABLE 4.2 – Statistiques descriptives des dix variables actives.

Variable	Unité	Min.	Moyenne	Max.
`100m`	secondes	10,44	11,00	11,64
`Long.jump`	mètres	6,61	7,26	7,96
`Shot.put`	mètres	12,68	14,48	16,36
`High.jump`	mètres	1,85	1,98	2,15
`400m`	secondes	46,81	49,62	53,20
`110m.hurdle`	secondes	13,97	14,61	15,67
`Discus`	mètres	37,92	44,33	51,65
`Pole.vault`	mètres	4,20	4,76	5,40
`Javeline`	mètres	50,31	58,32	70,52
`1500m`	secondes	262,1	279,0	317,0

Les variables sont exprimées dans des unités hétérogènes. On devrait se pencher vers une ACP normée.

4.2 Chargement et préparation des données

Cette section constitue le point de départ de tout workflow d'ACP sous R. On ouvre un nouveau script `.R` et on y ajoute les lignes suivantes au fur et à mesure.

Chargement des packages. On commence par charger les deux packages nécessaires à l'ensemble de l'analyse :

```
library(FactoMineR)   # ACP
library(factoextra)   # visuels
library(corrplot)     # visuels
library(plotly)       # visuels 3D
```

`FactoMineR` fournit la fonction `PCA()` qui réalise l'ACP. `factoextra` fournit des fonctions de visualisation construites sur `ggplot2` : éboulis, cercle des corrélations, plan factoriel.

Chargement des données : Dans un projet réel les données sont de la forme d'un fichier externe. On a souvent .xlsx ou .csv :

```
# CSV
data <- read.csv("chemin/vers/fichier.csv", row.names = 1)

# Excel
library(readxl)
data <- read_excel("chemin/vers/fichier.xlsx")
```

Dans notre cas le dataset `decathlon` est embarqué dans `FactoMineR`. On le charge puis exporte en CSV pour simuler exactement le cas d'un fichier reçu :

```
data(decathlon)
write.csv(decathlon, "decathlon.csv")
data <- read.csv("decathlon.csv", row.names = 1)
```

La suite est générique.

Vérification de la structure. Avant toute analyse on inspecte systématiquement le tableau chargé :

```
str(data)
```

```
'data.frame':   41 obs. of  13 variables:
 $ 100m         : num  11 10.8 11 11 11.3 ...
```

```
 $ Long.jump   : num  7.58 7.4 7.3 7.23 7.09 ...
 $ Shot.put    : num  14.8 14.3 14.8 14.2 15.2 ...
 $ High.jump   : num  2.07 1.86 2.04 1.92 2.1 ...
 $ 400m        : num  49.8 49.4 48.4 48.9 50.4 ...
 $ 110m.hurdle: num  14.7 14.1 14.1 15 15.3 ...
 $ Discus      : num  43.8 50.7 49 40.9 46.3 ...
 $ Pole.vault  : num  5.02 4.92 4.92 5.32 4.72 ...
 $ Javeline    : num  63.2 60.1 50.3 62.8 63.4 ...
 $ 1500m       : num  292 302 300 280 276 ...
 $ Rank        : int  1 2 3 4 5 6 ...
 $ Points      : int  8217 8122 8099 8067 8036 ...
 $ Competition: Factor w/ 2 levels "Decastar","OlympicG": 1 1 ...
```

Vérification des valeurs manquantes. L'ACP requiert un tableau complet : toute valeur manquante doit être traitée avant de lancer l'analyse. On vérifie systématiquement :

```
colSums(is.na(data))
```

```
       100m    Long.jump     Shot.put    High.jump         400m 110m.
          hurdle
          0            0            0            0            0
                       0
     Discus  Pole.vault     Javeline        1500m         Rank
        Points
          0            0            0            0            0
                       0
Competition
          0
```

Aucune valeur manquante.

4.3 Exploration préliminaire et matrice de corrélation

Avant de lancer l'ACP, on explore pour détecter des structures de corrélation et vérifier que l'ACP est pertinente sur ce jeu de données.

Calcul de la matrice de corrélation. On calcule la matrice de corrélation empirique entre les dix variables actives :

```
cor(data[, 1:10])
```

On obtient la matrice $\mathbf{R} \in \mathcal{M}_{10,10}(\mathbb{R})$:

TABLE 4.3 – Matrice de corrélation des dix variables actives (arrondi à 10^{-2}).

	100m	L.j	S.p	H.j	400m	110h	Disc	P.v	Jav	1500
100m	1,00	−0,60	−0,36	−0,25	0,52	0,58	−0,22	−0,08	−0,16	−0,06
L.j	−0,60	1,00	0,18	0,29	−0,60	−0,51	0,19	0,20	0,12	−0,03
S.p	−0,36	0,18	1,00	0,49	−0,14	−0,25	0,62	0,06	0,37	0,12
H.j	−0,25	0,29	0,49	1,00	−0,19	−0,28	0,37	−0,16	0,17	−0,04
400m	0,52	−0,60	−0,14	−0,19	1,00	0,55	−0,12	−0,08	0,00	0,41
110h	0,58	−0,51	−0,25	−0,28	0,55	1,00	−0,33	0,00	0,01	0,04
Disc	−0,22	0,19	0,62	0,37	−0,12	−0,33	1,00	−0,15	0,16	0,26
P.v	−0,08	0,20	0,06	−0,16	−0,08	0,00	−0,15	1,00	−0,03	0,25
Jav	−0,16	0,12	0,37	0,17	0,00	0,01	0,16	−0,03	1,00	−0,18
1500	−0,06	−0,03	0,12	−0,04	0,41	0,04	0,26	0,25	−0,18	1,00

Visualisation avec `corrplot`. On peut la visualiser sous forme de carte de chaleur :

```
corrplot(mat_cor,
                method      = "color",
                type        = "upper",
                tl.cex      = 0.8,
                addCoef.col = "black",
                number.cex  = 0.7,
                title       = "Matrice de corrélation",
                mar         = c(0, 0, 1.5, 0))
```

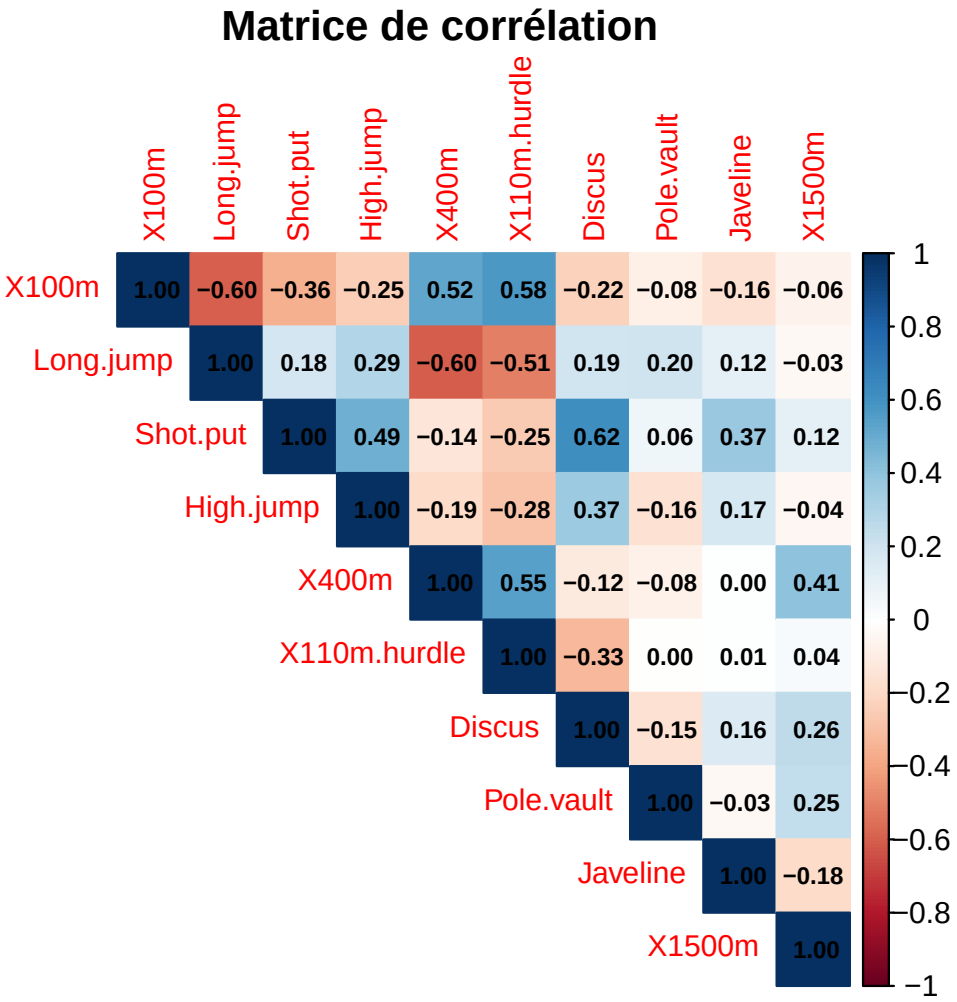


FIGURE 4.1 – Matrice de corrélation des 10 variables du décathlon

Lecture de la matrice. Trois groupes de corrélations se dégagent :

- **Bloc vitesse–explosivité** : `100m`, `400m`, `110m.hurdle` et `Long.jump` sont fortement intercorrélés ($|r| \in [0{,}51\,;\,0{,}60]$). Un bon sprinter a un *petit* temps au `100m` mais une *grande* distance en `Long.jump`, d'où la corrélation négative $r = -0{,}60$ entre ces deux variables.
- **Bloc force–lancer** : `Shot.put` et `Discus` sont fortement corrélés ($r = 0{,}62$).
- **Variables indépendantes** : `Pole.vault`, `Javeline` et `1500m` présentent de faibles corrélations avec les autres variables ($|r| < 0{,}30$), probablement qu'elles apportent des informations utiles pas définis par d'autres variables.

Pertinence de l'ACP. La présence de corrélations significatives entre plusieurs variables confirme qu'il existe des données qui se "répètent", apportent la meme information : une réduction de dimension a du sens. À l'inverse, si toutes les corrélations avaient été proches de zéro, les variables seraient déjà indépendantes et l'ACP n'apporterait rien.

Remarque 4.3.1. *Cette matrice de corrélation est calculée ici pour l'exploration et la visualisation.* `FactoMineR` *n'utilise pas* $\mathbf{R}$ *lors du calcul de l'ACP : la fonction* `PCA()` *applique directement la SVD sur la matrice des données centrées-réduites* $\mathbf{Z}$*, sans jamais former ni diagonaliser* $\mathbf{R}$*. Les valeurs propres et les axes principaux sont obtenus comme* $\lambda_k = \delta_k^2/n$ *et* $\boldsymbol{a}_k = \boldsymbol{v}_k$ *(proposition 2.5.1).*

4.4 Choix du type d'ACP et lancement

Pourquoi une ACP normée ? Le tableau 4.2 montre une forte hétérogénéité des unités et des ordres de grandeur : le `1500m` est mesuré en secondes avec des valeurs supérieures à 260, tandis que le `High.jump` est exprimé en mètres avec des valeurs proches de 2. Sans standardisation, l'ACP serait entièrement dominée par les variables à grande variance.

On travaille donc sur la matrice des données *centrées-réduites* $\mathbf{Z}$, de sorte que chaque variable z_j ait variance 1. Cela revient à diagonaliser la matrice de corrélation $\mathbf{R}$ plutôt que la matrice de variance-covariance $\mathbf{S}$, comme établi à la section 1.2.

La fonction `PCA()` de `FactoMineR`. Elle permet de réaliser l'ACP sur un tableau de données. Sa signature complète est la suivante :

```
PCA(X,
    scale.unit  = TRUE,
    ncp         = 5,
    graph       = TRUE,
    ind.sup     = NULL,
    quanti.sup  = NULL,
    quali.sup   = NULL)
```

Les arguments principaux sont décrits ci-dessous.

- `X` : le tableau de données
- `scale.unit` : si `TRUE` (défaut), les variables sont centrées-réduites avant l'analyse (ACP normée, diagonalisation de $\mathbf{R}$). Si `FALSE`, seul le centrage est appliqué (ACP non normée, diagonalisation de $\mathbf{S}$).
- `ncp` : nombre de composantes principales conservées dans l'objet résultat. (Par défaut 5).
- `graph` : si `TRUE`, les graphiques sont produits automatiquement au moment de l'appel. On passe `FALSE` pour les produire avec `factoextra`.
- `quanti.sup` : vecteur d'indices des *variables illustratives quantitatives*. Elles ne participent pas au calcul mais sont projetées, ce qui permet d'évaluer leur corrélation avec les composantes.
- `quali.sup` : vecteur d'indices des *variables illustratives qualitatives*.

Lancement de l'ACP. On dispose du tableau `data` chargé à la section 4.2, dont les 41 lignes sont les athlètes et les 13 colonnes les variables décrites au tableau 4.1. L'appel est le suivant :

```
res.pca <- PCA(data,
               scale.unit = TRUE,    # ACP normée
               ncp        = 5,       # 5 composantes gardées
               graph      = FALSE,   # graphiques après
               quanti.sup = 11:12,   # Illustratives
               quali.sup  = 13)      # Illustratives
```

L'objet `res.pca` est une liste dont on peut inspecter la structure :

```
str(res.pca, max.level = 1)
```

```
List of 6
 $ eig       : eigenvalues
 $ var       : variables
 $ ind       : individus
 $ quanti.sup: illu
 $ quali.sup : illu
 $ call      : résumé statistiques
```

Les six composantes de l'objet sont décrites dans le tableau 4.4.

TABLE 4.4 – Structure de l'objet `res.pca` retourné par `PCA()`.

Champ	Contenu
`res.pca$eig`	Matrice 10×3 : valeurs propres, pourcentages de variance et pourcentages cumulés.
`res.pca$var`	Liste des résultats pour les variables actives : coordonnées (`coord`), corrélations (`cor`), cosinus carrés (`cos2`), contributions (`contrib`).
`res.pca$ind`	Liste des résultats pour les individus : coordonnées (`coord`), cosinus carrés (`cos2`), contributions (`contrib`), distances au centre (`dist`).
`res.pca$quanti.sup`	Coordonnées et corrélations de `Rank` et `Points` projetés sur les axes.
`res.pca$quali.sup`	Coordonnées des barycentres par modalité de `Competition` et test de Hotelling.
`res.pca$call`	Paramètres de l'appel (données centrées-réduites, normes, etc.).

On peut accéder directement aux valeurs propres et aux pourcentages d'inertie :

```
round(res.pca$eig, 3)
```

```
       eigenvalue percentage of variance cumulative % of variance
comp 1      3.272                 32.719                    32.719
```

comp 2	1.737	17.371	50.090
comp 3	1.405	14.049	64.140
comp 4	1.057	10.569	74.708
comp 5	0.685	6.848	81.556
comp 6	0.599	5.993	87.548
comp 7	0.451	4.512	92.061
comp 8	0.397	3.969	96.030
comp 9	0.215	2.148	98.178
comp 10	0.182	1.822	100.000

Le choix du nombre de composantes est abordé à la section suivante.

4.5 Choix du nombre de composantes

Critère 1 — Règle de Kaiser–Guttman ($\lambda_k > 1$). En ACP normée, la moyenne des valeurs propres vaut $\bar{\lambda} = \mathrm{tr}(\mathbf{R})/p = p/p = 1$. On ne retient que les composantes dont la valeur propre dépasse cette moyenne :

TABLE 4.5 – Application de la règle de Kaiser–Guttman.

Composante	λ_k	$\lambda_k > 1$?	**Décision**
F_1	3,272	Oui	Retenir
F_2	1,737	Oui	Retenir
F_3	1,405	Oui	Retenir
F_4	1,057	Oui	Retenir
F_5	0,685	Non	Exclure

La règle de Kaiser recommande de retenir **4 composantes**. F_4 passe le seuil de justesse.

Critère 2 — Règle du coude. La règle du coude, on l'applique en observant le graphique donné par :

```
fviz_eig(res.pca,
         addlabels = TRUE,    # affiche les % sur chaque barre
         ylim      = c(0, 45),
         main      = "Éboulis des valeurs propres")
```

Qui nous affiche les pourcentages d'inertie pour chaque valeur propre.

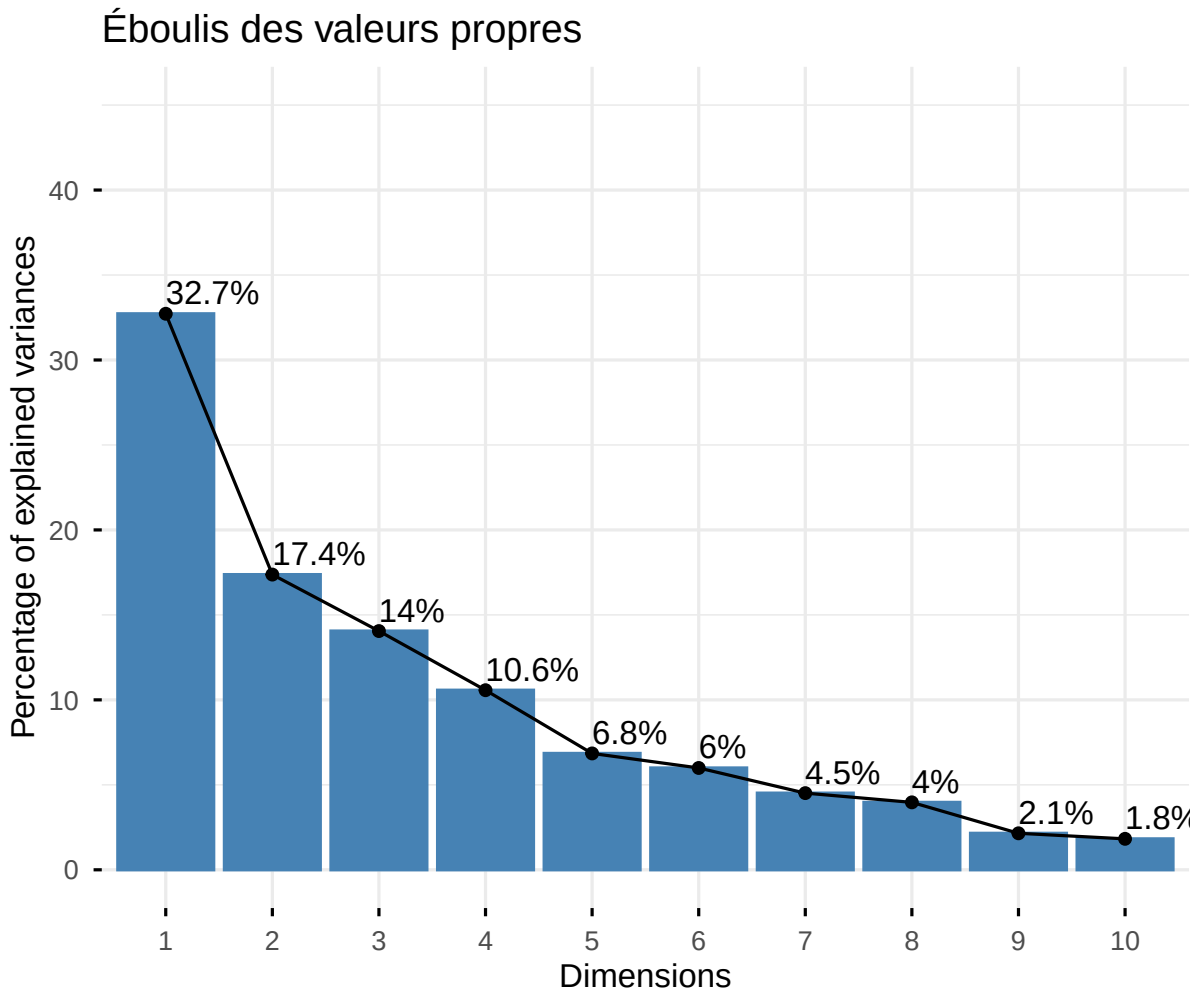


FIGURE 4.2 – Matrice de corrélation des 10 variables du décathlon

L'éboulis montre une décroissance rapide entre F_1 et F_5, puis une stabilisation à partir de F_5. La rupture de pente est localisée entre F_4 et F_5 : après F_4. La règle du coude désigne donc plutot **4 composantes**. Mais ça reste discutable au vu du graphique.

Critère 3 — Pourcentage d'inertie cumulée. Le seuil de 80 % souvent utilisé par exemple, n'est atteint qu'avec **5 composantes**.

on vérifie combien on en a avec 4 composantes :

```
res.pca$eig[4, 3]
```

qui nous donne :

```
> res.pca$eig[4, 3]
[1] 74.70804
```

On retient **4 composantes principales** pour l'analyse principal. F_1, F_2, F_3 et F_4 expliquent à eux deux 74.708% de l'inertie totale. F_4 possède une valeur propre de 1,057,

soit à peine au-dessus du seuil de Kaiser.

```
       eigenvalue percentage of variance cumulative percentage of
          variance
comp 1      3.272                  32.719                    32.719
comp 2      1.737                  17.371                    50.090
comp 3      1.405                  14.049                    64.140
comp 4      1.057                  10.569                    74.708
```

Décision. Les trois critères pointe plutôt vers 4 composantes :

— Kaiser et le coude montrent 4 axes.

— Le seuil de 80 % pointe vers 5 axes.

Fixer `ncp` en conséquence. Si l'on souhaitait se limiter à 4 composantes dès le calcul, on réglerait `ncp = 4` dans l'appel à `PCA()`.

```
res.pca$eig[1:4, ]
```

4.6 Analyse des variables — cercle des corrélations

Visualisation. On veut faire les cercles des corrélations avec `fviz_pca_var()`. L'argument `col.var = "cos2"` code la couleur de chaque variable selon sa qualité de représentation sur le plan (F_1, F_2) : Bien représentée en rouge foncé, mal représentée en gris.

```
fviz_pca_var(res.pca,
             col.var       = "cos2",
             gradient.cols = c("#AAAAAA", "#1E88E5", "#D32F2F"),
             repel         = TRUE,
             title         = "Cercle des corrélations")
```

L'argument `repel = TRUE` évite le chevauchement des étiquettes en les écartant.

On extrait les corrélations variables–facteurs (loadings), les cosinus carrés et les contributions depuis l'objet `res.pca$var` :

```
# Corrélations variables-facteurs (loadings)
round(res.pca$var$cor[, 1:4], 3)

# Cosinus carrés : qualité de représentation sur (F1, F2, F3, F4)
round(res.pca$var$cos2[, 1:4], 3)

# Cosinus carrés cumulés sur les 4 premiers axes
cos2_cum <- rowSums(res.pca$var$cos2[, 1:4])
round(sort(cos2_cum, decreasing = TRUE), 3)

# Contributions aux axes (%)
round(res.pca$var$contrib[, 1:4], 1)
# Seuil uniforme : 100 / p = 10 %
```

Seuls les loadings servent à la construction des cercles de corrélations, ils représentent la corrélation entre une variable et un axe.

Le cos^2 représente simplement le carré du loading et permet de dire à quel point regarder ce plan explique correctement une variable

Le CTR c'est l'inverse, il exprime à quel point une variable a contribué à la formation d'un axe.

On peut les utiliser sur nos cercles de corrélation de manière séparé pour avoir ces informations supplémentaires. Ils permettent d'avoir une interprétation plus visuelle.

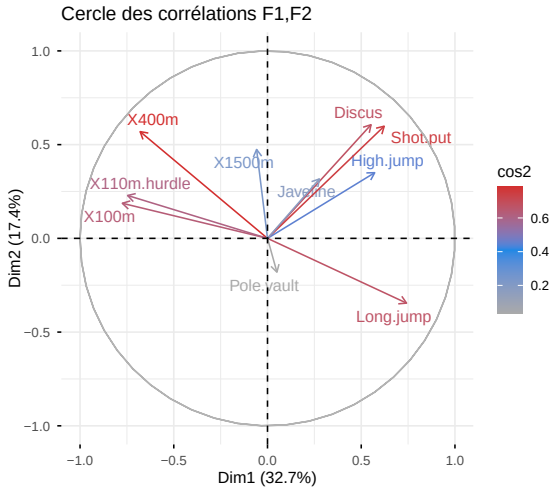
On utilise respectivement :

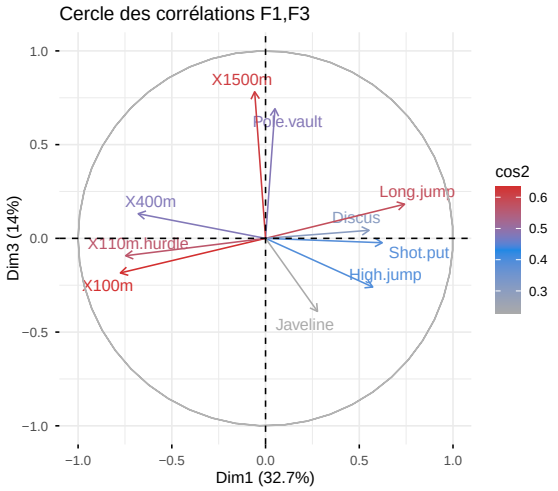
```
# Cercle des corrélations coloré par qualité de représentation (ici
    F1,F4)
print(fviz_pca_var(res.pca,axes=c(1,4),
                   col.var       = "cos2",
                   gradient.cols = c("#AAAAAA", "#1E88E5", "#D32F2F
                      "),
                   repel         = TRUE,
                   title         = "Cercle des corrélations"))
```

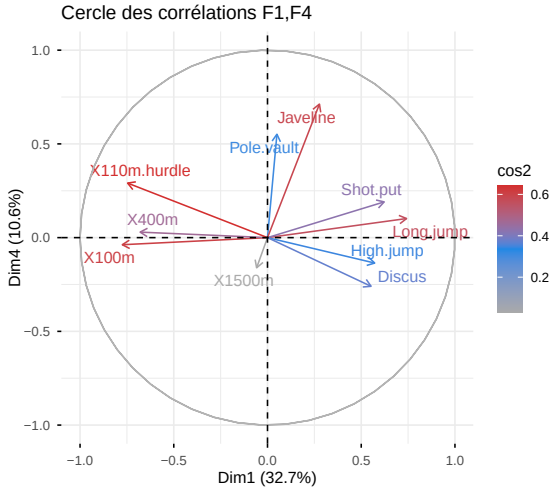
Ou :

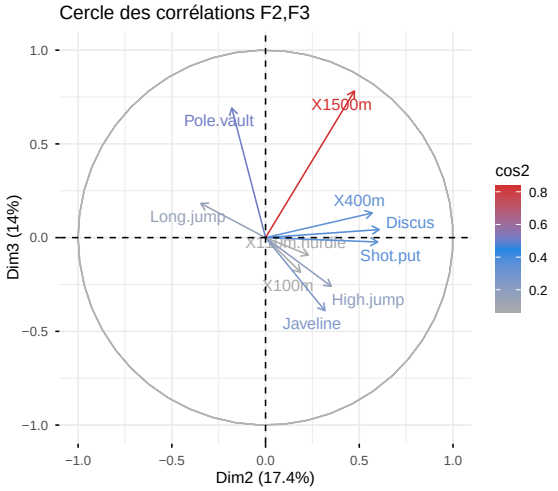
```
# Cercle des corrélations coloré par contribution
print(fviz_pca_var(res.pca, axes=c(3,4),
                   col.var       = "contrib",
                   gradient.cols = c("#AAAAAA", "#1E88E5", "#D32F2F
                      "),
                   repel         = TRUE,
                   title         = "Contributions des variables"))
```

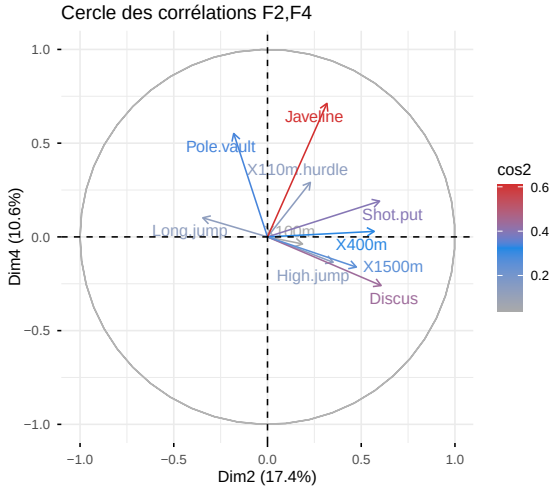
Ci-après respectivement la prochaine page : les représentations de nos cercles de corrélations avec le cos^2 : Les représentations de nos cercles de corrélations avec le CTR (contribution) sont quasiment identiques ici, donc je ne les ré-affiche pas.

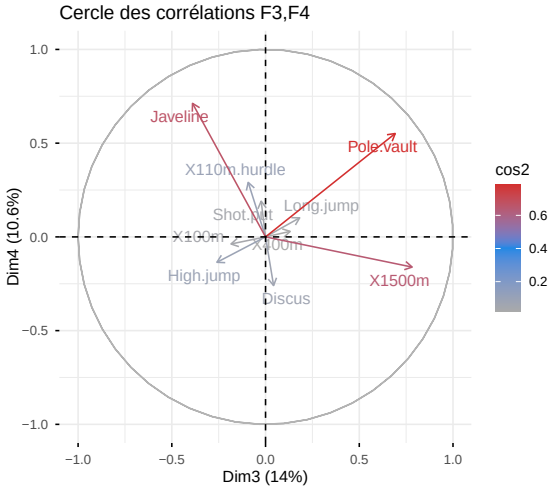

Cercle des corrélations F1,F2
X400m
Discus
Shot.put
X1500m
High.jump
X110m.hurdle
Javeline
X100m
Pole.vault
Long.jump
cos2
Dim1 (32.7%)
Dim2 (17.4%)


Cercle des corrélations F1,F3
X1500m
Pole.vault
Long.jump
X400m
Discus
X110m.hurdle
Shot.put
High.jump
X100m
Javeline
cos2
Dim1 (32.7%)
Dim3 (14%)


Cercle des corrélations F1,F4
Javeline
Pole.vault
X110m.hurdle
Shot.put
X400m
Long.jump
X100m
High.jump
X1500m
Discus
cos2
Dim1 (32.7%)
Dim4 (10.6%)


Cercle des corrélations F2,F3
Pole.vault
X1500m
X400m
Long.jump
Discus
X110m.hurdle
Shot.put
X100m
High.jump
Javeline
cos2
Dim2 (17.4%)
Dim3 (14%)


Cercle des corrélations F2,F4
Javeline
Pole.vault
X110m.hurdle
Shot.put
Long.jump
X100m
X400m
X1500m
High.jump
Discus
cos2
Dim2 (17.4%)
Dim4 (10.6%)


Cercle des corrélations F3,F4
Javeline
Pole.vault
X110m.hurdle
Long.jump
Shot.put
X100m
X400m
High.jump
X1500m
Discus
cos2
Dim3 (14%)
Dim4 (10.6%)

Qualité de représentation.

On voit que la plus part des variables sont bien représentés sur F1, F2. Seuls X1500m, Javeline et High.jump ne sont pas très fiables et Pol.vault pas du tout. On peut voir en revanche que le cercle de F3,F4 représente très bien Pole.vault, Javeline et X1500m. En revanche aucun ne capture particulièrment bien High.jump qui à l'air d'être un peu éparpillé partout. C'est cohérent avec ce qu'on avait vu de la matrice de variance covariance.

Lecture des cercle des corrélations.

Sur le premier cercle on retrouve notre **Groupe 1 :vitesse, explosivité** : `X100m` (loading $= -0{,}775$), `X110m.hurdle` ($-0{,}746$), `X400m` ($-0{,}680$) qui se distinguent par leur apparition dans le cadrant supérieur gauche du cercle et `Long.jump` (0,742) à l'opposé. Dans le cadrant supérieur droit on retrouve notre **Groupe 2 : force-lancer** : Le `Shot.put` (0,623) et le `Discus` (0,552)

Les autres cercles apportent et complètent certaines choses mais sont secondaires, on dégage déjà une bonne idée de notre représentation avec les deux premiers axes. Ils sont néanmoins utile pour compléter et avoir une interprétation complète de chaque variable. Si on s'intéresse à une variable en particulier il est en revanche essentiel de vérifier les axes qui lui correspondent, par exemple on voit que le `Javeline` est toujours porté par F4.

4.7 Analyse des individus — plan factoriel

Visualisation du plan factoriel. On représente les individus dans le plan (F_1, F_2) avec `fviz_pca_ind()`. Comme pour les variables la couleur montre les individus mal représentés sur ce plan :

```
fviz_pca_ind(res.pca,
             col.ind        = "cos2",
             gradient.cols  = c("#AAAAAA", "#1E88E5", "#D32F2F"),
             repel          = TRUE,
             title          = "Plan factoriel des individus")
```

Les scores, cosinus carrés et contributions des individus sont stockés dans `res.pca$ind` :

```
# Scores
round(res.pca$ind$coord[, 1:2], 3)

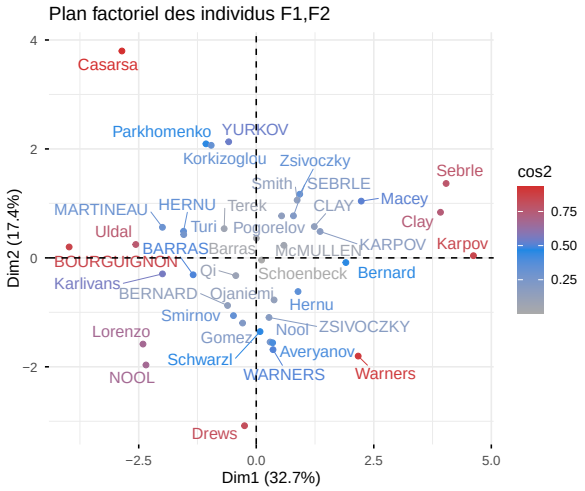
# Cosinus carrés
round(res.pca$ind$cos2[, 1:2], 3)

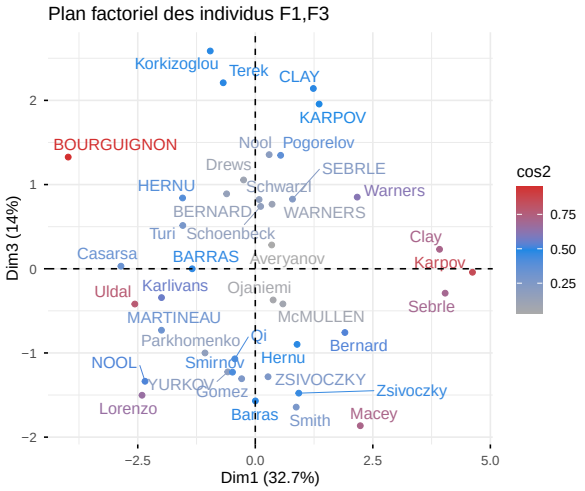
# Contributions (%)
round(res.pca$ind$contrib[, 1:2], 1)

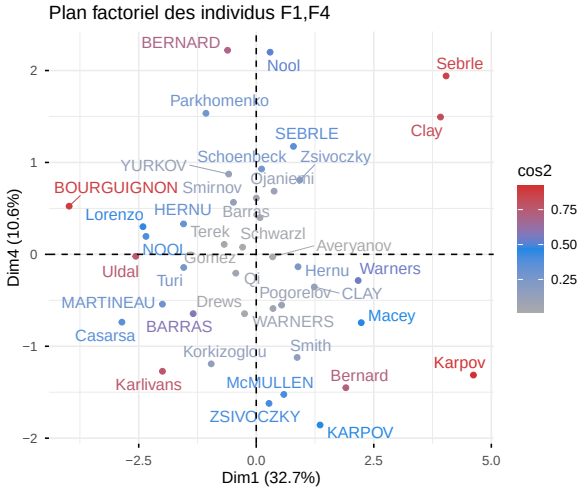
# Distance de chaque individu à l'origine
round(res.pca$ind$dist, 3)
```

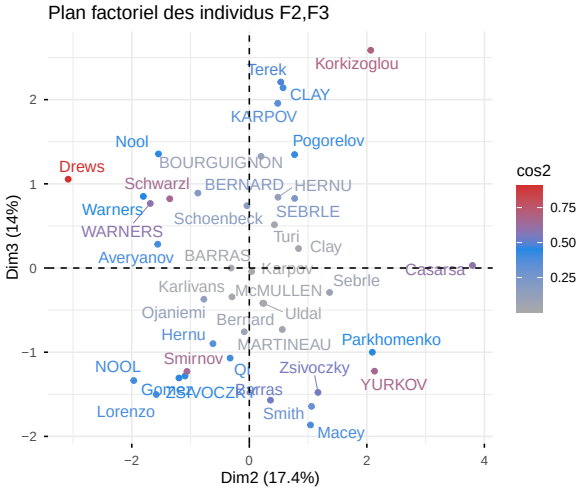
Pour notre cas on va étudier comme pour les cercles de corrélations les plans donnés par les axes deux à deux En complément, je propose aussi une visualisation des individus sur nos trois premiers axes F1, F2 et F3.

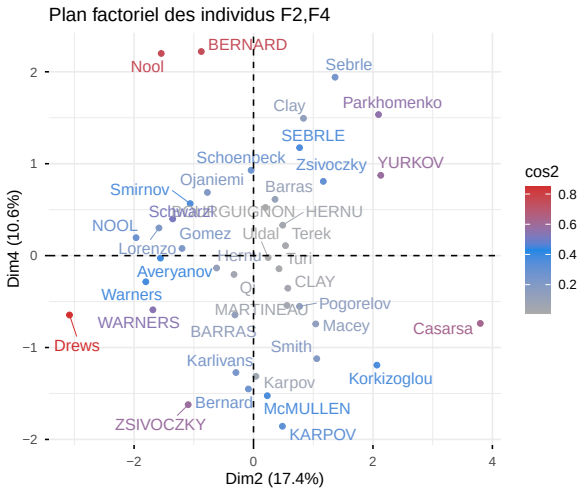
ci après nos graphiques.

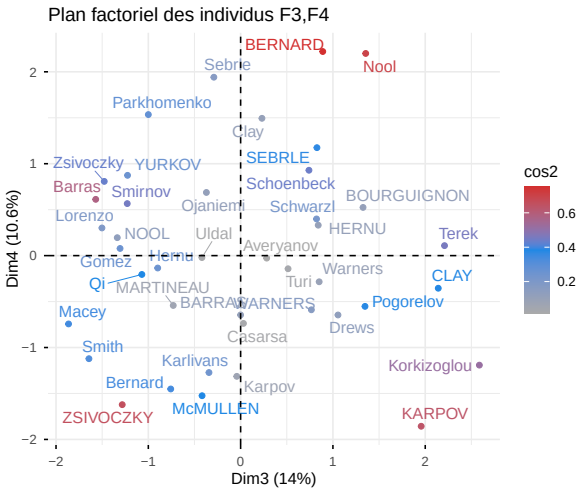

Plan factoriel des individus F1,F2
Dim1 (32.7%)
Dim2 (17.4%)
cos2
0.75
0.50
0.25
Casarsa
Parkhomenko
YURKOV
Korkizoglou
Zsivoczky
Smith
SEBRLE
Sebrle
MARTINEAU
HERNU
Terek
CLAY
Macey
Uldal
Turi
Pogorelov
Clay
BARRAS
Barras
McMULLEN
KARPOV
Karpov
BOURGUIGNON
Qi
Schoenbeck
Bernard
Karlivans
BERNARD
Ojaniemi
Hernu
Smirnov
Lorenzo
Nool
ZSIVOCZKY
Gomez
Averyanov
Schwarzl
NOOL
WARNERS
Warners
Drews

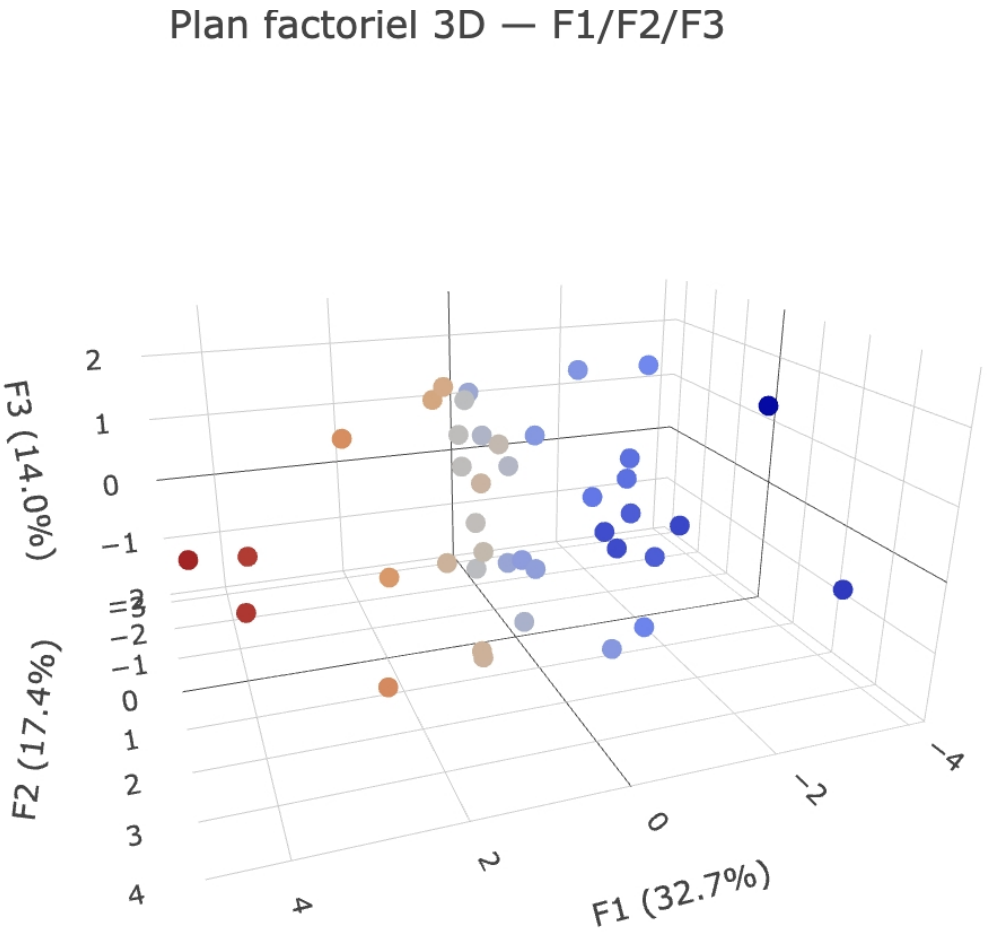

Plan factoriel des individus F1,F3
Dim1 (32.7%)
Dim3 (14%)
cos2
0.75
0.50
0.25
Korkizoglou
Terek
CLAY
KARPOV
BOURGUIGNON
Nool
Pogorelov
Drews
SEBRLE
HERNU
Schwarzl
Warners
BERNARD
WARNERS
Turi
Schoenbeck
Clay
Casarsa
BARRAS
Averyanov
Karpov
Uldal
Karlivans
Ojaniemi
Sebrle
MARTINEAU
McMULLEN
Parkhomenko
Qi
Bernard
NOOL
Smirnov
Hernu
YURKOV
ZSIVOCZKY
Gomez
Zsivoczky
Lorenzo
Barras
Smith
Macey


Plan factoriel des individus F1,F4
Dim1 (32.7%)
Dim4 (10.6%)
cos2
0.75
0.50
0.25
BERNARD
Nool
Sebrle
Parkhomenko
Clay
SEBRLE
Schoenbeck
Zsivoczky
YURKOV
Ojaniemi
BOURGUIGNON
Smirnov
Lorenzo
HERNU
Barras
Terek
Schwarzl
NOOL
Averyanov
Gomez
Uldal
Hernu
Warners
Turi
Qi
Pogorelov
CLAY
MARTINEAU
Drews
WARNERS
Macey
Casarsa
BARRAS
Korkizoglou
Smith
Karpov
Karlivans
McMULLEN
Bernard
ZSIVOCZKY
KARPOV


Plan factoriel des individus F2,F3
Dim2 (17.4%)
Dim3 (14%)
cos2
0.75
0.50
0.25
Terek
Korkizoglou
CLAY
KARPOV
Nool
Pogorelov
Drews
BOURGUIGNON
Schwarzl
BERNARD
HERNU
Warners
Schoenbeck
SEBRLE
WARNERS
Turi
Clay
Averyanov
BARRAS
Karpov
Casarsa
Karlivans
Sebrle
McMULLEN
Ojaniemi
Bernard
Uldal
Hernu
MARTINEAU
Parkhomenko
NOOL
Smirnov
Qi
Zsivoczky
YURKOV
Gomez
ZSIVOCZKY
Barras
Lorenzo
Smith
Macey


Plan factoriel des individus F2,F4
Dim2 (17.4%)
Dim4 (10.6%)
cos2
0.8
0.6
0.4
0.2
BERNARD
Nool
Sebrle
Clay
Parkhomenko
SEBRLE
Schoenbeck
Zsivoczky
YURKOV
Smirnov
Ojaniemi
Barras
Schwarzl
BOURGUIGNON
HERNU
NOOL
Gomez
Uldal
Terek
Lorenzo
Hernu
Turi
Averyanov
CLAY
Qi
Warners
MARTINEAU
Pogorelov
WARNERS
Macey
Casarsa
BARRAS
Drews
Smith
Karlivans
Karpov
Korkizoglou
Bernard
McMULLEN
ZSIVOCZKY
KARPOV


Plan factoriel des individus F3,F4
Dim3 (14%)
Dim4 (10.6%)
cos2
0.6
0.4
0.2
BERNARD
Nool
Sebrle
Parkhomenko
Clay
SEBRLE
Zsivoczky
YURKOV
Barras
Smirnov
Schoenbeck
BOURGUIGNON
Ojaniemi
Schwarzl
Lorenzo
HERNU
Terek
NOOL
Uldal
Averyanov
Gomez
Hernu
Warners
CLAY
Qi
Turi
MARTINEAU
BARRAS
WARNERS
Pogorelov
Macey
Drews
Casarsa
Smith
Karlivans
Korkizoglou
Bernard
Karpov
McMULLEN
ZSIVOCZKY
KARPOV



Cette figure est ici figée mais dans Rstudio on peut se déplacer dans l'espace 3D et avoir une bonne apréhension de la représentation de nos individus. (remarque : les couleurs de ce schéma sont arbitrairement basées sur F1, on pourrait attribuer la couleur aux cos^2 de nos individus pour avoir une idée de la fiabilité de leur représentation dans cet espace)

Lecture des plan factoriels :

Sur le plan F1, F2 on remarque que les individus en bords de graphiques sont mieux représentés que ceux vers le centre (aussi illustré par leurs couleurs qui tendent plus vers le rouge) Les capacités physiques de certains individus sont donc très bien cernés par les deux premiers axes, c'est le cas de Casara ou Karpov tandis que d'autres ne le sont absolument pas par exemple Terek ou Qi. Leurs capacités vont pouvoir être mieux cernés par d'autres plans.

Qualité de représentation des individus.

On doit faire attention à la qualité de la représentation des individus : **Individus bien représentés.** Les athlètes qui ont des cosinus carrés cumulés élevés ont un profil bien capturé par les axes. Leurs positions sur les plans sont donc bien représentatives. On peut aussi considérer les cos^2 non cumulés pour évaluer si tel ou tel plan les représentent bien (sur nos plan ceux bien représentés par ce plan tendent vers la couleur rouge)

Individus mal représentés. Ceux qui sont proches du centre du plan factoriel. Leur information est plus portée par d'autres axes. Le plan (F_1, F_2) ne restitue pas correctement tous les individus. On doit faire attention à l'interprétation des individus en fonction des plans.

Contributions et individus influents. La contribution d'un individu à un axe mesure son influence sur la construction de cet axe. Le seuil uniforme est $1/n = 1/41 \approx 2{,}4\,\%$. On repère les individus dont la contribution dépasse ce seuil, par exemple pour l'axe F1 :

```
seuil <- 100 / nrow(data)
ind_inf_F1 <- which(res.pca$ind$contrib[, 1] > seuil)
round(res.pca$ind$contrib[ind_inf_F1, 1:4], 1)
```

```
               Dim.1 Dim.2 Dim.3 Dim.4
MARTINEAU        3.0   0.4   0.9   0.7
NOOL             4.1   5.4   3.1   0.1
BOURGUIGNON     11.8   0.1   3.1   0.6
Sebrle          12.2   2.6   0.1   8.7
Clay            11.5   1.0   0.1   5.2
Karpov          15.9   0.0   0.0   4.0
Macey            3.7   1.5   6.0   1.3
Warners          3.5   4.6   1.3   0.2
Bernard          2.7   0.0   1.0   4.9
Lorenzo          4.3   3.5   3.9   0.2
Karlivans        3.0   0.1   0.2   3.7
Uldal            4.9   0.1   0.3   0.0
Casarsa          6.1  20.3   0.0   1.3
```

Il faut faire attention à l'influence des individus sur la construction des axes, on pourrait penser à les exclure pour vérifier leur impact.

4.8 Variables illustratives

Les variables illustratives `Rank`, `Points` (quantitatives) et `Competition` (qualitative) n'ont pas participé au calcul des axes. On les projete sur le plan (F_1, F_2) construit précédemment, on observe le lien qu'on peut avoir sans avoir influencé la formation des axes et choix précédents.

Variables illustratives quantitatives : `Rank` et `Points`

Extraction des corrélations. Pour une variable illustrative quantitative, `FactoMineR` calcule sa corrélation de Pearson avec chaque composante principale. On y accède via `res.pca$quanti.sup` :

```
round(res.pca$quanti.sup$cor, 3)
```

```
         Dim.1  Dim.2  Dim.3  Dim.4
Rank    -0.671  0.051 -0.058 -0.161
Points   0.956 -0.017 -0.066  0.236
```

Visualisation dans le cercle des corrélations. On peut superposer les variables illustratives au cercle des corrélations des variables actives pour visualiser leur positionnement :

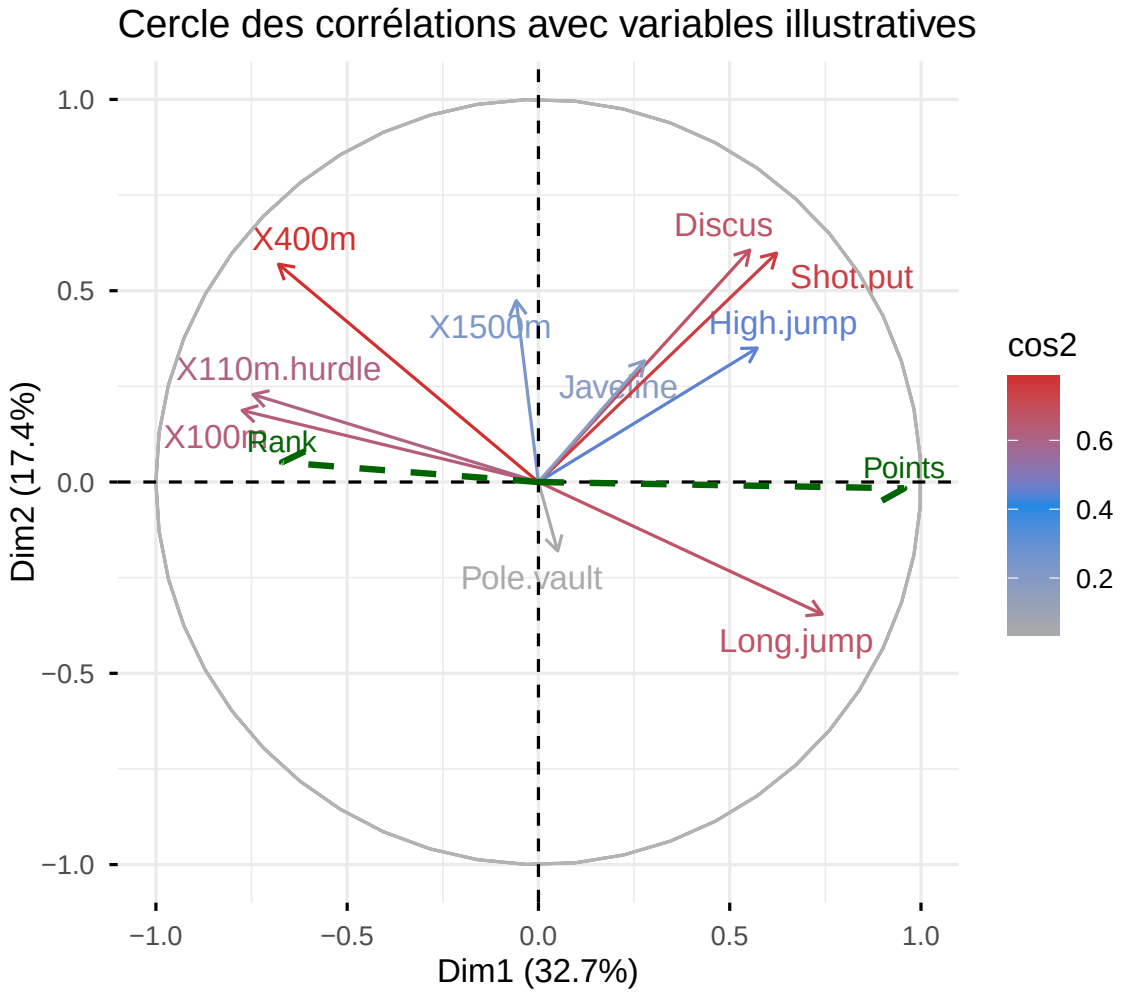
```
library(ggplot2)

#Graphique de base
p <- fviz_pca_var(res.pca,
                  col.var        = "cos2",
                  gradient.cols = c("#AAAAAA", "#1E88E5", "#D32F2F"
                     ),
                  repel          = TRUE,
                  title          = "Cercle des corrélations avec
                     variables illustratives")

# Coordonnées des variables illustratives
quanti_sup <- as.data.frame(res.pca$quanti.sup$coord[, 1:2])
quanti_sup$name <- rownames(quanti_sup)

# Ajout manuel des flèches en vert
p + geom_segment(data = quanti_sup,
                 aes(x = 0, y = 0, xend = Dim.1, yend = Dim.2),
                 arrow = arrow(length = unit(0.3, "cm")),
```

```
                  color = "darkgreen",
                  linewidth = 1,
                  linetype = "dashed") +
  geom_text(data = quanti_sup,
            aes(x = Dim.1, y = Dim.2, label = name),
            color = "darkgreen",
            vjust = -0.5,
            size = 3.5)
```



Interprétation. F1 représente vraiment bien les Points, donc c'est F1 qui représente le plus de gain de point, les variables qui contribuent à F1 sont donc celles qui ramènent le plus de points. En l'occurrence, ce sont les épreuves de "vitesse". Ce sont sur ces épreuves que se joue la plus grande part de la compétition (du gain de point). Contrairement à F2 qui sont des épreuves moins impactantes en terme de gain de points.

Variable illustrative qualitative : `Competition`

Représentation : Pour une variable illustrative qualitative, `FactoMineR` projette le barycentre sur le plan factoriel. On extrait ces coordonnées avec :

```
# Coordonnées des barycentres
round(res.pca$quali.sup$coord[, 1:4], 3)
```

```
           Dim.1  Dim.2  Dim.3  Dim.4
Decastar  -0.600 -0.038  0.289 -0.140
OlympicG   0.279  0.017 -0.134  0.065
```

Visualisation par compétition. On peut reproduire le plan factoriel des individus en colorant chaque athlète selon sa compétition et en ajoutant des ellipses de confiance à 95 % :

```
fviz_pca_ind(res.pca,
             habillage    = "Competition",
             addEllipses  = TRUE,
             ellipse.level = 0.95,
             palette      = c("#1E88E5", "#D32F2F"),
             repel        = TRUE,
             title        = "Plan factoriel coloré par compétition"
                )
```

Ici le résultat est peu concluant, les ellipses se chevauchent surtout et il n'ya pas de vraie distinction entre les deux groupes peu importe le plan sur lequel on l'effectue. En réalité ici la séparation entre les deux groupes se fait uniqument et légèrmeent par rapport à F1.

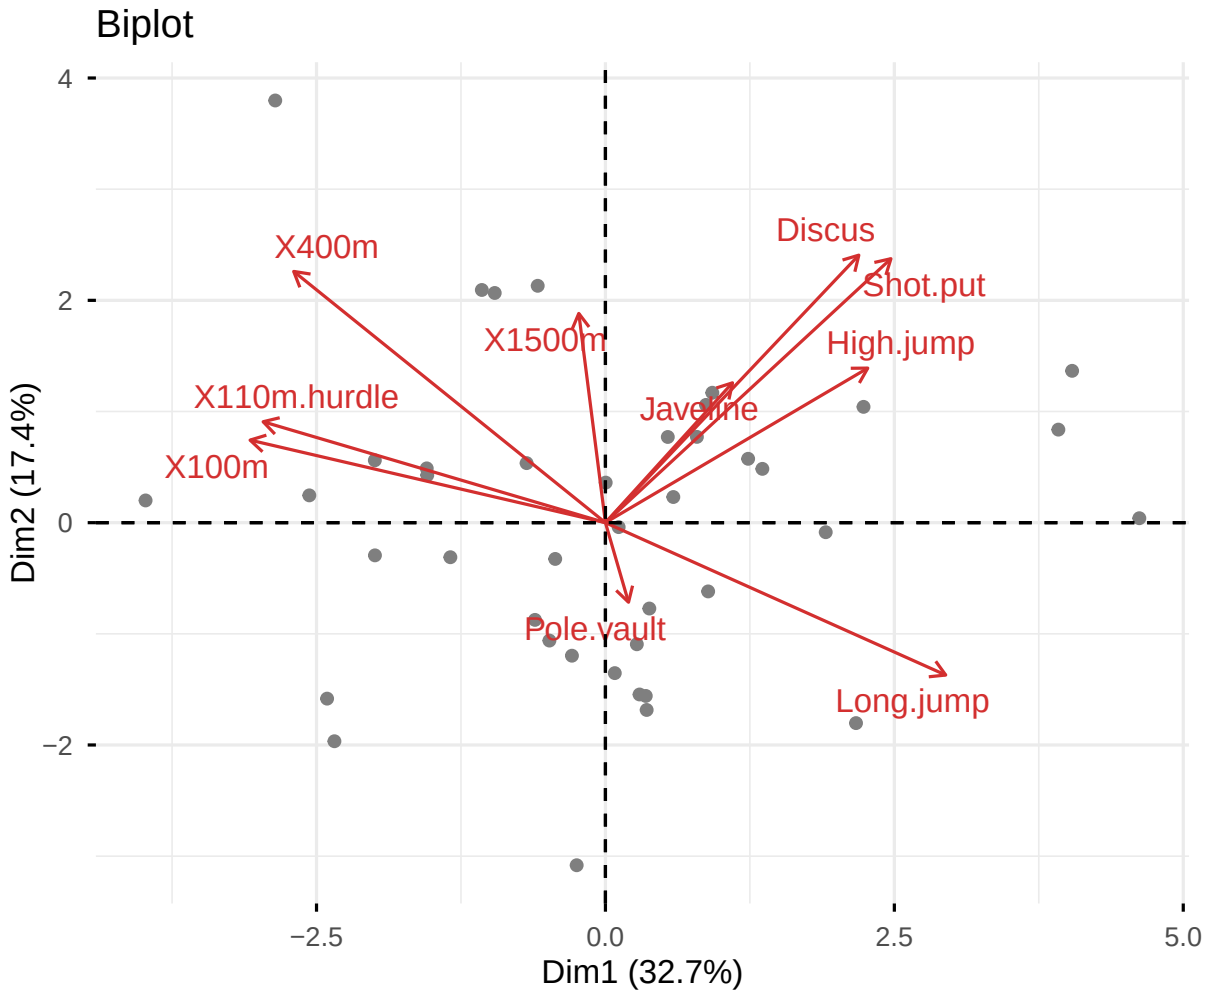
4.9 Interprétation

On a un ensemble de résultats graphiques. On les réunit en une phase de conclusion.

Biplot

Le biplot superpose les variables et les positions des individus. C'est la représentation la plus synthétique de l'ACP. On ne l'effectue ici que sur F1, F2.

```
fviz_pca_biplot(res.pca,
                col.var        = "#D32F2F",
                col.ind        = "gray50",
                repel          = TRUE,
                label          = "var",
                title          = "Biplot")
```



J'ai choisis de ne pas afficher les noms des individus pour ne pas surcharger. Un individu

situé dans la direction d'une flèche variable est un athlète qui a une valeur élevée pour cette variable.

L'ACP montre qu'il y a deux dimensions indépendantes dans cette compétition. Rapidité et force.

La vitesse comme déterminant du score. La corrélation de F_1 avec `Points` est la plus importante. Les épreuves de vitesse : 100 m, 400 m, 110 m haies, saut en longueur, déterminent le classement final.

A noter que l'échantillon de 41 athlètes reste relativement faible. A priori on reste bien dans le cadre et c'est un jeu de données fait pour être correctement interprété mais attention au cas pratique.

Conclusion

Dans ce mémoire nous avons présenté l'Analyse en Composantes Principales, depuis les outils mathématiques jusqu'à son utilisation sur données réelles.

Outils mathématiques : L'utilisation de la mesure de la dispersion d'un nuage de points par la matrice de variance-covariance $\mathbf{S}$ ou de corrélation $\mathbf{R}$, la projection orthogonale, la décomposition spectrale des matrices symétriques ou encore la décomposition en valeurs singulières, nous ont permis de construire les bases de l'ACP.

Trois formulations équivalentes : Dans le chapitre 2, on a répondu à la question : « comment réduire la dimension en perdant le moins d'information possible ? ». Cette question a trois formulations dont nous avons montré l'équivalence. Les axes principaux sont les vecteurs propres de $\mathbf{M}$. On les calcule en pratique directement par la SVD de la matrice des données centrées-réduites $\mathbf{Z}$. Les outils : scores, loadings, cosinus carrés, contributions, cercle des corrélations, forment un système permettant d'analyser individus et variables dans un espace réduit.

Un exemple illustratif à la main : L'application du chapitre 3 sur un jeu de données de véhicules montre chaque étape du calcul. Les corrélations très importantes entre les trois variables, montrent un cas extrême où la première composante à toute (presque) l'inertie.

Une application numérique sur données réelles : Le chapitre consacré au jeu de données `decathlon` est essentiel pour voir la puissance de l'ACP. Quatre composantes principales ont été retenues, expliquant 74,7 % de l'inertie. On a dégagé deux axes :

Un premier pour les épreuves de vitesse et d'explosivité (100 m, 400 m, 110 m haies, saut en longueur).

Un second lié aux épreuves de force et de lancers (poids, disque).

La corrélation entre la première composante et la variable illustrative `Points` montre que

les capacités en vitesse augmentent beaucoup le score global.

Limites : L'ACP ne voit pas les relations non linéaires entre variables. Elle est également sensible aux individus extrêmes. Elle n'est pas toujours applicable.

Ces limites ont motivé le développement d'autres méthodes. Que ce soit pour la réduction en dimension ou pour la visualisation en très grande dimension.

L'ACP reste une méthode incontournable. Elle fait partie d'une première analyse sur tout tableau de données.

Bibliographie

[1] Chavent, M. *Analyse en Composantes Principales*. Cours L3, Université de Bordeaux, 2013.
https://marie-chavent.perso.math.cnrs.fr/wp-content/uploads/2013/10/ACP_L3.pdf

[2] Jolliffe, I.T. *Principal Component Analysis*, 2e édition. Springer, 2002.
http://cda.psych.uiuc.edu/statistical_learning_course/Jolliffe%20I.%20Principal%20Component%20Analysis%20(2ed.,%20Springer,%202002)(518s)_MVsa_.pdf

[3] Saporta, G. *Probabilités, analyse des données et statistique*, 3e édition. Technip, 2011.
https://cdn-cms.f-static.com/uploads/1460418/normal_5b9ba5dc15394.pdf

[4] Progresser en maths. *ACP : cours complet — Formalisation mathématique*.
https://progresser-en-maths.com/acp-analyse-en-composantes-principales/

[5] Marcotte, D. *Analyse en composantes principales*. Cours GLQ3402, Polytechnique Montréal.
https://cours.polymtl.ca/geo/marcotte/glq3402/chapitre3.pdf

[6] Richard, C. *Analyse en Composantes Principales — Machine Learning*. Université de Nice.
https://www.cedric-richard.fr/assets/files/acp.pdf

[7] Hardouin, C. *Analyse en Composantes Principales*. Master 1 SES, CNRS.
https://fermin.perso.math.cnrs.fr/Files/doc-cours-acp.pdf

[8] Eckart, C. & Young, G. *The approximation of one matrix by another of lower rank*. *Psychometrika*, 1, 211–218, 1936.
https://ccrma.stanford.edu/~dattorro/eckart&young.1936.pdf

[9] Zhang, Z. *Singular Value Decomposition (SVD)*. Notes de cours, Carnegie Mellon University, 2022.
https://www.math.cmu.edu/users/zechengz/fall_2022_la/lec4_2p.pdf

[10] Golub, G.H. & Van Loan, C.F. *Matrix Computations*, 4e édition. Johns Hopkins University Press, 2013.

[11] FactoMineR Team. *Analyse en Composantes Principales — Documentation FactoMineR*.

http://factominer.free.fr/factomethods/analyse-en-composantes-principales.html

[12] STHDA. *Principal Component Analysis in R.*
https://www.sthda.com/english/wiki/wiki.php?id_contents=7851

Ressources ACP dans R

[13] DataCamp. *Analyse en Composantes Principales dans R.*
https://www.datacamp.com/fr/tutorial/pca-analysis-r

[14] Labatte, L. *Analyse en Composantes Principales.* Master 2, Université d'Angers.
https://math.univ-angers.fr/~labatte/enseignement%20UFR/masterTVPS/cm2010M2.pdf

[15] *ACP with R.*
https://fr.scribd.com/document/796209638/ACP-with-R

[16] Fermin, L. *ACP — Exemple du décathlon.* CNRS.
https://fermin.perso.math.cnrs.fr/Files/ACP-decatlon_new.html

[17] DellData. *Ressources pour l'ACP.*
https://delladata.fr/ressources-pour-acp/

Tutoriels vidéo — ACP dans R

[18] *Tutoriel ACP dans R.* YouTube.
https://www.youtube.com/watch?v=QpsTiVJbblo

[19] *Tutoriel ACP dans R.* YouTube.
https://www.youtube.com/watch?v=Zxv3ohNwYdA

[20] *Tutoriel ACP dans R.* YouTube.
https://www.youtube.com/watch?v=OEBVCZ3oNco

[21] *Tutoriel ACP dans R.* YouTube.
https://www.youtube.com/watch?v=dAk6uYzcC6w

[22] *Tutoriel ACP dans R.* YouTube.
https://www.youtube.com/watch?v=Tv9ex3NDeS0

[23] *ACP en R : Tutoriel Pratique pour Débutant(e)s.* YouTube.
https://www.youtube.com/watch?v=R44Q5hi7i6o